

CKA 기반 표현 다양성 정규화를 이용한 이미지 포렌식 이중 경량 모델 앙상블 설계 심층 조사

CKA와 HSIC를 학습 목적함수로 사용한 연구 흐름

CKA(Centered Kernel Alignment)는 원래 “표현 유사도 분석”을 위해 제안되었지만, 최근에는 **학습 손실 (regularizer)로 직접 넣는 사례**가 다수 확인됩니다. CKA의 대표적 형태(선형 CKA)는 두 표현 행렬 $X \in \mathbb{R}^{b \times d_1}, Y \in \mathbb{R}^{b \times d_2}$ (배치 크기 b)에 대해

$$\text{CKA}(X, Y) = \frac{\|X^\top Y\|_F^2}{\|X^\top X\|_F \|Y^\top Y\|_F}$$

처럼 정규화된 Gram-구조(예: $XX^\top, YY^\top$)의 코사인 유사도로 해석되며, (적절한 조건에서) 직교변환/스케일 변화에 대한 불변성 등 “표현 비교 지표”로서의 성질이 논의됩니다. ①

HSIC(Hilbert-Schmidt Independence Criterion)는 커널 기반 독립성/의존성 척도로, 표본 $Z = \{(x_i, y_i)\}_{i=1}^m$ 에 대해 K, L 을 커널 Gram, H 를 센터링 행렬로 두면 (biased) 추정량이

$$\text{HSIC}_b(Z) = \frac{1}{m^2} \text{tr}(KHLH)$$

꼴로 정리됩니다. ②

특히 선형 커널을 쓰면 HSIC/CKA가 “배치 내 (쌍대) 관계 구조”를 다루는 학습 신호가 되며, 실제로 CKA를 “(정규화된) HSIC 기반”으로 설명하면서 distillation 손실로 설계한 논문들이 그 연결고리를 명시합니다. ③

CKA를 손실로 직접 사용한 사례

1) Knowledge Distillation에서 CKA-기반 손실

BMVC 2022 논문은 “학생-교사”의 중간 표현을 직접 맞추는 대신, 배치 내 샘플-샘플 유사도(Gram 행렬)를 만들고 이를 CKA로 비교하는 **CKA 기반 distillation loss**를 제안합니다. 이 논문은 $\text{CKA} \in [0, 1]$ 를 목표(1에 가깝게)로 두고 $L_{\text{total}} = L_{\text{CE}} + \lambda_{\text{CKA}}(1 - \text{CKA})$ 형태로 학습에 통합했으며, 실험에서는 $\lambda_{\text{CKA}} = 1$, 배치 128, distillation 지점으로 **average pooling** 층을 사용한 설정이 명확히 기재됩니다. ④

CVPR 2021에서도 teacher-student 간 **Global CKA(GCKA)**를 “특징 유사도 최대화” 형태로 distillation에 쓰는 흐름이 확인됩니다. ⑤

2) CKA를 정규화 항으로 넣어 ‘유사도 감소/정체성 분리’를 유도

CKA를 “레이어 간 유사도 감소”에 사용해 희소성(sparsity)을 높이는 CKA-SR 계열은, CKA 측정을 **훈련 손실에 직접 정규화 항으로 추가**해 inter-layer feature similarity를 줄이는 접근을 취합니다. 또한 정보병목(IB) 관점에서 “유사도 감소 $\leftrightarrow$ (특정 조건에서) 상호정보 감소/희소성 증가”를 이론적으로 연결하려 합니다. ⑥

연합학습에서도 FedCKA처럼 CKA 기반 레이어-정규화를 목적함수에 넣는 사례가 보고됩니다. ⑦

HSIC를 목적함수(또는 핵심 구성요소)로 사용한 사례

1) HSIC Bottleneck(역전파 대안/충별 지역 학습 신호)

HSIC Bottleneck은 cross-entropy + backprop 대신 HSIC 기반 목적을 사용해 학습하는 프레임 제안을 하며, exploding/vanishing gradient 완화, update-locking 회피 등 “학습 메커니즘적” 주장을 포함합니다. ⑧

2) HSIC-loss로 ‘강건 학습’을 목표로 하는 설정

HSIC를 손실 함수로 직접 사용해 “잔차(residual)가 입력/환경과 독립이 되도록” 유도하여 covariate shift/강건성 쪽에 적용한 연구가 있습니다. 이 작업은 HSIC-loss를 supervised/robust 학습에 통합하는 대표 사례로 볼 수 있습니다.

9

3) DualHSIC(continual learning에서 간섭 억제 + 공유 촉진)

HSIC Bottleneck을 rehearsal buffer와 결합하고 task-invariant 공유를 위한 alignment까지 포함해, HSIC 기반 구성요소를 플러그인 정규화 항으로 쓰는 형태가 보고됩니다. 10

미니배치 단위 CKA/HSIC 추정의 분산과 실무적 해결책

CKA/HSIC는 본질적으로 배치 내 all-pairs 관계(Gram)를 쓰므로, b 가 작을수록 (i) 추정 분산이 커지고 (ii) 특정 샘플/아웃라이어 영향이 커지며 (iii) 커널/센터링 연산이 불안정해지기 쉽습니다. HSIC 쪽은 unbiased(U-statistics)와 biased(V-statistics) 추정량이 명확히 정의되어 있고, 어떤 추정량을 쓰느냐가 분산/편향에 영향을 준다는 점이 고전적으로 정리돼 있습니다. 11

또한 HSIC의 분산이 n 에 따라 감소하는 항(예: $O(n^{-1})$, $O(n^{-2})$ 계열)로 전개되는 결과와, 실용적 계산비용이 $O(n^2)$ 에 걸린다는 점이 정리되어 있어 “배치 크기 ↔ 안정성/비용” 트레이드오프가 구조적으로 존재합니다. 12

CKA도 같은 문제가 나타나며, 특히 작은 미니배치(예: GPU 당 2~4)로 학습하는 detection 류에서는 Gram이 “충분한 지식”을 모으지 못해 성능이 악화될 수 있음을 명시적으로 지적한 뒤, patch-based CKA(PCKA)로 “샘플 수를 사실상 늘리는” 해법이 제안됩니다. 13

또 다른 축으로는 CKA 자체가 단순 변환/아웃라이어에 민감하며 값 조작이 가능하다는 신뢰성 분석이 있어, “학습 목적에 직접 넣을 때의 위험(게임 가능성)”을 반드시 고려해야 합니다. 14

양상불 다양성을 직접 학습하는 방법론

양상불 다양성은 “좋은수록 무조건 이득”이 아니라, 정확도-다양성 trade-off의 형태로 나타난다는 것이 오래된 관찰입니다. 특히 NCL(negative correlation learning)은 각 구성 모델의 오차 상관을 패널티로 제어해 동시에 학습·결합하며, λ 로 bias-variance-covariance(=다양성) 균형을 조절할 수 있다고 설명합니다. 15

보다 현대적으로는 “양상불 다양성 이론”을 bias-variance 분해 안의 숨은 차원으로 정리하려는 시도도 있어, 다양성 그 자체를 목적함수로 넣는 작업이 왜 까다로운지(무엇을 다양성으로 정의하느냐) 배경을 제공합니다. 16

대표적 정규화 계열

DeCov(activation covariance 최소화)는 은닉 활성화의 공분산(대각 제외)을 직접 줄여 co-adaptation/과적합을 줄이려는 손실이며, 실제 실험에서 DeCov 가중치(예: CIFAR10에서 0.1이 안정적으로 나타남)를 튜닝 대상으로 다룹니다. 또한 “가중치 0이 전역 최소가 될 수 있다”는 류의 함정과, 대각(variance) 제거가 안정성에 도움 된다는 점을 논의합니다. 17

OrthoReg/정규직교(Gram=I) 류는 (가중치 혹은 특징의) Gram 행렬을 항등에 가깝게 하도록 강제해 직교성을 유도합니다. DeCov가 “activation 공분산”이라면, OrthoReg 계열은 “국소적 직교성”을 통해 decorrelation의 간섭 문제를 완화하는 동기를 제시합니다. 18

Anti-Distillation(출력/로짓 탈상관·반-증류)은 distillation이 구성원들을 비슷하게 만드는 경향이 있다는 반대편에서, 미니배치 수준에서 구성 모델들의 출력을 서로 밀어내는(decorrelate) 형태로 다양성을 강화합니다. 이 작업은 “부호가 음수인 항으로 모델들 간 차이를 키우는” 손실 설계를 명시적으로 보여줍니다. 19

Deep ensemble diversity regularization은 “정확도는 유지하면서 캘리브레이션/불확실성을 개선”하는 목표로 다양성 함수를 정규화 항으로 추가하는 흐름을 제시합니다. 20

다양성 강제 시 성능 저하와 완화(accuracy-diversity trade-off)

다양성 정규화가 과해지면 개별 모델이 “정답에 필요한 공통 신호”까지 버리면서 정확도가 떨어질 수 있습니다. 그 결과 앙상블도 이득이 제한되거나 손해가 될 수 있습니다(특히 데이터가 작거나 라벨 노이즈/도메인 이동이 큰 경우). 이는 NCL이 λ 로 trade-off를 조절한다고 말하는 맥락과 연결됩니다. ¹⁵

또한 “앙상블 전체 목적을 직접 최적화”할 때, 구성원들이 훈련 데이터에서만 통하는 **pseudo-diversity(겉보기 다양성)**를 만들어 일반화가 악화될 수 있다는 분석도 보고됩니다. 이는 “표현/예측 다양성 정규화”를 추가할수록 더 조심해야 함을 시사합니다. ²¹

이미지 포렌식 맥락에서의 멀티스트림·전문가 모델 전략

이미지 포렌식(조작/합성/생성 탐지)은 일반 객체 인식과 달리 **저수준 흔적(노이즈, JPEG/DCT 아티팩트, 경계 불일치, 카메라 지문)**이 핵심 단서가 되는 경우가 많아, “서로 다른 관점(view)”을 가진 스트림/모델을 결합하는 접근이 꾸준히 등장합니다. ²²

멀티스트림(RGB + SRM/노이즈 뷰 등)에서 ‘보완성’이 실증된 사례

- Two-stream 조작 탐지/로컬라이제이션에서 **RGB 스트림 + SRM 기반 노이즈 스트림**을 결합하고 bilinear pooling으로 융합해, “각 스트림 단독보다 결합이 더 좋다”는 실험 결과와 “두 모달리티가 서로 보완적”이라는 주장을 명시합니다. ²³
- 제한된 supervision(약한 지도) 환경에서도 **RGB / SRM noise map / constrained-noise map**의 3-스트림을 두고, 스트림별 예측을 가중 평균해 pseudo GT를 만든 뒤 각 스트림을 다시 그 pseudo GT로 학습시키는 **multi-source consistency**가 제안됩니다. 이 설계는 “각기 다른 입력 소스(view)를 최대한 활용”하고, 앙상블이 단일 스트림의 실패를 교정한다고 기술합니다. ²⁴
- 최신 멀티모달 포렌식 필터 비교/융합 연구는 SRM, constrained conv 계열, NoisePrint 류를 **각각 보조 입력으로 넣는 late/early fusion**을 비교하고, 여러 데이터셋에서 성능 향상을 보고합니다. ²⁵
- “RGB에 과도 의존하지 말라”는 문제의식에서 출발해, RGB와 다양한 noise-view를 다중 브랜치로 균형 있게 융합하는 프레임도 제안되며, 노이즈 뷰가 “미묘한 조작 흔적”에 기여한다고 밝힙니다. ²⁶

요약하면, 포렌식 분야에서는 이미 “**A가 보는 것(RGB/콘텐츠 단서) vs A가 놓치기 쉬운 것(노이즈/잔차/압축 흔적)**”의 분업이 구조적으로 존재합니다. 따라서 질문의 목표(“정확하면서도 A가 못 보는 정보를 보는 B”)는 포렌식 맥락에서 매우 자연스러운 방향이며, 다만 이를 ‘표현 유사도(CKA) 조절’로만 달성할 수 있느냐가 핵심 쟁점입니다. ²⁷

전문가(specialist) vs 일반가(generalist) 관점

“binary specialist”를 이론적으로 다루는 문헌에서는, 동일 정확도라도 **입력공간의 일부에서 매우 높은 확신을 내고 나머지는 거의 랜덤에 가까운** 분포를 갖는 분류기를 specialist로 정의하고, 이런 확신 분포가 앙상블에서의 거동을 크게 바꿀 수 있음을 논의합니다. ²⁸

질문 설정에서 Model A(3-class generalist)와 Model B(binary manipulated specialist)는 애초에 과제 정의가 달라 “전문화”가 가능하지만, B가 A와 표현까지 유사해지면 앙상블 이득이 줄고, 반대로 과도하게 멀어지면 B의 정확도가 떨어질 수 있어 trade-off 관리가 본질입니다. ²⁹

제안 손실의 수학적 정당성과 잠재적 위험

질문에서 제안한 형태는

$$L = L_{\text{focal}}(\text{logits}_B, y) - \lambda \cdot \text{CKA}(f_B, f_A), \quad f_A \text{ frozen}$$

이며, 최적화는 f_B 로만 그래디언트가 흐릅니다.

부호(sign) 해석이 목표와 충돌할 수 있음

- 일반적으로 CKA가 “유사도(similarity)”라면, 위 손실을 “최소화”할 때 $-\lambda \cdot \text{CKA}$ 는 CKA를 키우는 방향 (=A와 더 비슷하게) 작동합니다. 이는 “A가 보지 못하는 정보”를 찾기보다는 **distillation/정렬(alignment)**에 가깝습니다. 실제로 CKA를 학습 손실로 쓴 대표 사례들은 대체로 “teacher-student를 더 비슷하게” 만드는 쪽(예: $1 - \text{CKA}$ 를 최소화)입니다. ³⁰
- 목표가 “A와 다른 관점”이라면, 보통은 $+\lambda \cdot \text{CKA}(f_B, f_A)$ 로 두어 **CKA 유사도를 줄이거나**, $\lambda \cdot (1 - \text{CKA})$ 를 **최대화**하는 식이 더 직관적입니다(구현은 $-\lambda(1 - \text{CKA})$ 추가 등). 다만 CKA는 값의 정의/정규화 방식(선형/커널, centering 포함 여부)에 따라 손실 곡률이 달라지므로 “단순 부호 반전”이 곧바로 안정적인 학습을 보장하지는 않습니다. ³¹

수학적 정당성(왜 CKA를 넣는 게 의미가 있나)

CKA는 XX^T 와 YY^T 의 코사인 유사도로 해석될 수 있어, “개별 샘플의 절대 좌표”가 아니라 **배치 내 샘플 간 관계 구조**를 맞추거나(또는 일부러 다르게) 만들겠다는 목적 함수가 됩니다. ³²

특히 IJCAI 2024는 “CKA 최대화”가 특정 형태의 MMD(분포 거리) 상한과 연결된다는 관점을 제시해, distillation에서 CKA가 작동하는 이유를 이론적으로 설명하려 합니다. ³³

따라서 “A와의 표현 관계를 직접 조절”하는 수단으로 CKA를 넣는 것 자체는 선행연구 기반의 정당성이 있습니다. 문제는 (i) 어떤 층에서, (ii) 어떤 추정 안정성으로, (iii) 어떤 부호/스케줄로 넣어야 “보완성”으로 이어지느냐입니다. ³⁴

잠재적 위험

1) 미니배치 Gram 기반 손실의 불안정

작은 배치에서는 Gram이 관계 구조를 충분히 포착하지 못해 성능이 나빠질 수 있고, 실제로 작은 배치(2~4/GPU)에서 CKA 류 distillation이 실패할 수 있음을 지적한 뒤 patching으로 보완하는 흐름이 존재합니다. ¹³

2) 게임 가능성 / 지표 조작 가능성

CKA가 특정 변환/아웃라이어에 민감하고 값이 “겉보기로 조작될 수 있다”는 신뢰성 분석은, CKA를 “분석 지표”가 아니라 “학습 목표”로 사용할 때 더 치명적일 수 있음을 시사합니다. ¹⁴

3) 정확도-다양성 trade-off 및 pseudo-diversity

NCL처럼 다양성을 직접 조절하는 목적은 본질적으로 trade-off이며, 과도한 다양성 압력은 정확도 하락으로 이어질 수 있습니다. ³⁵

더 나아가, 앙상블 목적/다양성 목적을 직접 최적화할 때 “훈련 데이터에서만 통하는 가짜 다양성(pseudo-diversity)”이 생겨 일반화 격차가 커질 수 있다는 보고도 있어, B가 A를 “회피”하도록 강하게 밀면 비슷한 위험이 생길 수 있습니다. ³⁶

4) 표현 붕괴(의미 없는 표현) 우려

DeCov도 전역 최소가 “가중치 0” 같은 trivial 해가 될 수 있음을 언급하듯, 관계 기반 정규화는 종종 trivial solution 가능성이 있습니다. 다만 질문 설정에서는 L_{focal} 이 강하게 걸려 있으므로 완전 붕괴가 일어나려면 λ 가 과도하게 커져 L_{focal} 을 사실상 무시해야 하는 상황이 많습니다. 그럼에도 λ 가 커질수록 “정확도를 희생하고 유사도 최소화/최대화”를 택하는 경향은 현실적입니다. ³⁷

이를 완화하는 한 가지 원칙은 ‘정보성(라벨 예측력)을 명시적으로 유지’하는 것입니다. HSIC Bottleneck은 표현이 라벨과 충분히 의존하도록 만드는 HSIC 목적을 사용한다는 점에서, “붕괴 방지용 제약(예: 라벨과의 의존성 유지)”이라는 아이디어를 제공할 수 있습니다(단, 그대로 가져다 쓰기는 무겁고 목적이 다릅니다). ³⁸

실용적 구현 권장안

아래 권장안은 “Model A frozen, Model B만 학습”이라는 제약 하에서, **(A와의 보완성) + (B 자체 정확도) + (학습 안정성)**을 동시에 겨냥하는 실무 중심 절충안입니다. 제안은 가능한 한 선행연구에서 관측된 하이퍼파라미터/설계를 기준으로 삼되, 질문의 목표(보완성)가 distillation(유사성 최대화)과 다르다는 점을 반영합니다. 39

CKA 변형 선택

• 기본 권장: 선형 CKA + centering 포함

CKA를 distillation loss로 사용한 대표 구현은 “Gram을 만들고 centering/normalization 후 코사인 유사도” 형태를 취하며, 손실을 $1 - \text{CKA}$ 로 두는 방식이 명시되어 있습니다. 40

- 커널(RBF) CKA는 배치-커널 선택/대역폭 등 추가 요인이 들어가고, HSIC/CKA의 분산-SNR 문제가 커널 선택과 결합되어 더 어려워질 수 있습니다(HSIC 커널 학습/선택의 함정이 연구 주제로 존재). 12

CKA를 측정할 층(어디의 f_A, f_B 인가)

실무적으로는 “너무 이른 층”과 “너무 늦은 층(로짓 직전)” 모두 위험이 있습니다.

- 너무 이르면: 많은 CNN에서 초기 층은 데이터셋/초기화가 달라도 유사해지는 경향이 보고되며, 이 구간에 다양성 압력을 줘도 실질적 보완성이 작거나 오히려 저수준 유용 신호까지 훼손할 수 있습니다. 41
- 너무 늦으면: (특히 detection처럼 배치가 작은 경우) Gram 기반 손실이 불안정하고, FedCKA류 맥락에서는 “깊은 층 정규화가 성능을 해칠 수 있다”는 관찰이 언급됩니다. 42

권장 구조(현실적인 타협)

- 1차 후보: penultimate embedding(예: global average pooled 벡터)

distillation 논문은 average pooling을 distillation 위치로 사용하고, 배치 128에서 안정적으로 Gram 기반 손실을 계산했습니다. 43

- 2차 후보: 중간 feature map에서 ‘축약된 표현’로 CKA

예: (B,C,H,W) → (B,C)로 GAP 또는 채널/공간 평균을 취한 후 CKA. “어떤 차원에서 평균/패치화가 유리한가”를 실험적으로 비교한 KD 연구가 있어, 축약 방식 자체가 중요한 하이퍼파라미터가 될 수 있습니다. 44

질문 목표가 “보완성”이라면, 다층 CKA를 ‘방향성 있게’ 쓰는 설계가 현실적입니다. 예를 들어, - 저수준(초기 블록): 약한 정렬(유사도 유지)

- 고수준(후기 블록/embedding): 약한 분리(유사도 감소)

처럼 “부분 공유 + 부분 전문화”를 의도할 수 있습니다. 이는 NCL이 “상호작용하며 전문화/협동”을 만든다고 설명하는 직관과도 맞닿습니다. 29

미니배치 크기와 추정 안정성

- distillation에서 CKA를 손실로 쓴 설정은 배치 128(또는 분산 학습으로 256)을 사용했습니다. 43
- 반대로 작은 배치(2~4/GPU)에서는 Gram이 “충분한 지식”을 모으지 못해 성능이 떨어질 수 있으며, 이를 패치 기반으로 보완합니다. 13
- HSIC 쪽은 분산이 n 에 따라 감소하는 형태가 명시되어 있어, “배치/표본 수 확대 = 안정성 향상”이 원리적으로 뒷받침됩니다. 12

따라서 경량 모델(모바일) 학습에서도 가능하면 **CKA 계산용 배치(또는 누적 샘플 수)를 키우는 장치**가 유리합니다. 실무적으로는 (i) gradient accumulation으로 “유효 배치”를 늘리거나, (ii) feature를 패치/토큰으로 쪼개 “관계 샘플 수”를 늘리거나, (iii) 메모리 큐(최근 배치의 f_A 를 캐시)로 HSIC/CKA를 추정하는 변형이 후보가 됩니다(단, 분포 drift/모멘텀 업데이트 관리 필요). 45

λ 스케줄링(고정 vs annealing vs adaptive)

- CKA를 정렬(유사도 최대화)하는 distillation 연구에서는 $\lambda_{CKA} = 1$ 같은 고정값 예시가 존재합니다. ⁴³
- 한편 IJCAI 2024는 “초기에는 CE가 학습을 견인하고, 어느 시점부터 CKA(PCKA)가 고차 표현 정렬을 도와 일 반화를 개선한다”는 관찰을 제시합니다. 이는 **warm-up(초기 $\lambda = 0$) 후 점진적 증가**가 안정성에 유리하다는 근거로 쓸 수 있습니다. ⁴⁶
- DeCov 역시 손실 가중치를 튜닝 대상으로 두고(예: 0.1) 안정성을 언급합니다. ⁴⁷

권장 스케줄(보완성 목적에 맞춘 실무안)

- 1단계(초기 10~30% epoch): $\lambda = 0$. B가 우선 “조작 vs 비조작” 결정경계를 잡도록 함. ⁴⁸
- 2단계(중기): λ 를 서서히 증가(코사인 또는 선형).
- 3단계(후기): λ 를 고정 또는 소폭 감소(과도한 다양성으로 정확도 손실 방지).

여기서 중요한 점은 “질문에 제시된 부호”가 정렬인지 분리인지에 따라 λ 해석이 반대로 바뀐다는 것입니다. 즉, - 정렬 목적이면: $L = L_{focal} + \lambda(1 - CKA)$ 또는 질문식처럼 $-\lambda CKA$

- 분리 목적이면: $L = L_{focal} + \lambda CKA$

가 기본 뼈대입니다. ⁴⁹

“표현 붕괴” 방지 체크리스트

1) 분리(유사도 최소화)라면, ‘정보성 유지’ 항을 반드시 확보

- 기본은 L_{focal} 자체가 정보성을 강제하지만, 데이터가 작거나 클래스가 불균형하면 취약할 수 있습니다.
- HSIC Bottleneck은 “표현-라벨 의존성”을 학습 신호로 쓰는 사례로, 붕괴 방지 방향성(라벨과의 연결 유지)에 대한 참고점이 됩니다. ³⁸

2) CKA/HSIC의 아웃라이어 민감성과 ‘게임 가능성’을 방어

- CKA가 특정 변환에 의해 조작 가능하다는 분석은, 학습 중 “CKA만 낮추기/높이기”가 목표가 되지 않게 해야 함을 뜻 합니다. ¹⁴
- 실무적으로는 (i) CKA 계산 전 feature 정규화/클리핑, (ii) robust centering(배치 평균 대신 EMA), (iii) 다층 평균으 로 특정 층에 대한 공격적 최적화를 완화하는 방식이 후보입니다. ⁵⁰

대안 접근법 비교와 포렌식 적용 시나리오

선행연구 요약 표

아래 표는 요청 항목(저자/연도/방법/핵심 발견/포렌식 적용 가능성)을 중심으로 “학습 목적함수로 CKA/HSIC 사용”, “다양성 직접 학습”, “포렌식 멀티스트림/전문화”에 해당하는 핵심 축을 묶어 정리한 것입니다.

저자(연도)	방법(핵심 아이디어)	핵심 발견(요약)	포렌식 적용 가능 성
Simon Kornblith ⁵¹ (2019)	CKA 제안/표현 유사도 지표	CKA의 성질(불변성 등)과 레이어 대응성 분석을 정리. ⁵²	높음(표현 조절 손 실의 기반)
Aninda Saha ⁵³ (2022)	CKA를 distillation loss로 직 접 사용	$L = L_{CE} + \lambda(1 - CKA)$, $\lambda = 1$, 배치 128, avg pooling 층에서 Gram 기반 distillation. ⁴³	중간~높음(실제 구현 레퍼런스)

저자(연도)	방법(핵심 아이디어)	핵심 발견(요약)	포렌식 적용 가능성
Zikai Zhou ⁵⁴ (2024)	CKA 기반 KD를 이론적으로 재해석(RCKA/PCKA)	CKA를 Gram 코사인 유사도로 정리하고 MMD 상한과 연결. 작은 배치에서 Gram 실패 → patch-based로 보완. ⁵⁵	높음(배치/층 선택 실무 단서)
Qin Jin ⁵⁶ (2021)	GCKA로 distillation(특징 유사도 최대화)	teacher-student 특징 유사도를 GCKA로 최대화하는 distillation 흐름 제시. ⁵	중간(정렬 목적에 강함)
Mingjian Ni ⁵⁷ (2023)	CKA-SR: CKA를 학습 손실에 넣어 유사도 감소	CKA 정규화 항을 훈련 손실에 직접 추가해 inter-layer similarity 감소 및 희소성 향상(IB 관점 연결 주장). ⁶	중간(‘유사도 감소’ 설계 참고)
Ha Min Son ⁵⁸ (2021/2022)	FedCKA: CKA 기반 레이어 정규화(연합학습)	어떤 레이어를 정규화할지의 중요성과, 깊은 층 정규화가 해로울 수 있음을 언급. ⁷	중간(층 선택 경고로 유용)
Wan-Duo Kurt Ma ⁵⁹ (2019/2020)	HSIC Bottleneck	HSIC 기반 학습으로 backprop 대안을 제시하고, 깊은 네트워크 학습의 안정성 문제를 논의. ⁶⁰	간접(붕괴 방지/정보성 제약 아이디어)
Daniel Greenfeld ⁶¹ (2020)	HSIC-loss로 강건 학습	HSIC를 손실함수로 사용해 “잔차-입력 독립”을 유도하는 강건 학습을 제안. ⁹	중간(도메인 이동/강건성에 힌트)
Zifeng Wang ⁶² (2023)	DualHSIC(continual learning)	HSIC Bottleneck + alignment로 간섭 억제/공유 촉진을 결합. ¹⁰	간접(정규화 조합 설계 참고)
Arthur Gretton ⁶³ (2008)	HSIC 정의/추정량(U/V)	HSIC의 모수, unbiased/biased 추정량과 $\text{tr}(KHLH)$ 형태 정리. ²	높음(미니배치 HSIC/CKA 추정 이해)
Bo Ren ⁶⁴ (2024)	HSIC 추정 분산/스케일 분석	HSIC(u/b) 분산 전개와 계산비용 $O(n^2)$ 등, SNR/분산 문제를 구체화. ⁶⁵	높음(미니배치 분산 문제의 근거)
Yong Liu ⁶⁶ & Xin Yao ⁶⁷ (1999)	Negative Correlation Learning	상관 패널티로 동시 학습-결합, λ 로 trade-off 제어 및 전문화/협동 유도. ¹⁵	높음(“보완성 학습”의 원형)
Michael Cogswell ⁶⁸ (2015/2016)	DeCov(활성 공분산 최소화)	공분산(대각 제외) 최소화로 co-adaptation/과적합 완화, 가중치 튜닝(예: 0.1) 언급. ¹⁷	중간(표현 다양성의 단순·안정 대안)
Pau Rodríguez ⁶⁹ (2017)	OrthoReg(국소 직교성)	decorrelation 간섭을 줄이기 위해 국소적 특징 직교성 강제. ¹⁸	중간(Gram/직교 제약 대안)
Ohad Shamir ⁷⁰ (2020)	Anti-Distillation	모델 출력을 서로 밀어내는(디코릴레이션 등) 손실로 앙상블 다양성 강화. ¹⁹	높음(“A와 다른 B” 목표와 정합)

저자(연도)	방법(핵심 아이디어)	핵심 발견(요약)	포렌식 적용 가능성
Changjian Shui ⁷¹ (2018)	Deep ensembles diversity regularization	다양성 정규화로 캘리브레이션 개선을 노리며, 정확도는 유사하게 유지 가능성 보고. ⁷²	중간(불확실성/캘리브레이션 중요시)
Leonardo de Mathelin ⁷³ (2023)	(주의 사례) joint objective의 퇴행 가능성	앙상블을 함께 최적화할 때 가짜 다양성이 생기고 일반화가 악화될 수 있음을 보고. ²¹	높음(정규화 과도시 경고)
Belhassen Bayar ⁷⁴ (2016)	constrained conv layer로 universal manipulation detection	고정 필터 대신 학습 가능한 “제약 합성곱”으로 콘텐츠를 억제하고 조작 흔적을 학습. ⁷⁵	높음(B를 “다른 관점”으로 만드는 설계 근거)
Peng Zhou ⁷⁶ (2018)	RGB+SRM two-stream 조작 탐지	RGB/노이즈 스트림이 보완적이며 결합이 단독보다 우수하다고 명시. ⁷⁷	매우 높음(포렌식 보완성의 정석 사례)
Yue Zhai ⁷⁸ (2023)	3-stream + multi-source consistency	RGB/SRM/노이즈맵 각 스트림 예측을 앙상블로 묶어 pseudo GT로 재학습, 과적합 완화 및 견고성 주장. ²⁴	매우 높음(“서로 다른 관점” 설계 직접적)
Konstantinos Triaridis ⁷⁹ (2024)	여러 포렌식 필터 비교·융합	SRM/NoisePrint/제약 필터를 보조 입력으로 early/late fusion 비교 및 성능 향상 보고. ²⁵	매우 높음(보완성 측정/설계에 직접적)
Joonkyo Shim ⁸⁰ (2026)	Multi-noise-view fusion	RGB 중심 한계를 지적하고 노이즈 뷰 융합으로 미묘한 흔적 탐지 성능 향상 보고. ²⁶	매우 높음(실전 포렌식 설계 방향)
Marina Davari ⁸¹ (2023)	CKA 신뢰성 분석	CKA 값이 단순 변환/아웃라이어 등에 의해 조작 가능함을 분석. ¹⁴	높음(CKA를 학습 목표로 둘 때 핵심 리스크)
Ronan Meyen ⁸² (2021)	specialist vs generalist 이론	동일 정확도라도 확신 분포가 앙상블에서 중요하며 specialist/generalist를 정의·분석. ²⁸	중간(“binary specialist” 설계 해석에 도움)

방법 비교: 질문의 대안들과의 트레이드오프

요청한 대안들을 (a) 이론적 근거, (b) 구현 복잡도, (c) 포렌식 적용 가능성 관점에서 비교하면 다음과 같습니다.

접근	(a) 이론/직관적 근거	(b) 구현 복잡도	(c) 포렌식 적용 가능성
CKA regularization(제한 계열)	배치 내 관계 구조(Gram) 유사도/차이를 직접 최적화. KD에서는 MMD 상한 관점 등 정당화 시도. 단, 조작 가능성/작은 배치 불안정 위험. ⁸³	중간~높음 (Gram/센터링/메모리, 레이어 혹은 필요)	높음(포렌식은 “관점 분리”가 유리하나 안정성 설계가 관건) ⁸⁴

접근	(a) 이론/직관적 근거	(b) 구현 복잡도	(c) 포렌식 적용 가능성
Gradient diversity(gradient 방향 다양성)	공격 전이성/양상불 상호전이를 줄이기 위해 그래디언트 직교 + 매끄러움이 필요하다는 이론/경험. ⁸⁵	높음(입력 그래디언트 계산/정규화, 추가 최적화 포함)	중간(포렌식은 적대적 환경이 강하므로 의미 있으나 비용 ↑)
Error-guided sampling(어려 샘플 가중/하드 마이닝)	어려운 샘플이 학습을 지배하도록 샘플링/가중을 조절해 성능 개선(OHEM, Focal loss 등). ⁸⁶	낮음~중간(loss reweight, 샘플 선택)	높음(조작 탐지의 hard case(미묘한 조작/후처리)에 직접 대응 가능)
Adversarial complementarity(적대적 보완성)	새 모델이 기존 모델이 이미 학습한 지식을 “회피”하도록 적대적 프레임으로 보완 표현을 학습(ACoRL). ⁸⁷	높음(보조 판별/회피 목적 구성, 안정화 필요)	중간~높음(“A가 놓친 흔적”을 강제로 찾게 만들 수 있으나 튜닝 난이도 큼)
Prediction disagreement maximization	두 모델이 다른 예측을 내는 샘플에 집중하거나, 불일치를 유지해 다양성을 확보(Co-teaching+의 disagreement update 등). ⁸⁸	중간(두 모델 동시 운영, 필터링 로직)	중간(라벨 노이즈/경계 근처 샘플에서 유리; 포렌식의 OOD/후처리에도 유사 구조 가능)
Feature orthogonality constraint(Gram=I 등)	특징/가중치 Gram을 항등에 가깝게 하여 중복을 줄이고 안정성을 높임(OrthoReg/직교 정규화). ⁸⁹	중간(행렬 연산/정규화)	중간(포렌식에서 “노이즈 흔적”을 살리되 중복을 줄이는 보조 정규화로 유효)

포렌식 도메인에서 “특히 유효한/부적합한” 시나리오

유효할 가능성이 큰 경우

- 조작 흔적이 **콘텐츠와 독립적(노이즈/압축/잔차)**인 경우가 많고, RGB 중심 모델이 이를 놓치기 쉬운 환경: 멀티 노이즈 뷰/노이즈 스트림 융합이 효과적이라는 보고들이 이를 뒷받침합니다. ⁹⁰
- 데이터셋이 다양한 조작 유형/후처리를 포함해 “하나의 관점으로는 일반화가 어려운” 경우: multi-source consistency나 다중 포렌식 필터 비교·융합 연구는 서로 다른 뷰가 견고성에 기여함을 보여줍니다. ⁹¹
- Model B를 **입력 관점 자체를 바꾸는** 설계(예: RGB→노이즈 뷰로 변환, constrained conv 전처리)를 병행할 수 있는 경우: 이때 CKA는 “같은 입력에서 다른 특징을 보게 하는” 보조 규제로 더 설득력 있게 작동합니다. ⁹²

부적합/위험이 커지는 경우

- 배치가 작고(혹은 클래스 불균형이 심해) Gram 기반 추정이 불안정한 경우: 작은 배치에서 Gram이 충분한 정보를 못 담는다는 지적이 있으며, 포렌식 현업(고해상도/메모리 제약)에서 자주 발생합니다. ⁹³
- CKA 최소화(분리)를 강하게 걸어 “A를 회피”시키면, 훈련 데이터에서만 통하는 pseudo-diversity나 지표 게임이 발생할 가능성: CKA의 조작성 분석 및 joint objective 퇴행 사례는 경고 신호입니다. ⁹⁴
- 실제로는 “A가 놓친 정보”가 표현 차이보다 **데이터/샘플링(하드 케이스)** 문제인 경우: 이때는 CKA보다 hard example mining(OHEM)이나 focal loss 계열이 비용 대비 효과가 더 직접적일 수 있습니다. ⁸⁶

¹ ⁴¹ ⁵² ⁶⁸ <https://proceedings.mlr.press/v97/kornblith19a/kornblith19a.pdf>

<https://proceedings.mlr.press/v97/kornblith19a/kornblith19a.pdf>

² ¹¹ ⁶⁷ <https://proceedings.neurips.cc/paper/3201-a-kernel-statistical-test-of-independence.pdf>

<https://proceedings.neurips.cc/paper/3201-a-kernel-statistical-test-of-independence.pdf>

- 3 4 30 31 39 40 43 49 71 81 <https://bmvc2022.mpi-inf.mpg.de/0535.pdf>
<https://bmvc2022.mpi-inf.mpg.de/0535.pdf>
- 5 https://openaccess.thecvf.com/content/CVPR2021/html/Jin_Teachers_Do_More_Than_Teach_Compressing_Image-to-Image_Models_CVPR_2021_paper.html
https://openaccess.thecvf.com/content/CVPR2021/html/Jin_Teachers_Do_More_Than_Teach_Compressing_Image-to-Image_Models_CVPR_2021_paper.html
- 6 63 <https://arxiv.org/pdf/2307.07389>
<https://arxiv.org/pdf/2307.07389>
- 7 <https://arxiv.org/abs/2112.00407>
<https://arxiv.org/abs/2112.00407>
- 8 38 60 82 <https://arxiv.org/pdf/1908.01580>
<https://arxiv.org/pdf/1908.01580>
- 9 <https://proceedings.mlr.press/v119/greenfeld20a/greenfeld20a.pdf>
<https://proceedings.mlr.press/v119/greenfeld20a/greenfeld20a.pdf>
- 10 54 <https://github.com/zhanzheng8585/DualHSIC>
<https://github.com/zhanzheng8585/DualHSIC>
- 12 53 65 <https://proceedings.mlr.press/v238/ren24a/ren24a.pdf>
<https://proceedings.mlr.press/v238/ren24a/ren24a.pdf>
- 13 32 33 34 42 44 45 46 48 51 55 59 61 66 76 80 83 93 <https://www.ijcai.org/proceedings/2024/0628.pdf>
<https://www.ijcai.org/proceedings/2024/0628.pdf>
- 14 50 56 62 94 <https://openreview.net/pdf?id=8HRvyc606>
<https://openreview.net/pdf?id=8HRvyc606>
- 15 29 35 69 70 <https://www.sciencedirect.com/science/article/abs/pii/S0893608099000738>
<https://www.sciencedirect.com/science/article/abs/pii/S0893608099000738>
- 16 <https://www.jmlr.org/papers/volume24/23-0041/23-0041.pdf>
<https://www.jmlr.org/papers/volume24/23-0041/23-0041.pdf>
- 17 37 47 79 https://mlp.cc.gatech.edu/papers/2016/cagzb_iclr16/cagzb_iclr16.pdf
https://mlp.cc.gatech.edu/papers/2016/cagzb_iclr16/cagzb_iclr16.pdf
- 18 73 89 <https://openreview.net/pdf?id=ByOvslqeg>
<https://openreview.net/pdf?id=ByOvslqeg>
- 19 openreview.net
<https://openreview.net/pdf?id=okT7QRhSYBw>
- 20 72 74 <https://arxiv.org/pdf/1802.07881>
<https://arxiv.org/pdf/1802.07881>
- 21 36 58 [NeurIPS Poster Joint Training of Deep Ensembles Fails Due to Learner Collusion](https://neurips.cc/virtual/2023/poster/71391)
<https://neurips.cc/virtual/2023/poster/71391>
- 22 <https://pmc.ncbi.nlm.nih.gov/articles/PMC8321383/>
<https://pmc.ncbi.nlm.nih.gov/articles/PMC8321383/>

- 23 27 77 https://openaccess.thecvf.com/content_cvpr_2018/papers/Zhou_Learning_Rich_Features_CVPR_2018_paper.pdf
https://openaccess.thecvf.com/content_cvpr_2018/papers/Zhou_Learning_Rich_Features_CVPR_2018_paper.pdf
- 24 57 78 91 https://openaccess.thecvf.com/content/ICCV2023/papers/Zhai_Towards_Generic_Image_Manipulation_Detection_with_Weakly-Supervised_Self-Consistency_Learning_ICCV_2023_paper.pdf
https://openaccess.thecvf.com/content/ICCV2023/papers/Zhai_Towards_Generic_Image_Manipulation_Detection_with_Weakly-Supervised_Self-Consistency_Learning_ICCV_2023_paper.pdf
- 25 https://kostino.github.io/papers/MMM2024_forensics.pdf
https://kostino.github.io/papers/MMM2024_forensics.pdf
- 26 64 84 90 <https://yscholarhub.yonsei.ac.kr/bitstream/2021.sw.yonsei/26020/2/1-s2.0-S0925231225025871-main.pdf>
<https://yscholarhub.yonsei.ac.kr/bitstream/2021.sw.yonsei/26020/2/1-s2.0-S0925231225025871-main.pdf>
- 28 <https://arxiv.org/pdf/2107.04381>
<https://arxiv.org/pdf/2107.04381>
- 75 92 https://misl.ece.drexel.edu/wp-content/uploads/2017/07/Bayar_IHMMSec_2016.pdf
https://misl.ece.drexel.edu/wp-content/uploads/2017/07/Bayar_IHMMSec_2016.pdf
- 85 <https://proceedings.neurips.cc/paper/2021/file/937936029af671cf479fa893db91cbdd-Paper.pdf>
<https://proceedings.neurips.cc/paper/2021/file/937936029af671cf479fa893db91cbdd-Paper.pdf>
- 86 https://openaccess.thecvf.com/content_cvpr_2016/papers/Shrivastava_Training_Region-Based_Object_CVPR_2016_paper.pdf
https://openaccess.thecvf.com/content_cvpr_2016/papers/Shrivastava_Training_Region-Based_Object_CVPR_2016_paper.pdf
- 87 [Efficient Multi-Model Fusion with Adversarial Complementary Representation Learning](https://arxiv.org/html/2404.15704v1)
<https://arxiv.org/html/2404.15704v1>
- 88 <https://proceedings.mlr.press/v97/you19b/you19b.pdf>
<https://proceedings.mlr.press/v97/you19b/you19b.pdf>