

온디바이스·엣지 배치형 이미지 포렌식 연구 동향 2022-2026

핵심 요약

라즈베리 파이급 엣지 장치에서 **이미지 조작 탐지/로컬라이제이션(위조 영역 분할)**과 **AI 생성 이미지 탐지(AIGC/딥페이크)**를 “논문에서 직접” 엣지 하드웨어로 구동·보고한 사례는 많지 않지만, **명시적으로 Edge TPU 배치를 목표로 설계/측정한 포렌식 모델**이 등장했고(예: SAPN), AI 생성 탐지에서는 **초소형(수층 Conv)** 또는 **이진 신경망(BNN)** 같은 “엣지 지향” 효율화가 빠르게 진행 중입니다. ¹

또한 2025-2026에는 포렌식 “단일 RGB” 중심에서 벗어나 **노이즈-뷰/다중 뷰 융합**(여러 종류의 포렌식 단서를 하나의 네트워크에서 흡수)과 **선형 복잡도 계열 백본(SSM/Mamba 계열)**을 활용해 **F1-연산량 트레이드오프를 정면으로 다루**는 흐름이 분명해졌습니다(예: ForMa, MNVFusion). ²

벤치마크 측면에서는, AI 생성 이미지 탐지의 경우 **교차-생성기 일반화**와 **열화(압축/리사이즈/스크린샷/재업로드 등) 견고성**을 정량화하는 대형 벤치마크가 2023-2026에 연속적으로 제안되었고(GenImage, SIDBench, ImagiNet, AI-GenBench, RRDataset 등), “실사용 SNS 유통물” 기반 평가(예: WildRF)도 강화되는 추세입니다. ³

엣지 배치 관점의 공통 결론은, **여러 모델을 모두 항상 실행하는 구조(현재 MAIFS)**는 비용이 급증하기 쉽기 때문에, (i) **캐스케이드/조건부 실행**, (ii) **조기 종료(early exit)**, (iii) **양상물→단일 학생 모델 종류(distillation)** 같은 시스템적 전략이 사실상 필수에 가깝다는 점입니다. 이는 비포렌식 영역(비디오 분석/엣지 추론 시스템)에서 이미 검증된 패턴이며, 포렌식에도 그대로 이식 가능합니다. ⁴

온디바이스 이미지 포렌식 시스템 사례

라즈베리 파이 5는 2.4GHz 쿼드코어 Cortex-A76 및 LPDDR4X 메모리 구성을 제공하며(8-16GB 옵션), 여기에 Hailo-8L 같은 PCIe 기반 NPU(13 TOPS, typical 1.5W)가 결합될 수 있습니다. ⁵

B. S. Gangarapu ⁶ et al. — SAPN Edge TPU 배치형 위조 탐지/로컬라이제이션

서지: B. S. Gangarapu ⁶ et al. “Lightweight spatial attention pyramid network-based image forgery detection optimized for real-time edge TPU deployment.” (저널/연도: ScienceDirect 기사 페이지 기준 2025로 표기). ⁷

방법 요약: 피라미드 특징 추출과 공간 어텐션으로 조작 가능성이 높은 영역을 선택적으로 강화해 위조 탐지 성능과 효율을 함께 높입니다. “경량 아키텍처”를 전제로 엣지 가속기 배치를 논문 결론의 핵심으로 둡니다. ⁷

보고 지표: CASIA V1에서 정확도 94%, AUC 0.99를 보고하며, 파라미터 수 0.57M(=57만)로 매우 작다고 명시합니다. Edge TPU에서 평균 추론 지연이 이미지당 1.17초라고 보고합니다(즉, “실시간”이라기보다 “엣지에서 동작 가능한 near-real-time”에 가까운 수치로 읽히는 부분). ⁷

우리 작업과의 관련성: “엣지 배치(Edge TPU) + 모델 크기/지연 보고”를 명시적으로 수행한 드문 포렌식 사례입니다. MAIFS의 공간/노이즈/주파수 단서를 “하나의 경량 네트워크로 흡수”하는 방향의 비교 기준(상한/하한)을 제공할 수 있습니다. ⁷

José María Rodríguez Corral ⁸ et al. — 엣지 TPU vs 임베디드 GPU에서 “2-모델 파이프라인”의 시간·에너지 측정

서지: José María Rodríguez Corral ⁸ et al. “Energy efficiency in edge TPU vs. embedded GPU for computer-aided medical imaging segmentation and classification.” Engineering Applications of Artificial Intelligence, 2024. ⁹

방법 요약: (의료 영상이지만) **세그멘테이션(U-Net 계열) + 분류(MobileNetV2 계열)**의 2단계 파이프라인을 임베디드 보드에서 실행하며, 시간과 에너지(이미지당 mJ)를 체계적으로 측정합니다. ⁹

보고 지표: Edge TPU에서 세그멘테이션 추론 시간은 이미지당 29ms 미만, GPU(Maxwell)에서는 43ms 미만으로 보고합니다. 분류 서브시스템은 Edge TPU <10ms, GPU <14ms. 에너지 측면에서는 OD 세그멘테이션 기준 Edge TPU 38mJ/이미지, GPU 190mJ/이미지 등 구체 수치를 제시합니다. ⁹

우리 작업과의 관련성: 포렌식이 아닌 도메인이지만, “여러 모델을 연쇄 실행”하는 구조(현재 MAIFS와 유사한 비용 구조)가 엣지에서도 가능함을 **자연·에너지 단위로 계량한** 참고점입니다. MAIFS에서도 DAAC 앞단을 ‘저비용→고비용’ 캐스케이드로 재구성할 때 동일한 측정 프레임워크를 그대로 적용할 수 있습니다. ⁹

Bar Cavia ¹⁰ et al. — LaDeDa / Tiny-LaDeDa: 패치 기반 딥페이크 탐지 & 초소형 종류

서지: Bar Cavia ¹⁰ et al. “Real-Time Deepfake Detection in the Real-World (LaDeDa).” arXiv, 2024. ¹¹

방법 요약: 이미지를 패치로 분할해 **패치 단위 딥페이크 점수**를 예측하고, 이를 풀링해 이미지 레벨 점수를 산출합니다. 핵심은 “패치 레벨 단서만으로도” 높은 성능이 가능하다는 가설을 바탕으로, 교사(LaDeDa)→학생(Tiny-LaDeDa)로 **극단적 경량화 종류**를 수행한 점입니다. ¹²

보고 지표: 표준(시뮬레이션) 프로토콜에서 LaDeDa가 98.9 mAP로 보고됩니다(표 1). Tiny-LaDeDa는 4개 합성곱 층으로 구성되며, LaDeDa 대비 FLOPs가 375배 적고 파라미터 효율이 10,000배 높다고 주장합니다. 또한 “실세계” 평가를 위해 WildRF 데이터를 구축하고, 그 위에서 93.7% mAP를 보고합니다. ¹¹

우리 작업과의 관련성: (1) “엣지에서도 돌릴 수 있는 수준”의 초소형 학생 모델 설계, (2) **데이터 유통(소셜/재압축) 기반 현실 벤치마크(WildRF)** 제안, (3) ‘패치→풀링’ 구조는 MAIFS에서 **저비용 1차 스크리닝 에이전트**로 매우 적합한 형태입니다. ¹²

Romeo Lanzino ¹³ et al. — 이진 신경망(BNN) 기반 “실시간” 딥페이크 탐지

서지: Romeo Lanzino ¹³ et al. “Faster Than Lies: Real-time Deepfake Detection using Binary Neural Networks.” CVPRW 2024 (DFAD 워크숍), 2024. ¹⁴

방법 요약: 가중치/활성의 이진화를 통해 연산을 크게 줄이는 BNN을 딥페이크 이미지 탐지에 적용합니다. 입력 보조 채널로 FFT magnitude 및 LBP를 추가해 주파수/텍스처 단서를 결합합니다. ¹⁵

보고 지표: COCOFake 검증에서 BNext-S가 정확도 99.28%, AUC 99.89%로 보고되며, 이때 파라미터 67.1M, FLOPs 1.91G를 제시합니다(테이블에 여러 크기 변형 포함). 또한 “최대 20× FLOPs 감소”를 강조합니다. 다만 논문 자체는 FLOPs 중심이며, 특정 엣지 하드웨어의 ms 지연을 직접 보고하지는 않습니다. ¹⁶

우리 작업과의 관련성: FatFormer/CLIP 계열처럼 큰 임베딩 모델이 부담될 때, “작은 CNN/BNN + 주파수 보조 채널” 조합은 **CPU-only 또는 NPU-friendly** 후보가 될 수 있습니다. 특히 DAAC의 “불일치/불확실성” 신호를 만들기 위한 **초저지연 에이전트**로 적합합니다. ¹⁶

Xiaohong Liu ¹⁷ et al. — PSCC-Net: 경량 백본 기반 조작 탐지/로컬라이제이션 (고해상도 처리 주장)

서지: Xiaohong Liu ¹⁷ et al. “PSCC-Net: Progressive Spatio-Channel Correlation Network for Image Manipulation Detection and Localization.” (저자 코멘트에 따르면 IEEE TCSVT 게재), arXiv v2 2022. ¹⁸

방법 요약: top-down(특징 추출) + bottom-up(마스크 점진 추정) 경로의 2-path 구조와, 공간·채널 상관 모듈(SCCM)로 다양한 조작 유형에 대응하는 것을 목표로 합니다. ¹⁸

보고 지표: “light-weight backbone and progressive mechanism” 덕분에 1080p 이미지를 50+ FPS로 처리 가능하다고 주장합니다(하드웨어 명시 없음). ¹⁸

우리 작업과의 관련성: MVSS-Net류의 “다중 스케일/다중 힌트” 접근을 유지하면서도 고해상도 처리 효율을 강하게 주장하는 계열입니다. 단, 엣지 보드 실측(ms, W, mJ) 보고가 아니라는 한계가 있어, RPi5/Hailo 타킷에선 별도 재현 벤치마킹이 필요합니다. ¹⁸

하드웨어 관점 근접 사례 — RPi5 + Hailo ¹⁹ -8L, 엣지 NPU 기반 실시간 추론

서지: G. Bueno ²⁰ et al. “Real-Time Edge Computing vs. GPU-Accelerated ...” Electronics, 2025. (RPi5 + Hailo-8L로 YOLOv8 실시간 추론을 비교). ²¹

방법 요약: 현미경 영상 분석에서 RPi5 + Hailo-8L로 실시간 추론을 수행하는 구성과, RPi4에서 캡처 후 데스크톱 GPU로 보내는 구성을 비교합니다. 포렌식 모델은 아니지만 “RPi급 + Hailo NPU”의 실시간 처리 가능성을 보여주는 시스템 레퍼런스입니다. ²¹

보고 지표: 해당 논문 요약 페이지는 “RPi5 + Hailo-8L로 실시간 추론 가능” 및 비교 설정을 명시합니다(정확한 지연/전력 수치는 원문 표/실험 섹션 확인 필요). ²¹

우리 작업과의 관련성: MAIFS 목표(<1초)에서 가장 큰 미지수는 “모델 연산” 뿐 아니라 런타임(전처리·I/O·스케줄링·멀티모델)입니다. 이런 시스템 논문에서 쓰는 비교 프레임(엣지 vs 오프로딩)을 MAIFS에도 적용해, “로컬 우선 + 불확실 시 오프로딩” 같은 하이브리드 구성을 검토할 근거가 됩니다. ²¹

경량 이미지 포렌식 모델 후보

아래는 질문에서 지정한 4개 백엔드(주파수/노이즈/CLIP/공간)에 대응하도록, 2022-2026 사이의 “경량화에 유리한 설계”를 가진 방법들을 정리한 것입니다. (저자 표기는 길이/표준 관행을 고려해 대표 저자 중심으로 축약 표기했습니다.)

JPEG/압축 아티팩트 기반 대안

Myung-Joon Kwon ²² et al. — CAT-Net (Compression Artifact Tracing)

서지: Myung-Joon Kwon ²² et al. “Learning JPEG Compression Artifacts for Image Manipulation Detection and Localization.” IJCV 2022 (arXiv:2108.12947는 선행 공개). ²³

방법 요약: JPEG의 DCT/압축 아티팩트를 학습 가능 표현으로 만들고, 이를 조작 로컬라이제이션에 활용합니다. CAT-Net v2는 v1(WACV 2021)을 확장해 일반 조작으로 넓혔다고 프로젝트 문서에서도 구분합니다. ²⁴

보고 지표: 본 항목은 사용자가 이미 채택 중인 계열로, 여기서는 “압축-단서 기반 접근의 표준 레퍼런스”로만 위치시킵니다(경량화 수치-엣지 ms 지연은 해당 오픈 소스/가중치 기준 별도 측정이 필요). 23

우리 작업과의 관련성: MAIFS의 Frequency/CAT-Net 에이전트가 목표로 하는 “압축 단서 기반”의 대표 계열이며, 이후 대안(아래 CA-IFL, 문서 포렌식 분기)들과 비교축을 제공합니다. 23

Menglu Wang 25 et al. — JPEG Compression-aware Image Forgery Localization (CA-IFL)

서지: Menglu Wang 25 et al. “JPEG Compression-aware Image Forgery Localization.” ACM Multimedia 2022. 26

방법 요약: (1) 웨이블릿 기반 압축 표현을 대조학습으로 학습(CRL-Net), (2) 이를 로컬라이제이션 네트워크(CA-IFL)의 압축-인지 분기 및 경계 보정 분기에 주입해 “JPEG 압축 하의 조작 로컬라이제이션 저하”를 줄입니다. 27

보고 지표: Ablation에서 설정별 F1(예: “Ours” 세팅 F1 0.469)을 제시하고, JPEG 품질(QF 50–100) 변화에 따른 F1 강건성 곡선도 제공합니다. 다만 파라미터/지연/엣지 하드웨어 실측은 본 PDF에서 핵심 지표로 보고되지 않습니다. 28

우리 작업과의 관련성: CAT-Net 대체라기보다, “JPEG/재압축 강건성”을 명시적으로 목적 함수/구조에 포함한 점이 중요합니다. MAIFS에서 “재업로드/재압축”을 별도 클래스로 다루거나, DAAC 메타피처에 “압축 민감도”를 넣는 설계에 직접적 근거가 됩니다. 29

노이즈 기반 조작 탐지/로컬라이제이션 대안

Kun Guo 30 et al. — ForMa (Vision Mamba 기반 경량 로컬라이제이션)

서지: Kun Guo 30 et al. “A Lightweight and Effective Image Tampering Localization Network with Vision Mamba (ForMa).” arXiv v1, 2025. 31

방법 요약: 백본으로 VMamba(SSM/Mamba 계열)를 사용해 전역 의존성을 선형 복잡도로 모델링하고, 디코더는 픽셀 셔플 기반 업샘플링(파라미터-프리)과 선형층 위주로 경량화합니다. 추가로 SRM/Noiseprint++/BayarConv 계열 노이즈 특징을 “디코더 보조 신호”로 주입하는 noise-assisted decoding을 제안합니다. 31

보고 지표: 512×512 입력 기준 평균 F1 64.1%와 함께, FLOPs 42G, 파라미터 37M을 명시합니다. 또한 CAT-Net 대비 FLOPs가 134G→231G(TruFor) 같은 비교 맥락을 제시하며, 여러 데이터셋에서 F1/IoU를 표로 보고합니다. 31

우리 작업과의 관련성: MVSS-Net(노이즈/다중뷰) 계열의 “노이즈 단서”를 유지하면서도, 단일 백본 내부에 다중 노이즈 뷰를 통합하는 방향입니다. MAIFS에서 “노이즈 에이전트 + 공간 에이전트”를 별도 모델로 돌리는 대신, ForMa류로 2개 에이전트를 하나로 축약할 수 있는 연구 근거로 유용합니다. 31

Joonkyo Shim 32 et al. — MNVFusion (Multi-Noise-View Fusion + 고정 연산 기반 검출)

서지: Joonkyo Shim 32 et al. “Do not overestimate RGB: Improving image manipulation detection and localization via multi-noise-view fusion.” Neurocomputing, 2026. 33

방법 요약: RGB 중심 접근의 한계를 지적하며, 다양한 노이즈-뷰(고역통과/지문 등)를 생성해 멀티브랜치 인코더로 통합합니다. MB-CMM(단순 MLP 기반 채널 믹싱)으로 효율적 융합을 수행하고, 로컬라이제이션 맵 위에 고정 연산(Fixed GeM)으로 이미지 레벨 검출을 추가해 효율을 높입니다. 33

보고 지표: 6개 벤치마크에서 탐지·로컬라이제이션 SOTA를 주장하지만, 해당 공개 PDF 첫 부분(초록/하이라이트)만으로는 파라미터·ms 지연·하드웨어 실측 수치가 핵심 지표로 제시되진 않습니다. ³³

우리 작업과의 관련성: MAIFS의 “노이즈 모델 + 공간 모델”을 분리해 유지할 경우, DAAC 메타피처는 풍부해지지만 실행 비용이 커집니다. MNVFusion은 “다중 단서”를 하나의 네트워크로 접어넣는 설계이므로, **에이전트 수를 줄이면서도 다양한 포렌식 단서 보존**이라는 목표에 직접 연결됩니다. ³³

Noise-aware Cross Attention for IML (NC-Net) — 노이즈 추출기 게이팅 + DWT 결합

서지: H. Zhang et al. “Noise-aware cross attention for image manipulation localization.” Pattern Recognition, 2026. ³⁴

방법 요약: BayarConv와 DWT 기반 노이즈 특징을 게이트로 혼합하는 “Gated Noise Extractor”를 두고, 노이즈-도메인과 RGB-도메인을 cross-attention 및 FPN 방식으로 융합합니다. “낮은 파라미터/연산량의 경량 설계”를 주장합니다. ³⁴

보고 지표: 공개된 요약 정보만으로는 구체 파라미터 수·지연·하드웨어가 확인되지 않습니다(원문 표 필요). ³⁴

우리 작업과의 관련성: MVSS-Net 계열 대체로 고려할 때, “여러 노이즈 추출 전략을 게이팅으로 선택/혼합”하는 아이디어는 DAAC의 “불일치 인지”와 구조적으로 궁합이 좋습니다(DAAC가 어떤 노이즈-뷰가 유효한지 조건부로 선택하는 정책 학습과 연결). ³⁴

CLIP/대규모 임베딩 기반 AI-생성 이미지 탐지의 경량화 축

Utkarsh Ojha ³⁵ et al. — “CLIP 피쳐 공간” 기반 범용 생성 이미지 탐지(UniversalFakeDetect)

서지: Utkarsh Ojha ³⁵ et al. “Towards Universal Fake Image Detectors that Generalize Across Generative Models.” CVPR 2023. ³⁶

방법 요약: “real-vs-fake 분류기를 새로 학습”하는 패러다임이 새로운 생성기 계열(예: GAN→Diffusion)로의 일반화에 취약함을 보이고, 대신 대형 비전-언어 모델의 피쳐 공간(예: CLIP)에서 **nearest neighbor / linear probing** 같은 간단한 분류기를 쓰면 의외로 일반화가 잘 된다는 관찰을 제시합니다. ³⁶

보고 지표: 예시로 “unseen diffusion/autoregressive에서 기존 SOTA 대비 +15.07 mAP, +25.90% acc” 같은 개선 폭을 초록에서 제시합니다. 다만 엡지 하드웨어 지연/메모리 보고는 목적이 아니며, 실제 비용은 “어떤 CLIP 백본을 쓰느냐”가 대부분을 결정합니다. ³⁶

우리 작업과의 관련성: 현재 MAIFS의 FatFormer/CLIP-ViT-L/14 에이전트가 하는 역할(범용성/개념적 단서)을 “간단한 헤드 + 임베딩 공간”으로 재정의할 수 있게 해줍니다. 즉, **CLIP 자체를 경량화(아래 MobileCLIP 등) + 헤드는 극소형으로 유지하는 구성**이 직접적으로 연결됩니다. ³⁶

Pavan Kumar Anasosalu Vasu ³⁷ et al. — MobileCLIP: 모바일 지향 CLIP 패밀리

서지: Pavan Kumar Anasosalu Vasu ³⁷ et al. “MobileCLIP: Fast Image-Text Models through Multi-Modal Reinforced Training.” CVPR 2024. (소속: Apple ³⁸) ³⁹

방법 요약: 모바일 배치의 병목(메모리/지연)을 전제로, 하이브리드 CNN-Transformer와 구조적 reparameterization 등을 통해 “모바일 친화 CLIP”을 설계합니다. 또한 강한 CLIP 양상블·캡처닝 모델 지식을 “강화 데이터셋”에 저장해, 학습 시 추가 비용 없이 지식 전달을 수행하는 multi-modal reinforced training을 제안합니다. ³⁹

보고 지표: MobileCLIP-S0가 표준 ViT-B/16 CLIP 대비 약 5× 빠르고 3× 작다고 보고하며, 지연은 iPhone 12 Pro Max에서 측정했다고 명시합니다. MobileCLIP-S2는 “이전 best ViT-B/16 기반 모델 대비 2.3× faster & 더 정확”하다고도 보고합니다. ³⁹

우리 작업과의 관련성: FatFormer(대형 CLIP) 계열을 엣지에서 유지하려면 “임베딩 모델 자체의 축소”가 핵심인데, MobileCLIP은 그 목적에 직접 부합합니다. MAIFS에서 “AI-Generated” 판정용 임베딩을 MobileCLIP로 바꾸고, DAAC의 43D 메타피처(신뢰도, 불일치 등)는 그대로 유지하는 이식이 현실적입니다. ³⁹

SPAI — 스펙트럼(주파수) 자기지도 학습 기반 Any-resolution 탐지

서지: E. Karageorgiou et al. “Any-Resolution AI-Generated Image Detection by Spectral Learning (SPAI).” CVPR 2025. ⁴⁰

방법 요약: “생성기 아티팩트를 직접 학습”하기보다, **실제 이미지의 스펙트럼 분포를 자기지도(주파수 복원)로 모델링** 하고, 생성 이미지를 그 분포의 OOD로 본다는 발상입니다. 또한 원해상도에서 스펙트럼 단서를 유지하기 위한 spectral context attention을 제안해 any-resolution 처리를 강조합니다. ⁴⁰

보고 지표: 13개 최신 생성 접근에 대해 AUC가 기존 SOTA 대비 5.5%p 개선되었다고 보고합니다(초록). 모델 크기/지연/특정 모바일·보드 실측은 핵심 기여가 아닙니다. ⁴⁰

우리 작업과의 관련성: “주파수/압축 단서”와 잘 결합되는 AI-Generated 탐지 촉진입니다. 특히 MAIFS의 Frequency에 이전트와 역할이 일부 겹치므로, 별도 모델을 추가하기보다 **기존 주파수 에이전트를 ‘스펙트럼 OOD’ 방식으로 교체/증류**하는 방향의 아이디어 소스로 적합합니다. ⁴⁰

LaDeDa / Tiny-LaDeDa 및 BNN 계열 — “가장 작은 모델” 후보군

(위 RQ1에 이미 상세 기술) Tiny-LaDeDa(4 Conv 층, 극단적 FLOPs/파라미터 효율) ¹² 및 BNN 기반(BNext-S: 1.91 GFLOPs 등) ¹⁶ 은, “AI-Generated/딥페이크 스크리닝”을 초저비용으로 붙이는 관점에서 현재 공개된 문헌 중 가장 직접적인 후보군에 속합니다.

공간(Spatial) 기반 로컬라이제이션의 경량 후보

Akram ⁴¹ et al. — CMV2U-Net: MobileNetV2 + 엣지 스트림 기반 스플라이싱 로컬라이제이션

서지: Akram ⁴¹ et al. “CMV2U-Net: A U-shaped network with edge-weighted features for detecting and ...” Journal of Forensic Sciences, 2025. ⁴²

방법 요약: MobileNetV2를 특징 추출 백본으로 쓰고, Canny/Sobel 기반 엣지 정보를 별도 스트림으로 결합해 스플라이싱 경계 단서를 강화합니다. depthwise separable conv와 채널 어텐션을 결합해 효율·성능을 함께 노립니다. ⁴²

보고 지표: ablation에서 “채널 어텐션 + 엣지 검출” 조합이 AUC 96.56%, F1 94.37%, FPR 0.031을 보고합니다. 또한 비교 표에서 CASIA AUC/F1 94.46% / 93.21%, Columbia 88.52% / 82.37%, NIST16 91.20% / 77.65%, In-the-Wild 78.25% / 67.61% 등을 제시합니다(하드웨어 지연은 별도 기재 없음). ⁴³

우리 작업과의 관련성: Mesorch 같은 공간 로컬라이제이션 백엔드에 대한 “MobileNet급 대체 후보”로 가장 직관적입니다. 특히 MAIFS가 목표로 하는 RPi5급 환경에서, MobileNetV2 백본은 TFLite/INT8/NPU 매핑 가능성이 높아(일반론) 실행 측면에서도 유리할 가능성이 큼니다. 성능 측면에서는 “스플라이싱 중심”이므로, copy-move/removal/합성 편집까지 커버 범위를 확인해야 합니다. ⁴⁴

SAPN (Edge TPU) / ForMa / MNVFusion — “다중 단서 통합형 로컬라이제이션” 라인

SAPN은 0.57M 파라미터와 Edge TPU 실측 지연(1.17s)을 명시해 “가장 엣지 지향”이고 ⁷, ForMa는 FLOPs/params를 명시하며 SOTA급 F1을 주장하는 “연산량-정량화 지향”입니다. ³¹ MNVFusion은 “여러 노이즈 뷰”를 내부에서 융합해 MAIFS의 multi-agent 철학을 단일 모델로 압축할 여지를 제공합니다. ³³

엣지에서의 멀티에이전트/양상블 실행 전략

MAIFS는 4개 전문 에이전트를 “동시에” 실행하는 설계이므로, 엣지에서는 곧바로 **(1) 에이전트 실행 순서 최적화, (2) 조건부 생략, (3) 양상블 지식의 단일화**로 이어지는 것이 자연스럽습니다. 아래는 다른 도메인에서 이미 정립된 대표 패턴들입니다.

Daniel Kang ⁴⁵ et al. — NoScope: 저비용 모델 캐스케이드 + 불확실 시 고비용 호출

서지: Daniel Kang ⁴⁵ et al. “NoScope: Optimizing Neural Network Queries over Video at Scale.” VLDB 2017. ⁴⁶

방법 요약: 비디오 질의에서 “항상 무거운 모델(레퍼런스 DNN)을 쓰는 비용”을 줄이기 위해, (i) 특정 비디오/객체에 특화된 저비용 모델, (ii) difference detector 등을 조합한 **캐스케이드**를 자동 탐색합니다. 불확실한 경우에만 레퍼런스 모델을 호출해 정확도를 보존합니다. ⁴⁷

보고 지표: 비용을 최대 3자리수(수백~천 배)까지 줄일 수 있다고 요약에서 주장합니다(문맥상 시스템 최적화 성과). ⁴⁸

우리 작업과의 관련성: MAIFS에 그대로 대응하면 “항상 4개 모델 실행” 대신, **저비용 에이전트(예: Tiny-LaDeDa/BNN/경량 JPEG 단서) → 필요 시 추가 에이전트 실행 → 여전히 불확실하면 서버 오프로딩** 같은 정책을 DAAC가 학습하도록 설계할 수 있습니다. NoScope가 보여준 핵심은 ‘캐스케이드가 정확도 손실 없이 비용을 크게 줄일 수 있다’는 점입니다. ⁴⁷

Junchen Jiang ⁴⁹ et al. — Chameleon: 상황에 따라 “구성(해상도/프레임레이트/모델)”을 동적으로 선택

서지: Junchen Jiang ⁴⁹ et al. “Chameleon: scalable adaptation of video analytics.” SIGCOMM 2018. ⁵⁰

방법 요약: 입력 스트림 특성과 정확도-비용 곡선이 상황에 따라 달라진다는 점을 전제로, 컨트롤러가 실시간으로 “최적 구성”을 선택합니다(비디오 분석 파이프라인의 동적 튜닝). ⁵¹

보고 지표: 본 논문은 “적응형 구성 선택” 자체가 기여이며, 엣지 자원 제약 하에서 정확도/비용을 균형화하는 시스템 패턴을 정립합니다. ⁵¹

우리 작업과의 관련성: MAIFS에서도 이미지 해상도(다운스케일), 패치 수, JPEG 품질 추정 기반 전처리 강도, 실행 에이전트 수 같은 “구성 파라미터”를 DAAC가 동적으로 고르는 문제로 바꿀 수 있습니다. 즉, DAAC를 단순 최종 분류기(GBM)에서 **정책/컨트롤러** 성격으로 확장하는 근거가 됩니다. ⁵²

Surat Teerapittayanon ⁵³ et al. — BranchyNet: 조기 종료(Early Exit)

서지: Surat Teerapittayanon ⁵³ et al. “BranchyNet: Fast Inference via Early Exiting from Deep Neural Networks.” arXiv 2017. ⁵⁴

방법 요약: 네트워크 중간에 “측면 분류기(출구)”를 달아, 쉬운 샘플은 중간에서 종료하고 어려운 샘플만 끝까지 진행합니다. 지연/에너지 절감이 목표입니다. ⁵⁴

보고 지표: 여러 백본(LeNet/AlexNet/ResNet)에서 추론 시간을 크게 줄일 수 있음을 서술합니다(요약 중심). ⁵⁴

우리 작업과의 관련성: MAIFS의 각 에이전트를 “서로 다른 모델”로 유지하더라도, 각 모델 내부에 early exit를 넣거나, DAAC가 “현재까지 관측된 에이전트 출력”만으로 충분히 확신할 때 즉시 종료하도록 만들 수 있습니다. 이는 엣지에서 1초 미만 지연을 맞추는 현실적인 기법입니다. ⁵⁴

LF-ViT — 두 단계(저해상도→포커스)로 FLOPs를 줄이는 조건부 계산

서지: Youbing Hu et al. “LF-ViT: Reducing Spatial Redundancy in Vision Transformer for Efficient Image Recognition.” arXiv 2024. ⁵⁵

방법 요약: 먼저 축소 해상도로 예측하고, 불확실하면 “중요 영역”만 원 해상도로 포커스해 재추론하는 2단계 구조를 제안합니다(같은 파라미터 공유). ⁵⁵

보고 지표: DeiT-S 대비 FLOPs를 63% 줄이고 처리량을 2배로 만들었다고 요약에서 주장합니다. ⁵⁵

우리 작업과의 관련성: 포렌식에서 특히 비싼 부분은 고해상도 처리/세그멘테이션입니다. “저해상도 1차 판정 + 의심 영역만 고해상도”는 Mesorch류 공간 로컬라이제이션 또는 CAT-Net류 마스크 추정에 바로 적용 가능한 설계 패턴입니다. ⁵⁵

양상블을 엣지 단일 학생 모델로 압축하는 증류

서지: Hossein Sharify et al. “Ensemble-Guided Distillation for Compact and Robust Acoustic Scene Classification on Edge Devices.” arXiv 2025. ⁵⁶

방법 요약: 여러 교사 모델 양상블을 구성하고, 그 결정을 학생(경량) 모델로 증류해 엣지에서 단일 모델로 실행하는 프레임워크를 제안합니다. 또한 양자화 준비(quantization-ready) 같은 엣지 배치 관점을 명시합니다. ⁵⁶

보고 지표: TAU Urban Acoustic Scenes 2022 Mobile에서 SOTA를 주장합니다(도메인은 다르지만 “양상블→단일 모델”의 엣지 적용 사례). ⁵⁶

우리 작업과의 관련성: MAIFS는 본질적으로 “전문가 양상블”이므로, 최종 목표(<1초)를 위해서는 (A) 에이전트를 유지하되 조건부로 실행하거나, (B) 아예 DAAC가 학습한 결정을 **단일 경량 학생 모델**로 증류하는 2단계 로드맵이 유효합니다. ⁵⁶

벤치마크 데이터셋 및 엣지 평가 프로토콜

AI-생성 이미지 탐지 벤치마크

GenImage

서지: M. Zhu et al. “A Million-Scale Benchmark for Detecting AI-Generated Image (GenImage).” arXiv 2023. ⁵⁷

핵심: 100만 규모의 real/fake 페어를 포함하고, 다양한 클래스·생성 모델을 포함한다고 소개합니다. “교차-생성기 일반화” 및 “열화 조건”을 평가하는 대표 벤치마크로 널리 인용됩니다. ⁵⁸

엣지 평가 관점: 대형 벤치마크일수록 “모델이 작을수록”보다 “열화에 견디는가”가 중요해지고, 이는 엣지에서 흔히 발생하는 리사이즈/재압축과 직접 연결됩니다. ⁵⁹

SIDBench / ImagiNet / AI-GenBench / RRDataset

서지: SIDBench (R. Bertin et al., 2025) ⁶⁰; ImagiNet (G. Berde et al., 2024) ⁶¹; AI-GenBench (Y. Tian et al., 2025) ⁶²; RRDataset (P. Zhou et al., ICCV 2025) ⁶³

핵심: 공통적으로 “다양한 생성기/다양한 변환(압축, 블러, 리사이즈, 캡처 등)” 하에서의 탐지 성능을 체계화하려는 벤치마크 흐름입니다. ⁶⁴

엣지 평가 관점: MAIFS 같은 시스템은 엣지에서 입력이 “카메라→코덱→전송→저장”을 거치기 쉬우므로, 벤치마크 선택 시 반드시 **degraded/cross-generator** 트랙이 있는 것을 우선해야 합니다. ⁶⁵

WildRF (실세계 소셜 미디어 딥페이크)

서지: LaDeDa 논문이 WildRF를 Reddit/X/Facebook 등 소셜 네트워크 기반으로 구축했다고 설명합니다. ⁶⁶

핵심: 기존 프로토콜의 “JPEG/PNG 포맷 차이 같은 데이터셋 편향” 문제를 지적하고, 실제 유통물로 일반화 갭을 측정하려는 시도입니다. ¹²

엣지 평가 관점: 온디바이스는 오프라인/현장 판별이 잦아 “실세계 유통물 성능”이 더 중요해집니다. WildRF류 평가는 MAIFS 최종 품질을 가능하는 우선순위가 높습니다. ¹²

조작 로컬라이제이션(마스크) 벤치마크

MIML (대규모 조작 로컬라이제이션 데이터셋)

서지: Chenfan Qu et al. “Towards Modern Image Manipulation Localization: A Large-Scale Dataset and Novel Methods.” CVPR 2024. ⁶⁷

핵심: 웹에서 수집한 수동 위조 이미지를 자동·정밀 주석하는 패러다임(CAAA)과 품질 필터(QES)를 제안하며, 123,150 장의 마스크 주석 데이터를 구축했다고 보고합니다. ⁶⁷

엣지 평가 관점: 엣지에서 “마스크까지” 뽑는 모델은 비용이 크게 증가하므로, MIML 같은 대형 마스크 데이터셋은 **저해상도 마스크** 또는 **의심 영역만 ROI 마스크** 같은 경량 추론 전략의 실험장으로도 적합합니다. ⁶⁷

엣지 전용 평가 프로토콜 및 지표

MLPerf Tiny / MLPerf Power

서지: MLPerf Tiny는 tinyML 시스템에서 정확도·지연·에너지 측정을 목표로 하는 벤치마크로 소개됩니다. ⁶⁸ 또한 MLPerf Power는 마이크로와트~메가와트까지 다양한 수준에서 에너지 효율 비교를 위한 규칙/방법론을 제시합니다. ⁶⁹

핵심: 포렌식 분야에는 “MLPerf-forensics”처럼 표준화된 엣지 측정 체계가 아직 널리 자리잡았다고 보기 어렵기 때문에 에(문헌 전반에서 포맷/지표가 제각각), MLPerf류의 규칙(정확도+지연+에너지 동시 보고)을 참조해 자체 프로토콜을 설계하는 것이 현실적입니다. ⁷⁰

엣지 보드 현실 측정 예시(비포렌식)

라즈베리 파이 3/4/5 및 Jetson 계열에서 객체탐지 모델의 에너지·지연·정확도를 수집하는 벤치마킹 연구가 존재하며, 이런 측정 설계(전력 측정, 프레임워크(TFLite/TensorRT 등), 배치=1 지연 등)는 포렌식에도 그대로 적용 가능합니다. ⁷¹

MAIFS·DAAC 관점의 설계 시사점

현행 MAIFS(4개 전문 에이전트 + DAAC/GBM)에서 “엣지 <1초”를 달성하려면, 문헌이 시사하는 최우선 레버는 **모델 자체 경량화** 못지않게 **실행 정책(언제 어떤 에이전트를 돌릴지)**입니다.

첫째, “다중 에이전트”를 유지하되 **NoScope형 캐스케이드**로 비용을 줄이는 접근이 가장 직접적입니다. Tiny-LaDeDa/BNN 같은 초저비용 탐지기를 1차로 두고, DAAC가 확신이 부족할 때만 주파수/노이즈/공간 로컬라이제이션을 추가 실행하도록 정책화하면, 평균 지연을 크게 낮추면서도 어려운 샘플에서 정확도를 확보하는 구조가 됩니다. ⁷²

둘째, “에이전트 수 자체를 줄이는” 방향으로 ForMa/MNVFusion처럼 **다중 단서를 단일 모델 내부로 흡수**하는 계열이 유력합니다. 이는 MAIFS의 장점(다중 단서)과 단점(다중 모델 비용) 사이의 트레이드오프를, “모델 내부 멀티브랜치”로 재배치하는 전략입니다. ²

셋째, CLIP 기반 에이전트를 유지해야 한다면, Ojha et al.처럼 “피쳐 공간은 유지하되 헤드는 단순화”하고, MobileCLIP처럼 “임베딩 모델 자체를 모바일 지향으로 치환”하는 조합이 가장 문헌 친화적입니다. 이때 DAAC 메타피쳐(에이전트별 확률/신뢰도/불일치 통계)는 그대로 유지할 수 있어, 시스템 구조 변경 대비 효과가 큼니다. ⁷³

넷째, 엣지에서의 성능 검증은 “정확도 하나”로는 부족합니다. MLPerf Tiny/Power가 강조하듯 **정확도-지연-에너지**의 동시 보고가 실제 배치 의사결정에 더 직접적이며, 포렌식에서도 SAPN(Edge TPU 지연 보고)이나 의료 파이프라인 연구(이미지당 ms/mJ 보고)처럼 “하드웨어 단위” 측정이 설득력을 갖습니다. ⁷⁴

¹ ⁶ ⁷ ⁷⁴ <https://www.sciencedirect.com/science/article/abs/pii/S0045790625005889>
<https://www.sciencedirect.com/science/article/abs/pii/S0045790625005889>

² ⁸ ³¹ ⁴¹ <https://arxiv.org/html/2502.09941v1>
<https://arxiv.org/html/2502.09941v1>

³ ³⁷ ⁵⁷ ⁵⁸ <https://arxiv.org/abs/2306.08571>
<https://arxiv.org/abs/2306.08571>

⁴ ⁴⁶ ⁴⁷ ⁴⁸ https://people.eecs.berkeley.edu/~matei/papers/2017/vldb_noscope.pdf
https://people.eecs.berkeley.edu/~matei/papers/2017/vldb_noscope.pdf

⁵ ²⁰ <https://pip.raspberrypi.com/documents/RP-008348-DS-raspberry-pi-5-product-brief.pdf>
<https://pip.raspberrypi.com/documents/RP-008348-DS-raspberry-pi-5-product-brief.pdf>

⁹ Energy efficiency in edge TPU vs. embedded GPU for computer-aided medical imaging segmentation and classification - ScienceDirect
<https://www.sciencedirect.com/science/article/abs/pii/S0952197623014823>

¹⁰ ²⁴ <https://github.com/mjkwon2021/cat-net>
<https://github.com/mjkwon2021/cat-net>

¹¹ <https://arxiv.org/abs/2406.09398>
<https://arxiv.org/abs/2406.09398>

¹² ⁶⁶ ⁷² <https://ar5iv.org/abs/2406.09398>
<https://ar5iv.org/abs/2406.09398>

¹³ ¹⁴ ¹⁵ ¹⁶ ⁴⁵ https://openaccess.thecvf.com/content/CVPR2024W/DFAD/papers/Lanzino_Faster_Than_Lies_Real-time_Deepfake_Detection_using_Binary_Neural_Networks_CVPRW_2024_paper.pdf
https://openaccess.thecvf.com/content/CVPR2024W/DFAD/papers/Lanzino_Faster_Than_Lies_Real-time_Deepfake_Detection_using_Binary_Neural_Networks_CVPRW_2024_paper.pdf

¹⁷ ⁴⁰ https://openaccess.thecvf.com/content/CVPR2025/papers/Karageorgiou_Any-Resolution_AI-Generated_Image_Detection_by_Spectral_Learning_CVPR_2025_paper.pdf
https://openaccess.thecvf.com/content/CVPR2025/papers/Karageorgiou_Any-Resolution_AI-Generated_Image_Detection_by_Spectral_Learning_CVPR_2025_paper.pdf

¹⁸ ⁴⁹ <https://arxiv.org/abs/2103.10596>
<https://arxiv.org/abs/2103.10596>

- 19 33 <https://yscholarhub.yonsei.ac.kr/bitstream/2021.sw.yonsei/26020/2/1-s2.0-S0925231225025871-main.pdf>
<https://yscholarhub.yonsei.ac.kr/bitstream/2021.sw.yonsei/26020/2/1-s2.0-S0925231225025871-main.pdf>
- 21 <https://www.mdpi.com/2079-9292/14/5/930>
<https://www.mdpi.com/2079-9292/14/5/930>
- 22 62 65 <https://fdmas.github.io/AIGCDetect/Awesome-AIGCDetection>
<https://fdmas.github.io/AIGCDetect/Awesome-AIGCDetection>
- 23 53 <https://arxiv.org/abs/2108.12947>
<https://arxiv.org/abs/2108.12947>
- 25 35 39 https://openaccess.thecvf.com/content/CVPR2024/papers/Vasu_MobileCLIP_Fast_Image-Text_Models_through_Multi-Modal_Reinforced_Training_CVPR_2024_paper.pdf
https://openaccess.thecvf.com/content/CVPR2024/papers/Vasu_MobileCLIP_Fast_Image-Text_Models_through_Multi-Modal_Reinforced_Training_CVPR_2024_paper.pdf
- 26 27 28 29 <https://xueyangfu.github.io/paper/2022/ACMMM/Forgery-Localization.pdf>
<https://xueyangfu.github.io/paper/2022/ACMMM/Forgery-Localization.pdf>
- 30 63 <https://arxiv.org/html/2505.12335v2>
<https://arxiv.org/html/2505.12335v2>
- 32 50 51 52 <https://dl.acm.org/doi/10.1145/3230543.3230574>
<https://dl.acm.org/doi/10.1145/3230543.3230574>
- 34 <https://www.sciencedirect.com/science/article/pii/S0031320326001299>
<https://www.sciencedirect.com/science/article/pii/S0031320326001299>
- 36 73 https://openaccess.thecvf.com/content/CVPR2023/papers/Ojha_Towards_Universal_Fake_Image_Detectors_That_Generalize_Across_Generative_Models_CVPR_2023_paper.pdf
https://openaccess.thecvf.com/content/CVPR2023/papers/Ojha_Towards_Universal_Fake_Image_Detectors_That_Generalize_Across_Generative_Models_CVPR_2023_paper.pdf
- 38 55 <https://arxiv.org/abs/2402.00033>
<https://arxiv.org/abs/2402.00033>
- 42 43 44 https://cris.vtt.fi/ws/portalfiles/portal/115032643/Journal_of_Forensic_Sciences_-_2025_-_Akram_-_CMV2U_Net_A_U_shaped_network_with_edge_weighted_features_for_detecting_and_1_.pdf
https://cris.vtt.fi/ws/portalfiles/portal/115032643/Journal_of_Forensic_Sciences_-_2025_-_Akram_-_CMV2U_Net_A_U_shaped_network_with_edge_weighted_features_for_detecting_and_1_.pdf
- 54 <https://arxiv.org/abs/1709.01686>
<https://arxiv.org/abs/1709.01686>
- 56 <https://arxiv.org/abs/2512.13905>
<https://arxiv.org/abs/2512.13905>
- 59 <https://www.mdpi.com/2079-9292/14/4/665>
<https://www.mdpi.com/2079-9292/14/4/665>
- 60 64 <https://mever.gr/publications/2404.18552v1.pdf>
<https://mever.gr/publications/2404.18552v1.pdf>
- 61 <https://aclanthology.org/2025.findings-acl.643.pdf>
<https://aclanthology.org/2025.findings-acl.643.pdf>

- ⁶⁷ https://openaccess.thecvf.com/content/CVPR2024/papers/Qu_Towards_Modern_Image_Manipulation_Localization_A_Large-Scale_Dataset_and_Novel_CVPR_2024_paper.pdf
https://openaccess.thecvf.com/content/CVPR2024/papers/Qu_Towards_Modern_Image_Manipulation_Localization_A_Large-Scale_Dataset_and_Novel_CVPR_2024_paper.pdf
- ⁶⁸ ⁷⁰ <https://arxiv.org/abs/2106.07597>
<https://arxiv.org/abs/2106.07597>
- ⁶⁹ <https://arxiv.org/html/2410.12032v2>
<https://arxiv.org/html/2410.12032v2>
- ⁷¹ https://www.researchgate.net/publication/384367118_Benchmarking_Deep_Learning_Models_for_Object_Detection_on_Edge_Computing_Devices
https://www.researchgate.net/publication/384367118_Benchmarking_Deep_Learning_Models_for_Object_Detection_on_Edge_Computing_Devices