

멀티에이전트·앙상블 시스템에서의 최적 부분집합 선택: Shapley·정보이론·비용인지·상호작용 관점 문헌 조사

문제 정식화와 본 과제의 독자성

본 과제는 “특징 선택(feature selection)”이 아니라 **에이전트(모듈) 단위 선택**이다. 4개 이미지 포렌식 에이전트의 출력에서 총 43차원(에이전트별/쌍별 파생 특징 포함)을 구성하고, 메타 분류기(DAAC)가 이를 학습한다는 점에서, 어느 에이전트를 제거하면 (i) 그 에이전트에 해당하는 다수의 특징 차원이 함께 사라지고 (ii) **그 에이전트가 관여하는 모든 쌍별(interaction) 특징도** 함께 제거된다(“그룹 특징 + 상호작용 동시 제거” 구조). 이런 구조는 일반적인 L1/L0 기반 개별 특징 선택보다 **조합적(2^N)이며 상호작용 민감한** 선택 문제가 된다.

이를 문헌적으로 가장 자연스럽게 정식화하는 방법은 “부분집합 $S \subseteq A$ (에이전트 집합)”에 대해 - 가치함수 $v(S)$: “S에 포함된 에이전트 출력으로 구성 가능한 특징만 사용했을 때의 메타 분류 성능(예: AUC/accuracy 등)” - 비용함수 $c(S)$: “S를 실행하는 총 계산비용(지연/전력/메모리 등)”을 정의하고, **정확도(또는 손실)-비용의 다목적 최적화** 또는 **예산 제약 하 최대화(knapsack류)**로 푸는 것이다. 이런 관점은 (a) 4개일 때는 완전탐색이 가능하지만, (b) N이 커질 때 일반화되는 알고리즘적 틀(근사, 탐욕, 진화, 정수계획, 미분가능 선택 등)을 제공하며, (c) “왜 특정 에이전트/조합이 중요한가”를 **기여도(credit)와 시너지(상호작용)**로 설명할 이론적 언어를 제공한다. 이때 핵심 난점은 사용자가 강조한 대로 **상호작용(특히 Frequency↔FatFormer 불일치) 특징이 절대적으로 중요**하다는 경험적 사실이 “개별 에이전트 성능” 중심의 단순 프루닝을 무력화한다는 점이다.

아래에서는 사용자가 제시한 5개 연구질문에 맞춰, “에이전트 가치평가(Shapley)-정보이론 기반 중복/시너지-비용인지 선택-조합최적화/부분모듈러성-상호작용 보존”까지 연결되는 대표 문헌과 본 과제 적용 포인트를 정리한다.

Shapley value 기반 앙상블 멤버 가치 평가

Shapley의 기본 틀과 “Model Shapley vs Data Shapley” 적용

논문: Lloyd S. Shapley ¹. A Value for N-Person Games. (1953).

방법 요약: 협력게임에서 각 플레이어의 기여를 “모든 순열에서의 평균 한계기여”로 분배하는 공리적 해(효율성·대칭성·더미·가법성)를 제시한다. Shapley 값은 상호작용이 존재해도(어떤 플레이어의 기여가 다른 플레이어 존재에 의존해도) **모든 연합에 대한 평균적 한계기여**로 개인 기여도를 정의한다. ²

본 과제와의 연결: 에이전트를 플레이어로 보고, $v(S)$ 를 “해당 에이전트 부분집합만으로 구성된 특징으로 학습한 DAAC 성능”으로 놓으면 **에이전트 단위의 공정한 기여도 산정**이 가능해진다. 특히 “개별 약하지만 함께 강한” 경우에도 Shapley는 $v(S \cup \{i\}) - v(S)$ 를 다양한 S에서 평균내므로 **상호보완성/대체성에 따른 맥락 의존 기여**를 반영한다. ²

정식화 선택: 본 문제는 “데이터 포인트의 가치”가 아니라 “에이전트(모델/모듈)의 가치”이므로, 용어로는 **Model Shapley(모델/에이전트가 플레이어)**가 직접 대응한다. 다만, 계산 복잡도(순열/부분집합 샘플링), 빠른 근사, 분산 추정 등은 Data Shapley 문헌에서 제안된 기법을 거의 그대로 차용할 수 있다(플레이어가 ‘데이터’이든 ‘모델’이든 Shapley 추정의 계산 구조는 유사). ³

Shapley를 “앙상블 멤버 가치평가/프루닝”에 직접 쓰는 연구

논문: Benedek Rozemberczki ⁴ et al. The Shapley Value of Classifiers in Ensemble Games. CIKM ⁵ 2021.

방법 요약: 사전 학습된 분류기들이 “앙상블 게임”에서 협력한다고 보고, 모델 중요도를 Shapley 값으로 정량화한다.

Troupe라는 근사 알고리즘으로 Shapley 기반 앙상블 프루닝을 논한다. ⁶

본 과제와의 연결: “모델(에이전트) 선택”을 Shapley 기반으로 정당화하는 대표적 직접 선행연구다. 특히 “부분집합 선택이 단순 정확도 순서가 아니라, 상호작용/상관/적대적 모델 존재까지 반영한 기여도”로 설명될 수 있음을 보여준다.

⁷

논문: Youcef Djenouri ⁸ et al. Shapley Consensus Deep Learning for Ensemble Pruning (SCDL). WACV ⁹ 2025.

방법 요약: 여러 딥모델을 학습한 뒤, Shapley 값으로 모델(부분집합 포함)의 기여를 평가해 프루닝하고, 데이터 분포/지식베이스를 활용해 추론 시점에서도 모델을 선택하는 2단계 프레임 제안한다. “상호작용을 고려한 모델 중요도”를 강조한다. ¹⁰

본 과제와의 연결: (1) Shapley를 “프루닝의 이론적 기반”으로 세우고 (2) 실제로 모델 수를 줄여 추론 비용을 낮추려는 목표가 본 과제와 정합적이다. 또한 “부분집합의 가치함수 설계(모델 출력 기반)”를 논의하므로, DAAC의 $v(S)$ 설계(예: AUC, log-loss, calibration 포함)에 참고가 된다. ¹⁰

Data Shapley 계열 근사/변형이 주는 계산적 도구

논문: Amirata Ghorbani ¹¹ et al. Data Shapley: Equitable Valuation of Data for Machine Learning. ICML ¹² 2019.

방법 요약: Shapley로 “학습 데이터 포인트”의 기여를 정의하고, 계산량 문제를 해결하기 위한 추정 전략을 제시한다. ¹³

본 과제와의 연결: 플레이어가 데이터가 아니라 에이전트로 바뀌더라도, “부분집합 $v(S)$ 평가가 비싸고 2^N 이 커진다”는 구조는 동일하다. $N=4$ 에서는 정확 계산이 가능하지만, 논문 기여 측면에서 “향후 N 이 커질 때의 근사 가능성(순열 샘플링, 트렁케이션)”을 제시할 때 이 계열이 레퍼런스로 매우 유용하다. ¹³

논문: Ruoxi Jia ¹⁴ et al. Towards Efficient Data Valuation Based on the Shapley Value. AISTATS ¹⁵ 2019.

방법 요약: Shapley 추정을 효율화하는 접근으로 알려진 TMC-Shapley(Truncated Monte Carlo)와 KNN-Shapley 등을 제안한다(문제에 따라 빠른 근사 가능). ¹⁶

본 과제와의 연결: 에이전트 수가 커질 때 “순열 기반 몬테카를로 + 조기 중단(truncation)”으로 비용을 줄이는 설계를 제안할 때 직접 인용 가능하다. $N=4$ 에서는 “정확 Shapley와 근사 Shapley 비교(샘플 수 대비 오차)” 같은 분석도 가능해, 작은 N 에서도 이론/실험적 기여를 만들 수 있다. ¹⁶

논문: Yongchan Kwon ¹⁷ et al. Beta Shapley: a Unified and Noise-reduced Data Valuation Framework for Machine Learning. AISTATS ¹⁵ 2022.

방법 요약: 고전 Shapley의 “효율성(efficiency) 공리”를 완화해 더 일반적인 베타-가중 분포로 기여도를 정의하며, 잡음/분산을 낮추는 데이터 가치평가 프레임을 제시한다. ¹⁸

본 과제와의 연결: “에이전트 기여도”를 Shapley로 정의할 때도, 공리(특히 효율성)를 그대로 유지할지, 비용/불확실성/분산 관점에서 완화할지 논문적 논의가 가능하다(예: 작은 데이터셋에서 $v(S)$ 추정 분산이 큰 경우). ¹⁸

“특징이 아니라 에이전트(그룹 특징) 선택”을 위한 Group Shapley

논문: Martin Jullum ¹⁹ et al. groupShapley: Efficient prediction explanation with Shapley values for feature groups. (2021, preprint/CEUR 버전 존재).

방법 요약: 개별 특징이 아니라 사전 정의된 특징 그룹에 대해 Shapley를 계산하는 groupShapley를 제안한다. 특징이 많거나 의존성이 있을 때 “그룹 단위 설명”이 실용적임을 강조한다. ²⁰

본 과제와의 연결: 한 에이전트가 ≈ 10 차원 특징과 그 에이전트 관련 쌍별 특징까지 “최소 단위”로 묶여 움직이므로, 에이전트는 곧 “특징 그룹”이다. groupShapley는 “에이전트 단위 기여도”를 바로 “그룹 Shapley”로 해석할 수 있어, ‘우리는 특징 선택이 아니라 모듈 선택을 한다’는 메시지를 이론적으로 뒷받침한다. ²⁰

멀티에이전트(다중 주체) 시스템에서 Shapley를 쓰는 맥락

논문: Jie Li ²¹ et al. Shapley Counterfactual Credits for Multi-Agent Reinforcement Learning. KDD ²² 2021.

방법 요약: 다중 에이전트 RL의 credit assignment 문제를 Shapley(및 몬테카를로 근사)로 다루며, “연합(coalition) 고려”를 강조한다(상호작용을 반영한 크레딧 할당). ²³

본 과제와의 연결: 포렌식 앙상블도 “여러 에이전트가 공동으로 최종 결정을 만들어내는 협력 시스템”이므로, (i) 개별 기여도뿐 아니라 (ii) **조합이 만들어내는 시너지/상관 구조**까지 포함한 credit allocation이 필요하다는 논리적 유사성을 제공한다. ²⁴

논문: Jianhong Wang ²⁵ et al. Shapley Q-value: A Local Reward Approach to Solve Global Reward Games. AAAI ²⁶ 2020(아카이브/초안 2019).

방법 요약: 전역 보상을 각 에이전트의 기여로 분해(Shapley 기반)하여 학습을 안정화하려는 “Shapley Q-value”를 제안한다. ²⁷

본 과제와의 연결: DAAC 성능(전역 보상)에 대해 에이전트별 기여와 상호작용을 분해한다는 점에서 개념적 유사성이 크다. 특히 “전역 성능만 보면 왜 특정 에이전트가 중요한지 설명이 어려운데, Shapley 크레딧으로 분해하면 설명 가능”이라는 논리 전개에 참고하기 좋다. ²⁷

정보이론 기반의 앙상블 프루닝·중복성·조건부 기여도

사용자가 제안한 **조건부 상호정보량** $I(Y; X_a | X_{-a})$ 는 “다른 에이전트를 이미 알고 있을 때 에이전트 a가 Y(정답/포렌식 레이블)에 주는 추가 정보”를 의미하며, 직관적으로 에이전트 기여도를 재는 매우 적절한 필터 기준이다. 특히 본 과제처럼 “두 에이전트가 함께 있을 때만 강함”이 관측되는 경우, 단순 $I(Y; X_a)$ 보다 **조건부/상호작용 정보를 포함한 기준**이 중요하다.

앙상블 다양성을 정보이론으로 해석하는 고전적 흐름

논문: Gavin Brown ²⁸ . An Information Theoretic Perspective on Multiple Classifier Systems. (Springer, 2009, Multiple Classifier Systems 관련 챕터).

방법 요약: 상호정보량과 분류오차의 관계를 논하고, 앙상블의 정보량을 “정확도(accuracy) + 다양성(diversity)” 관점으로 전개하는 아이디어를 제시한다. ²⁹

본 과제와의 연결: “각 에이전트의 단독 정확도”가 아니라 “오차 상관/중복 정보”를 줄여서 앙상블 성능이 상승한다는 논리를 정보이론으로 정당화한다. 사용자의 핵심 특징(불일치/갈등)이 높은 중요도를 가진다는 관측은, 바로 이런 “다양성(비중복) 정보”가 가치 있음을 시사한다. ²⁹

논문: Zhi-Hua Zhou ³⁰ et al. Multi-information Ensemble Diversity. (MCS 2010, LNCS).

방법 요약: 앙상블 다양성을 multi-information 관점에서 기술하고, 고차(2차 이상) 상관·상호작용 정보가 다양성에 핵심임을 논한다. ³¹

본 과제와의 연결: “Frequency↔FatFormer 불일치”가 가장 중요하다는 결과는 2차(쌍) 상호작용이 핵심 신호일 가능성을 강하게 시사한다. multi-information/interaction information 계열은 “왜 단독 성능이 약해도 페어가 중요할 수 있는가”를 정보이론적으로 해석하는 레퍼런스를 제공한다. ³¹

논문: Ludmila I. Kuncheva ³² et al. Measures of Diversity in Classifier Ensembles and Their Relationship with the Ensemble Accuracy. Machine Learning 2003.

방법 요약: 이진 분류기 출력 기반의 다양한 다양성 지표(불일치, Q-statistic, double fault, vote entropy 등)를 정리하고, 다양성과 앙상블 정확도의 관계가 단순히 많음을 실험적으로 논한다. ³³

본 과제와의 연결: 사용자의 “불일치 특징이 가장 중요”라는 관측은 Kuncheva 계열의 고전적 다양성 논의(불일치/공동실패 등)와 직접 연결된다. 또한 “다양성 지표가 항상 성능을 보장하진 않는다”는 경고는, 왜 정보이론/게임이론 기반의 더 정교한 기여도(조건부 정보, Shapley 상호작용)를 병행해야 하는지 논리적 배경이 된다. ³³

조건부 상호정보량 기반 선택과 mRMR 계열

논문: Hanchuan Peng³⁴ et al. Feature selection based on mutual information: criteria of max-dependency, max-relevance, and min-redundancy (mRMR). IEEE³⁵ TPAMI 2005.

방법 요약: 상호정보량 기반 최대 관련성-최소 중복성(mRMR) 기준으로 점진적(feature-by-feature) 선택을 정당화한다. 핵심은 “Y와의 관련성”과 “선택된 변수들과의 중복”을 동시에 제어하는 것.³⁶

본 과제와의 연결: mRMR은 원래 특징 선택이지만, “각 에이전트의 출력/요약값을 하나의 랜덤변수로 보고” 에이전트 선택으로 끌어올리면 $I(Y; X_a)$ vs $I(X_a; X_{\{S\}})$ 의 경쟁 구조가 그대로 유지된다. 단, 본 과제는 에이전트 삭제가 쌍별 특징을 동시에 제거하므로, (i) 에이전트를 변수로 보고 MI를 계산하거나, (ii) 에이전트-기반 특징 그룹을 정의해 그룹 MI/조건부 MI를 쓰는 쪽이 더 적합적이다.³⁷

논문: Gavin Brown²⁸ et al. A Unifying Framework for Information Theoretic Feature Selection. JMLR 2012.

방법 요약: 다양한 MI 기반 휴리스틱 기준들을 “조건부 가능도/조건부 MI 근사” 관점으로 통합해 해석한다.³⁸

본 과제와의 연결: 에이전트 선택으로 일반화할 때도 “CMI 근사”가 자연스럽게 등장하고, 흔히 쓰는 관련성-중복성 트레이드오프가 어떤 가정(독립성/근사) 위에 서 있는지 논문적으로 설명할 수 있다.³⁹

“모델 선택을 MI로 한다”는 최신 이론: LLM 앙상블 선택 논문

논문(매우 직접적): Don't Always Pick the Highest-Performing Model: An Information Theoretic View of LLM Ensemble Selection. (arXiv 2026-02).

방법 요약: 모델 출력들을 이산 확률변수로 보고, 부분집합의 가치(예: $I(Y; X_S)$)를 최대화하는 관점에서 “정확도(개별 정보)”-“중복(상관)”-“오차 상관/구조적 오차”의 분해를 제시하며, 그리디 MI 선택 알고리즘을 제안한다. 또한 특정 가정 하에서 (조건부) 서브모듈러성 및 그리디 근사 보장을 논한다.⁴⁰

본 과제와의 연결: 사용자가 원하는 “왜 어떤 에이전트가 중요한가”에 대해, (1) 단독 정확도, (2) 기존 에이전트들과의 예측 중복, (3) 오차 상관/오차 구조로 “추가 가치”를 분해해 설명하는 틀이 바로 제공된다. 특히 “불일치가 중요한 이유 = 라벨 관련 구조적 오차 패턴을 추가로 설명/보완하기 때문”이라는 식의 논문 서술이 가능해진다. 또한 이 논문은 학습 파라미터를 바꾸지 않고도(출력 빈도만으로) MI를 추정해 선택하는 구현 흐름을 제시하므로, 에지 배치 맥락에서 “모델 재학습 없이 선택/프루닝”이라는 스토리도 강화할 수 있다.⁴⁰

정보이론 기반 프루닝(상호작용 고려)과 실제 알고리즘

논문: Yiqing Wu⁴¹ et al. An ensemble pruning method considering classifiers' interaction based on information theory (CCIEP). Springer⁴² Multimedia Systems 2024.

방법 요약: 분류기 간 상호작용을 고려하는 프루닝을 제안하며, symmetric uncertainty(상호정보량 기반 정규화 지표)로 랭킹 및 프루닝을 한다고 기술한다.⁴³

본 과제와의 연결: “상호작용을 고려하는 프루닝”을 명시적으로 내세운 최근 논문으로, 사용자 시스템처럼 “불일치/상호작용 특징이 강력한 신호”인 경우에 이론적 레퍼런스로 인용 가치가 있다. 다만 CCIEP가 실제로 어떤 수준(쌍/고차)에서 상호작용을 정량화하는지는 구현 확인이 필요하다(논문은 symmetric uncertainty 중심으로 서술).⁴³

에이전트 간 “중복성” 측정: CKA·MI 추정 도구

논문: Simon Kornblith⁴⁴ et al. Similarity of Neural Network Representations Revisited. ICML¹² 2019.

방법 요약: 표현 유사도 비교를 위한 CKA(centered kernel alignment)를 제시하고, CKA의 성질을 분석한다.⁴⁵

본 과제와의 연결: 에이전트 출력이 단순 확률/로짓뿐 아니라 중간 표현(또는 후처리 임베딩)을 갖는다면, “두 에이전트가 사실상 같은 신호를 내는지(중복성)”를 CKA로 측정해 프루닝 전 중복 진단을 수행할 수 있다. 이는 “비용 절감”과 “다양성 보존”의 근거로 활용 가능하다.⁴⁵

논문: Mohamed Ishmael Belghazi⁴⁶ et al. MINE: Mutual Information Neural Estimation. ICML¹² 2018.

방법 요약: 고차원 연속변수 사이 상호정보량을 신경망 기반 변분 하한으로 추정하는 MINE를 제시한다.⁴⁷

본 과제와의 연결: 에이전트 출력이 연속·고차원(예: 히트맵, 특징맵 요약)이라면 MI/CMI를 직접 추정하기 어려운데, MINE류를 통해 “에이전트 간 정보 중복/조건부 중복” 추정으로 확장 가능하다. 다만 안정적 추정(편향/분산)은 실험적으로 검증이 필요하다. 47

비용인지 모델·모듈 선택: 다목적 최적화, Pareto, NAS/미분가능 선택

예지 배치에서는 “최대 정확도”가 아니라 **정확도-비용 Pareto 최적**이 목표가 되는 경우가 많다. 본 과제는 에이전트별 비용이 명확(대략 일정)하다는 점에서 비용인지 선택 문제로 깔끔하게 정식화된다.

다목적 최적화의 표준: NSGA-II 및 앙상블 적용

논문: Kalyanmoy Deb 48 et al. A Fast and Elitist Multiobjective Genetic Algorithm: NSGA-II. IEEE 35 TEVC 2002.

방법 요약: 비지배 정렬과 엘리티즘 기반의 대표적 다목적 진화 알고리즘(NSGA-II)을 제시해 Pareto front를 근사한다. 49

본 과제와의 연결: 에이전트 선택을 이진 벡터(선택/미선택)로 두고, 목적함수 1=정확도(또는 -loss), 목적함수 2=비용(지연/연산량)을 두면 NSGA-II로 Pareto-optimal 에이전트 부분집합들을 한 번에 탐색할 수 있다. 이는 “4개는 완전탐색이면 되지만 N이 커지면?”에 대한 자연스러운 일반화 레퍼런스가 된다. 50

논문: Arjun Chandra 51 et al. Ensemble learning using multi-objective evolutionary algorithms. Springer 42 J. Mathematical Modelling & Algorithms 2006.

방법 요약: 앙상블을 “정확도 vs 다양성”의 다목적 문제로 보고, Pareto trade-off를 직접 최적화(DIVACE 등)하는 관점을 정리한다. 52

본 과제와의 연결: 본 과제는 “정확도 vs 비용”이지만, 다양성은 비용 관점과 별개로 성능에 중요(특히 불일치 특징이 핵심)하므로, 2~3목적(정확도, 비용, 다양성/중복성)을 두는 설계를 정당화할 때 인용할 수 있다. 53

논문: Nishant Singh 54 et al. Stacking-based multi-objective evolutionary ensemble learning (“NSGA-II-Stacking”). 2020.

방법 요약: 스택킹 기반 앙상블에서 다목적 진화(예: NSGA-II)를 사용해 베이스 러너 선택을 수행하는 흐름을 보여준다. 55

본 과제와의 연결: 사용자의 시스템도 “메타 분류기(스태킹 류)” 구조이므로, “메타 분류 성능을 유지하며 베이스(에이전트)를 줄인다”는 매우 직접적인 유사 사례다. 56

★ Shapley + 비용(예산) 결합의 대표 사례: CoAI

논문(교차 강조 ★): Gabriel Erion 57 et al. CoAI: Cost-Aware Artificial Intelligence for Health Care. Nature Biomedical Engineering 58 2022.

방법 요약: (1) Shapley 계열의 **가법적 특징 기여도(importance)**를 계산하고, (2) 예산 제약 하에서 중요도 합을 최대화하는 최적화(문서 내 knapsack 형태)를 통해 저비용 특징 부분집합을 선택하는 비용인지 예측 프레임워크를 제시한다. 59

본 과제와의 연결: 에이전트가 곧 “특징 그룹”이라는 본 과제 구조에서는, CoAI의 “(기여도 산정) → (예산 제약 선택)” 파이프라인을 **에이전트 단위로 승격**하는 것이 가능하다. 다만 CoAI는 중요도 합(가법) 기반 선택이어서, 사용자 시스템처럼 “쌍별 불일치가 핵심인 강한 상호작용”을 그대로 반영하려면 **단독 기여도 + 상호작용 기여도(페어 항)**를 함께 최적화(2차 항 포함 knapsack/정수계획)하는 확장이 필요하다. 60

예산/비용을 학습 목표에 넣는 “budgeted prediction” 계열

논문: Zhixiang (Eddie) Xu 61 et al. The Greedy Miser: Learning under Test-time Budgets. ICML 12 2012.

방법 요약: 테스트 시간에 드는 특징 추출 비용을 학습 목적에 포함시켜, CPU-time 예산 하에서 성능을 최대화하도록 학습하는 접근을 제시한다. 62

본 과제와의 연결: “에이전트 하나를 실행하면 그 에이전트 관련 특징군을 얻는다”는 구조는 Greedy Miser가 다루는 “특정 비용”과 구조적으로 유사하다(단, 여기서 모듈/에이전트 비용). 이 계열은 **에지 배치에서 비용을 목적함수로 직접 다루는** 논문적 배경이 된다. ⁶³

논문: Matt J. Kusner ⁶⁴ et al. Cost-Sensitive Tree of Classifiers (CSTC). ICML ¹² 2013.

방법 요약: 입력에 따라 다른 특징을 계산하도록 “분류기 트리”를 구성해 기대 테스트 비용을 낮추는 비용인지 분류 구조를 제안한다. ⁶⁵

본 과제와의 연결: “모든 입력에서 모든 에이전트를 실행”하는 고정 앙상블 대신, 입력 난이도/불확실도에 따라 “필요한 에이전트만 호출”하는 **조건부 실행(conditional computation)**으로 확장할 때 인용 가치가 크다. ⁶⁵

논문: Matt J. Kusner ⁶⁴ et al. Feature-Cost Sensitive Learning with Submodular Trees of Classifiers (ASTC). AAAI ²⁶ 2014.

방법 요약: CSTC를 단순화하고 “근사 서브모듈러성(approximate submodularity)”을 활용해 비용-성능 트레이드오프 최적화를 다룬다. ⁶⁶

본 과제와의 연결: (1) 비용인지 구조를 가지면서도 (2) 서브모듈러/근사 서브모듈러 관점으로 최적화 근거를 제공한다. 여기서, “포렌식 앙상블 정확도가 서브모듈러한가?” 같은 질문에 대해 **‘정확도 자체는 아니어도 특정 대체 목적(정보량/불확실도 감소)은 서브모듈러에 가깝다’**는 논리 전개가 가능해진다. ⁶⁶

NAS/미분가능 선택을 “앙상블 구성 선택”으로 확장

논문: Eric Jang ⁶⁷ et al. Categorical Reparameterization with Gumbel-Softmax. ICLR ⁶⁸ 2017.

방법 요약: 이산 선택(범주형 샘플링)을 연속 완화해 미분가능하게 만드는 Gumbel-Softmax(Concrete 계열) 재파라미터화를 제시한다. ⁶⁹

본 과제와의 연결: 에이전트 선택을 이진/범주형 게이트로 두고 end-to-end 학습으로 “어떤 에이전트를 켤지”를 학습하려면, Gumbel-Softmax류가 대표적 도구다(다만 에이전트 수가 작을 땐 과도할 수 있고, 상호작용을 어떻게 손실에 넣는지가 설계 포인트). ⁶⁹

논문: Chris J. Maddison ⁷⁰ et al. The Concrete Distribution: A Continuous Relaxation of Discrete Random Variables. 2017.

방법 요약: 이산변수의 연속 완화를 위한 Concrete distribution을 제시한다(Gumbel-Softmax와 독립적으로 제안된 계열). ⁷¹

본 과제와의 연결: Gumbel-Softmax와 함께 “차분가능한 에이전트 선택”을 정당화하는 기본 레퍼런스다. ⁷¹

논문: Hussein Hazimeh ⁷² et al. DSelect-k: Differentiable Selection in the Mixture of Experts. NeurIPS ⁷³ 2021.

방법 요약: Mixture-of-Experts에서 k개 이하의 전문가를 선택하는 “희소·미분가능 게이트”를 제안한다. ⁷⁴

본 과제와의 연결: “에이전트 풀에서 최대 k개만 선택”이라는 형태로 에지 비용을 강하게 제어하려면 DSelect-k류의 게이팅이 직접적인 설계 영감을 준다(정적 선택이든 입력별 동적 선택이든). ⁷⁴

논문: James Kotary ⁷⁵ et al. Differentiable Model Selection for Ensemble Learning. IJCAI ⁷⁶ 2023.

방법 요약: 사전 학습된 모델 풀에서 상황(입력)에 따라 선택되는 “미분가능 선택 프로그램”을 학습해 앙상블 멤버를 선택하는 프레임워크를 제시한다. ⁷⁷

본 과제와의 연결: 고정 4에이전트에서 더 큰 풀로 확장할 때, “학습으로 선택을 자동화”하는 방향의 대표 레퍼런스가 된다. 특히 DAAC가 이미 메타 단계 학습을 하고 있으므로, 그 위에 “선택 게이트”를 올리는 구조 논의가 가능해진다. ⁷⁷

논문: Sheheryar Zaidi ⁷⁸ et al. Neural Ensemble Search for Uncertainty Estimation and Dataset Shift. NeurIPS ⁷³ 2021.

방법 요약: 단일 고정 아키텍처의 단순 랜덤시드 앙상블을 넘어서, 아키텍처 다양성을 포함해 자동으로 앙상블을 구성하는 “앙상블-레벨 탐색”을 제안한다. ⁷⁹

본 과제와의 연결: “양상블 구성 자체를 탐색/최적화한다”는 메시지가 논문 기여 포인트로 강화된다. 포렌식 에이전트 풀을 키울 경우(추가 아키텍처/전처리/검출기), NAS/ensemble-search 문헌이 강력한 레퍼런스가 된다. ⁷⁹

에이전트 선택의 조합최적화 관점: 서브모듈러, knapsack, 정수계획

서브모듈러 최대화와 근사 보장

논문: George L. Nemhauser ⁸⁰ et al. An analysis of approximations for maximizing submodular set functions. 1978.

방법 요약: 단조 서브모듈러 함수 최대화에서 탐욕(greedy)이 $(1-1/e)$ 근사 보장을 갖는 고전 결과를 제시한다. ⁸¹

본 과제와의 연결: “에이전트 추가의 한계효용이 감소(diminishing returns)”하는 형태라면, 그리디 선택이 이론적으로 정당화된다. 다만 사용자의 관측(특정 쌍 불일치가 지배적)처럼 강한 보완성은 서브모듈러를 깨뜨릴 수 있어, ‘정확도 자체가 서브모듈러’라고 주장하려면 엄격한 조건 또는 대체 목적(예: 정보량)이 필요하다. ⁸²

논문: Maxim Sviridenko ⁸³. A note on maximizing a submodular set function subject to a knapsack constraint. 2004.

방법 요약: 비용(가중치) 제약이 있는 서브모듈러 최대화(서브모듈러 knapsack)에서 $(1-1/e)$ 근사 알고리즘을 논한다. ⁸⁴

본 과제와의 연결: 에이전트별 비용이 다르고 “총 비용 $\leq$ 예산”이면 정확히 이 설정(서브모듈러 knapsack)과 합치된다. 문제는 $v(S)$ 가 실제로 서브모듈러인지인데, 정보이론 목적($I(Y; X_S)$)은 특정 조건에서 서브모듈러가 성립하는 경우가 있어(아래), “정확도 대신 정보량 목적”으로 이론을 세우는 전략이 가능하다. ⁸⁵

정보이론 목적의 서브모듈러성: 센서 배치와의 연결

논문: Andreas Krause ⁸⁶ et al. Near-Optimal Sensor Placements in Gaussian Processes. JMLR 2008(관련 초기 버전 2005–2006).

방법 요약: 센서 배치를 “상호정보량 최대화”로 두고, MI 목적이 서브모듈러임을 이용해 그리디로 근사 최적 배치를 찾는 흐름을 제시한다. ⁸⁷

본 과제와의 연결: 에이전트를 “센서”로 보고(각 에이전트 출력이 레이블에 대한 정보 제공), 목적을 “불확실도 감소/정보 이득”으로 두면, 서브모듈러성 기반 이론(그리디 근사, 예산 제약)이 논문적 기반이 될 수 있다. 특히 “선택된 에이전트가 레이블의 불확실도를 얼마나 줄이는가”는 포렌식에서도 자연스러운 목표다. ⁸⁸

양상블 프루닝을 정수최적화로 푸는 고전/최근

논문: Yingjie Zhang ⁸⁹ et al. Ensemble Pruning via Semi-definite Programming. JMLR 2006.

방법 요약: 양상블 부분집합 선택을 (정확도-다양성 트레이드오프를 포함한) 이차 정수계획 형태로 두고, SDP로 근사해해를 구하는 접근을 제시한다. ⁹⁰

본 과제와의 연결: 사용자의 시스템처럼 “쌍별 불일치(다양성) 특징이 핵심”이면 목적함수가 자연스럽게 2차 항(페어)으로 확장된다. 이때 QIP/SDP 류는 “상호작용을 보존한 채 프루닝”을 수학적으로 정식화하고 풀 수 있다는 전제로 매우 적절하다. ⁹⁰

논문: Nan Li ⁹¹ et al. Diversity Regularized Ensemble Pruning (DREP). ECML PKDD ⁹² 2012.

방법 요약: 투표 기반 양상블에서 다양성의 역할을 이론적으로 분석하고, 다양성 정규화를 포함한 프루닝(DREP)을 제안한다. ⁹³

본 과제와의 연결: “다양성(불일치)”이 중요하다고 해도 ‘무조건 불일치가 크면 좋은가’는 그렇지 않을 수 있는데, DREP류는 다양성을 정규화 항으로 넣어 성능과 함께 최적화하는 관점을 제공한다. DAAC의 특징 공간에서 “불일치가 성능에 유용한 방식(라벨-연관 불일치)”을 보존하는 설계를 논문적으로 연결하기 쉽다. ⁹³

논문: Marcelo Antônio Mendes Bastos ⁹⁴ et al. Ensemble pruning via an integer programming approach with diversity constraints. (arXiv 2022; 저자 페이지/후속 버전 존재).

방법 요약: 앙상블 선택을 정수계획(IP)으로 풀고, 다양성 최소 수준을 제약으로 거는 방식(“다양성 제약 프루닝”)을 제시한다. ⁹⁵

본 과제와의 연결: 사용자의 목표가 “정확도 최대 + 비용 최소”인데 동시에 “핵심 상호작용(불일치)을 유지”해야 한다면, 상호작용 유지 조건을 “제약”으로 두는 IP 접근이 직관적이다(예: 특정 페어를 반드시 함께 선택, 또는 특정 불일치 지표가 임계 이상). ⁹⁵

논문: Yijun Bian ⁹⁶ et al. Ensemble Pruning based on Objection Maximization with a General Distributed Framework. (arXiv 2018; IEEE ³⁵ TNNLS 게재 버전 언급).

방법 요약: 앙상블 프루닝을 정보 엔트로피 기반 목적 최대화로 정식화하고, 중앙/분산 프레임워크를 제시한다. ⁹⁷

본 과제와의 연결: “비용(시간/메모리) 감소”라는 프루닝 목적을 명시하며, 엔트로피 기반 목적을 사용한다는 점에서 “정보이론 목적 + 프루닝” 교차 레퍼런스다. ⁹⁷

“정확도는 서브모듈러인가?”에 대한 현실적 결론

- 일반적인 분류 정확도(특히 메타 분류기가 비선형이고, 특징이 상호작용을 강하게 포함할 때)는 서브모듈러를 보장하기 어렵다. Kuncheva 계열의 결과처럼 “다양성과 정확도의 관계는 단순하지 않다”는 점도 이를 뒷받침한다. ³³
- 대신, (i) **정보량(불확실도 감소)** 기반 목적, (ii) **잠재 난이도/조건부 독립 가정** 하의 정보 목적(아래 LLM MI 논문), 또는 (iii) “근사 서브모듈러성” 프레임으로 그리디 근거를 제시하는 전략이 문헌적으로 더 안전하다. ⁹⁸

상호작용 효과 측정과 “핵심 불일치(시너지) 보존” 프루닝

사용자 시스템의 핵심 발견은 “Frequency–FatFormer 불일치가 전체 중요도의 56.5%”라는 점이다. 이는 (a) 개별 에이전트의 단독 성능이 아니라 (b) **특정 쌍의 상호작용 신호**가 의사결정에 지배적일 수 있음을 의미한다. 따라서 프루닝 기준도 “개별 정확도/개별 기여도”만으로는 부족하고, **상호작용(시너지/보완성)을 정량화하고 보존하는 선택**이 필요하다.

SHAP interaction values: 예측 설명에서의 상호작용 분해

논문: Scott M. Lundberg ⁹⁹ et al. Consistent Individualized Feature Attribution for Tree Ensembles. (2018; TreeSHAP 및 SHAP interaction values 정의). ¹⁰⁰

방법 요약: 트리 앙상블에 대해 빠른 Shapley(트리 SHAP) 계산을 제안하고, **SHAP interaction values**로 국소적(입력별) 상호작용 효과를 정의한다. ¹⁰¹

본 과제와의 연결: DAAC가 트리 기반(또는 트리로 근사 가능)이라면, “에이전트 간 불일치 특징”과 “개별 에이전트 특징”의 상호작용을 SHAP interaction으로 직접 분해해, “**쌍 상호작용이 정말 성능에 기여한다**”를 설명가능하게 만들 수 있다. 이는 프루닝 시 “특정 쌍을 깨면 성능이 급락” 같은 결과를 이론적으로 뒷받침한다. ¹⁰¹

논문: (같은 계열) A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS 2017. ¹⁰²

방법 요약: Shapley 기반의 가법 설명 프레임(SHAP)을 제시하고, 공리적 성질(유일성/일관성 등)을 논한다. ¹⁰³

본 과제와의 연결: “불일치 특징의 중요도”를 단순 feature-importance로 보고 끝내지 않고, Shapley 기반 설명 프레임으로 “기여도 공리 + 상호작용 확장”까지 연결하는 서술의 기반이 된다. ¹⁰⁴

게임이론적 상호작용 지수: Shapley interaction index, Banzhaf interaction

논문: Michel Grabisch ¹⁰⁵ et al. An axiomatic approach to the concept of interaction among players in cooperative games. 1999.

방법 요약: 협력게임에서 플레이어 집합 S (쌍/부분집합)의 상호작용을 공리적으로 정의하는 interaction index를 제시하며, Banzhaf 및 Shapley 상호작용 지수로 확장될 수 있음을 논한다. ¹⁰⁶

본 과제와의 연결: 에이전트 i, j 의 “시너지(둘이 함께 있을 때만 성능이 상승)”를 정량화하려면, 단일 Shapley 값(개별

기여)만으로는 부족하고 **2차 상호작용 지수**가 필요하다. Grabisch 계열은 “상호작용을 측정하는 표준 공리적 도구”로, Frequency-FatFormer 페어 중요성을 “게임이론적 시너지”로 정식화하는 레퍼런스가 된다. 107

논문: Jean-Luc Marichal 108. Weighted Banzhaf power and interaction indexes through weighted approximations. EJOR 2011.

방법 요약: Banzhaf power/interaction index를 가중 최소제공 근사 문제로 해석하는 등, 상호작용 지수의 계산/해석을 제공한다. 109

본 과제와의 연결: Shapley 상호작용 대신(또는 보조로) Banzhaf 상호작용을 써서 “페어 시너지”를 측정하는 선택지가 된다. 또한 일부 프루닝/모델 가치평가 연구는 Banzhaf 계열을 더 빠르게 계산 가능한 대안으로 사용하기도 한다 (SCDL도 Banzhaf 언급). 110

Shapley 기반 고차 상호작용: Shapley-Taylor, Faith-Shap

논문: Mukund Sundararajan 111 et al. The Shapley Taylor Interaction Index. 2020.

방법 요약: Shapley를 고차 상호작용으로 일반화한 Shapley-Taylor index를 제안하고, 상호작용 분배 공리 등을 논한다. 112

본 과제와의 연결: “쌍별 불일치”뿐 아니라 (N이 커질 때) “3개 이상 에이전트 조합에서만 나타나는 고차 시너지”까지 이론적으로 다루려면 Shapley-Taylor 같은 고차 interaction 프레임이 유용하다. 112

논문: Chih-Ping Tsai 113 et al. Faith-Shap: The Faithful Shapley Interaction Index. JMLR 2023.

방법 요약: 특정 상호작용의 “신뢰성/충실성”을 목표로 하는 Shapley interaction index 변형을 제안한다. 114

본 과제와의 연결: DAAC의 상호작용(불일치) 특징이 실제로 “모델이 학습한 상호작용”을 얼마나 충실히 반영하는지, 단순 중요도(importance) 대비 상호작용 분해가 얼마나 안정적인지 논의할 때 인용 가능하다. 114

정보이론에서의 시너지/중복 분해: PID(Partial Information Decomposition)

논문: Michael Wibral 115 et al. Partial information decomposition as a unified approach to the information decomposition... 2017(리뷰 성격).

방법 요약: 여러 입력이 출력에 제공하는 정보를 **고유(unique)·중복(redundant)·시너지(synergistic)** 로 분해하는 PID 프레임을 정리한다. 116

본 과제와의 연결: “두 에이전트가 함께 있을 때만 얻는 정보”는 PID에서 말하는 ‘synergistic information’과 정확히 대응한다. Frequency-FatFormer 페어가 제공하는 신호를 “중복이 아니라 시너지”로 정량화하면, 프루닝 시 그 페어를 반드시 유지해야 한다는 논문적 정당화가 크게 강화된다. 117

“상호작용을 보존하는 프루닝”을 설계하는 실무적 결론

문헌을 종합하면, 본 과제처럼 “불일치=핵심 신호” 구조에서 프루닝은 다음 중 하나(또는 혼합)로 설계하는 것이 논문적으로 설득력이 높다.

1) (게임이론) 에이전트 **Shapley + 페어 상호작용 지수**를 함께 산정해, “개별 기여”와 “페어 시너지”를 분리 보고한다. (Grabisch 상호작용, SHAP interaction, Shapley-Taylor 등) 118

2) (정보이론) 조건부 MI 기반 **marginal gain**으로 에이전트 추가 가치를 “정확도-중복-오차상관”으로 해석한다. 특히 2026 LLM 양상블 MI 논문이 제공하는 분해는 “왜 단독 성능이 낮아도 특정 에이전트가 필요한가”를 설명하는 데 직접적이다. 40

3) 프루닝 최적화 문제를 **2차 항(페어 상호작용) 포함 정수최적화(QIP/SDP/IP)** 로 두어, “핵심 페어/하이퍼엣지”를 제약 또는 목적함수로 보존한다(Zhang 2006 SDP, Bastos 2022 IP 등). 119

4) 비용까지 포함하면, ★CoAI처럼 “(기여도 산정) → (예산 제약 선택)”이 깔끔하지만, 본 과제처럼 페어 시너지가 지배적이면 단독 기여도 합만으로는 부족하므로, **단독 + 상호작용 항을 포함한 예산 제약 최적화**로 확장하는 것이 자연스럽다. ¹²⁰

¹ ³⁸ ³⁹ ⁸⁶ ⁸⁹ ⁹² ¹¹³ <https://www.jmlr.org/papers/volume13/brown12a/brown12a.pdf>

<https://www.jmlr.org/papers/volume13/brown12a/brown12a.pdf>

² ¹² ⁹⁶ <https://www.rand.org/content/dam/rand/pubs/papers/2021/P295.pdf>

<https://www.rand.org/content/dam/rand/pubs/papers/2021/P295.pdf>

³ ¹³ ⁵⁷ <https://proceedings.mlr.press/v97/ghorbani19c/ghorbani19c.pdf>

<https://proceedings.mlr.press/v97/ghorbani19c/ghorbani19c.pdf>

⁴ ⁷⁰ ¹⁰² ¹⁰³ ¹⁰⁴ <https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>

<https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>

⁵ ¹¹² <https://proceedings.mlr.press/v119/sundararajan20a/sundararajan20a.pdf>

<https://proceedings.mlr.press/v119/sundararajan20a/sundararajan20a.pdf>

⁶ ¹⁴ ³² <https://www.pure.ed.ac.uk/ws/files/243305402/2101.02153v2.pdf>

<https://www.pure.ed.ac.uk/ws/files/243305402/2101.02153v2.pdf>

⁷ ³⁴ <https://arxiv.org/abs/2101.02153>

<https://arxiv.org/abs/2101.02153>

⁸ ⁷³ ⁸¹ ⁸² <https://luthuli.cs.uiuc.edu/~daf/courses/Opt-2019/Paperssubmodular/fisher.pdf>

<https://luthuli.cs.uiuc.edu/~daf/courses/Opt-2019/Paperssubmodular/fisher.pdf>

⁹ ¹⁸ ⁹⁴ ⁹⁹ <https://proceedings.mlr.press/v151/kwon22a/kwon22a.pdf>

<https://proceedings.mlr.press/v151/kwon22a/kwon22a.pdf>

¹⁰ ²² ⁵¹ ⁶⁸ ¹¹⁵ https://openaccess.thecvf.com/content/WACV2025/papers/Djenouri_Shapley_Consensus_Deep_Learning_for_Ensemble_Pruning_WACV_2025_paper.pdf

[https://openaccess.thecvf.com/content/WACV2025/papers/](https://openaccess.thecvf.com/content/WACV2025/papers/Djenouri_Shapley_Consensus_Deep_Learning_for_Ensemble_Pruning_WACV_2025_paper.pdf)

[Djenouri_Shapley_Consensus_Deep_Learning_for_Ensemble_Pruning_WACV_2025_paper.pdf](https://openaccess.thecvf.com/content/WACV2025/papers/Djenouri_Shapley_Consensus_Deep_Learning_for_Ensemble_Pruning_WACV_2025_paper.pdf)

¹¹ ³⁶ ³⁷ ¹⁰⁵ **Feature Selection Based on Mutual Information**

https://ranger.uta.edu/~chqding/papers/mRMR_PAMI.pdf?utm_source=chatgpt.com

¹⁵ ³⁰ ⁶⁶ <https://cdn.aaai.org/ojs/8967/8967-13-12495-1-2-20201228.pdf>

<https://cdn.aaai.org/ojs/8967/8967-13-12495-1-2-20201228.pdf>

¹⁶ **Towards Efficient Data Valuation Based on the Shapley Value**

https://proceedings.mlr.press/v89/jia19a/jia19a.pdf?utm_source=chatgpt.com

¹⁷ ²¹ ⁵⁵ ⁵⁶ <https://www.sciencedirect.com/science/article/abs/pii/S020852161930467X>

<https://www.sciencedirect.com/science/article/abs/pii/S020852161930467X>

¹⁹ ⁵⁹ ⁶⁰ ⁶¹ ⁷⁶ ¹²⁰ <https://pmc.ncbi.nlm.nih.gov/articles/PMC9537352/>

<https://pmc.ncbi.nlm.nih.gov/articles/PMC9537352/>

²⁰ ⁸³ <https://martinjullum.com/publication/preprint-jullum-2021-groupshapley/preprint-jullum-2021-groupshapley.pdf>

<https://martinjullum.com/publication/preprint-jullum-2021-groupshapley/preprint-jullum-2021-groupshapley.pdf>

23 24 25 <https://kunkuang.github.io/papers/KDD21-ShapleyMARL.pdf>
<https://kunkuang.github.io/papers/KDD21-ShapleyMARL.pdf>

26 77 <https://www.ijcai.org/proceedings/2023/0217.pdf>
<https://www.ijcai.org/proceedings/2023/0217.pdf>

27 <https://cdn.aaai.org/ojs/6220/6220-13-9445-1-10-20200516.pdf>
<https://cdn.aaai.org/ojs/6220/6220-13-9445-1-10-20200516.pdf>

28 29 https://link.springer.com/chapter/10.1007/978-3-642-02326-2_35
https://link.springer.com/chapter/10.1007/978-3-642-02326-2_35

31 41 <https://www.lamda.nju.edu.cn/publication/mcs10diversity.pdf>
<https://www.lamda.nju.edu.cn/publication/mcs10diversity.pdf>

33 <https://link.springer.com/content/pdf/10.1023/a%3A1022859003006.pdf>
<https://link.springer.com/content/pdf/10.1023/a%3A1022859003006.pdf>

35 52 53 <https://link.springer.com/article/10.1007/s10852-005-9020-3>
<https://link.springer.com/article/10.1007/s10852-005-9020-3>

40 98 <https://arxiv.org/html/2602.08003v1>
<https://arxiv.org/html/2602.08003v1>

42 43 75 <https://link.springer.com/content/pdf/10.1007/s00530-023-01227-2.pdf>
<https://link.springer.com/content/pdf/10.1007/s00530-023-01227-2.pdf>

44 93 <https://people.cs.bris.ac.uk/~flach/ECMLPKDD2012papers/1125539.pdf>
<https://people.cs.bris.ac.uk/~flach/ECMLPKDD2012papers/1125539.pdf>

45 54 <https://proceedings.mlr.press/v97/kornblith19a/kornblith19a.pdf>
<https://proceedings.mlr.press/v97/kornblith19a/kornblith19a.pdf>

46 100 101 <https://arxiv.org/abs/1802.03888>
<https://arxiv.org/abs/1802.03888>

47 <https://proceedings.mlr.press/v80/belghazi18a/belghazi18a.pdf>
<https://proceedings.mlr.press/v80/belghazi18a/belghazi18a.pdf>

48 72 74 https://proceedings.neurips.cc/paper_files/paper/2021/file/f5ac21cd0ef1b88e9848571aeb53551a-Paper.pdf
https://proceedings.neurips.cc/paper_files/paper/2021/file/f5ac21cd0ef1b88e9848571aeb53551a-Paper.pdf

49 50 <https://www.cp.eng.chula.ac.th/~prabhas/teaching/ec/ec2024/paper/nsga2-ieee-trans-ec-2002.pdf>
<https://www.cp.eng.chula.ac.th/~prabhas/teaching/ec/ec2024/paper/nsga2-ieee-trans-ec-2002.pdf>

58 69 108 <https://openreview.net/pdf?id=rkE3y85ee>
<https://openreview.net/pdf?id=rkE3y85ee>

62 63 78 80 91 <https://icml.cc/2012/papers/592.pdf>
<https://icml.cc/2012/papers/592.pdf>

64 111 116 117 <https://www.sciencedirect.com/science/article/pii/S027826261530021X>
<https://www.sciencedirect.com/science/article/pii/S027826261530021X>

65 https://www.cs.cornell.edu/~kilian/papers/ICML2013_CSTC.pdf
https://www.cs.cornell.edu/~kilian/papers/ICML2013_CSTC.pdf

- 67 79 <https://proceedings.neurips.cc/paper/2021/file/41a6fd31aa2e75c3c6d427db3d17ea80-Paper.pdf>
<https://proceedings.neurips.cc/paper/2021/file/41a6fd31aa2e75c3c6d427db3d17ea80-Paper.pdf>
- 71 <https://arxiv.org/pdf/1611.00712>
<https://arxiv.org/pdf/1611.00712>
- 84 85 <https://thibaut.horel.org/submodularity/papers/sviridenko2004.pdf>
<https://thibaut.horel.org/submodularity/papers/sviridenko2004.pdf>
- 87 88 <https://www.jmlr.org/papers/volume9/krause08a/krause08a.pdf>
<https://www.jmlr.org/papers/volume9/krause08a/krause08a.pdf>
- 90 119 <https://www.jmlr.org/papers/volume7/zhang06a/zhang06a.pdf>
<https://www.jmlr.org/papers/volume7/zhang06a/zhang06a.pdf>
- 95 <https://arxiv.org/abs/2205.01088>
<https://arxiv.org/abs/2205.01088>
- 97 <https://arxiv.org/pdf/1806.04899>
<https://arxiv.org/pdf/1806.04899>
- 106 107 118 <https://link.springer.com/article/10.1007/s001820050125>
<https://link.springer.com/article/10.1007/s001820050125>
- 109 110 <https://www.sciencedirect.com/science/article/abs/pii/S0377221710008076>
<https://www.sciencedirect.com/science/article/abs/pii/S0377221710008076>
- 114 <https://www.jmlr.org/papers/volume24/22-0202/22-0202.pdf>
<https://www.jmlr.org/papers/volume24/22-0202/22-0202.pdf>