

Error-Driven Specialist Ensemble for Image Forensics 최신 연구 동향과 적용 전략

문제 설정과 연구 초점

현재 운영 중인 두 개의 경량 3-class 분류기(dual-stream MobileNetV2, MobileCLIP fine-tuned)는 **표현(특징) 공간에서는 매우 유사하지만, 실제 예측 오답(실패) 집합은 부분적으로 독립**이라는 점이 핵심 출발점입니다. 이런 “표현 유사-오답 비유사” 조합은 앙상블 관점에서 흔히 **오류 다양성(error diversity)**로 해석되며, (적절한 결합 규칙·캘리브레이션이 갖춰지면) 단일 모델 대비 성능 개선 여지가 생깁니다. 앙상블 다양성은 “오답이 함께 나는지(공동 실패)”를 직접 측정하는 **disagreement / double-fault** 같은 지표로 분석할 수 있고, 실제로 double-fault(둘 다 틀리는 비율)가 조합 성능과 더 직접적으로 연결된다는 고전적 관찰도 있습니다. ¹

사용자 예러 분석에서 “두 모델이 공통으로 실패”하는 케이스가 (1) **교묘한 조작(진짜처럼 보이는 splicing/inpainting 등) → authentic으로 오인**, (2) **학습에 없던 신규 생성기(OOD) AI 생성 이미지 → authentic으로 오인**으로 요약됩니다. 이 두 유형은 공통적으로 “**false negative(가짜를 진짜로 놓침)**”를 유발하며, 특히 실제 서비스·포렌식 운영에서는 누락 비용이 큰 축에 속합니다. 또한 최근 포렌식 연구는 알고리즘 자체만큼이나 **데이터 편향(해상도, 포맷, JPEG 압축, 장면/콘텐츠 편향)**이 일반화 실패를 만들 수 있음을 반복적으로 강조해 왔기 때문에, “공통 실패 이미지”를 단순히 많이 모으는 것뿐 아니라 **편향 없는 하드셋 구성**이 중요합니다. ²

이 보고서는 요청하신 네 축(오류 기반 앙상블 보조모델, 미세 조작 탐지, OOD AI 생성 탐지, 전문가 다양성 설계)을 각각 (a) 핵심 논문, (b) 구현 방법, (c) 적용 가능성 관점에서 정리하고, 마지막에 현재 시스템(두 경량 3-class) 위에 얹는 **실행 가능한 설계안**을 통합 형태로 제안합니다. ³

Error-driven ensemble과 mistake-focused learning

핵심 아이디어와 AdaBoost 대비 차이

“Error-driven ensemble / mistake-focused learning”을 실무적으로 정의하면, **기존 모델(들)의 실패 분포(오류 패턴)**를 명시적으로 모델링하고, 그 실패가 집중되는 영역을 (1) **샘플 재가중/마이닝** 또는 (2) **별도 ‘corrector/specialist’ 모델**로 보강하는 접근입니다. 고전적 AdaBoost는 대표적으로 “이전 단계가 틀린 샘플 가중치를 올려 다음 약분류기가 더 잘 맞추도록” 순차 학습을 수행합니다. ⁴

하지만 질문의 맥락(이미 두 개의 강한 경량 DNN이 있고, 공통 실패 유형이 명확)에서는 AdaBoost를 그대로 적용하기보다, 다음과 같은 현대 DNN식 변형이 더 자연스럽습니다.

- **보조(corrector) 모델은 “base 모델을 대체”하기보다 “실패를 보완”**: base 두 모델을 고정(freeze)하고, (특히 둘 다 authentic로 오인하는) **공통 실패 샘플**에 대해 보조 모델이 “조심스러운 재판정”을 하도록 설계합니다. 이는 AdaBoost처럼 전체 데이터에서 반복적으로 가중치를 바꾸며 약학습기를 늘리는 것과 달리, **실패 버킷에 특화된 보강 경로**를 만드는 방향입니다. ⁵
- **하드 샘플 마이닝/가중 손실은 ‘탐지 안정화’에 유리**: DNN에서 “어려운 예제에 더 집중”시키는 대표 기법으로 OHEM(Online Hard Example Mining)과 Focal Loss가 널리 쓰입니다. OHEM은 학습 중 손실이 큰 샘플을 온라인으로 선별해 업데이트를 집중시키고, Focal Loss는 잘 맞히는(easy) 샘플의 기여를 줄여 hard 샘플에 더 큰 학습 신호를 줍니다. ⁶

- ‘**실패 자체**’를 학습 신호로 쓰는 최근 흐름: 예측이 틀릴 때 불확실성을 높이도록 학습하는 “error-driven uncertainty-aware training”류의 접근은, 단순 정확도 향상뿐 아니라 “**모델이 언제 틀리는지**”를 더 잘 알게 만들어 후단 게이팅/양상블 결합에 유리한 신호를 제공합니다. ⁷

또한 AI 생성 이미지 탐지 쪽에서는 “학습 없이도(또는 few-shot으로) 실패 샘플을 활용”해 일반화를 개선하려는 연구가 늘고 있습니다. 예를 들어 “failed samples”를 캐시/보조 신호로 활용하는 recent framework들이 등장했고, 이는 질문의 “mistake-focused” 관점과 결이 맞습니다. ⁸

핵심 논문 3~5편

- **AdaBoost (기초 대비점)**: Yoav Freund ⁹, Robert E. Schapire ¹⁰의 부스팅 정식화는 “오류 샘플 가중치 상승”이라는 대표적 mistake-driven 학습의 원형입니다. ⁴
- **OHEM**: 학습 중 hard example을 온라인으로 선택해 학습 효율과 성능을 올리는 대표적 hard mining 기법입니다. ¹¹
- **Focal Loss**: 잘 맞는 샘플의 손실 기여를 억제해 hard/misclassified 샘플에 집중하도록 설계된 손실로, “하드 예제 중심 학습”을 손실 함수 수준에서 구현합니다. ¹²
- **Error-Driven Uncertainty Aware Training(EUAT)**: “틀릴 때 불확실성을 키우는” 방향으로 error-driven 학습을 수행해 신뢰도/불확실성 추정력을 개선하는 접근입니다. ¹³
- **Leveraging Failed Samples 계열(최근 deepfake/AIGI 일반화)**: 실패 샘플을 few-shot / training-free 방식으로 활용해 OOD 일반화를 노리는 흐름을 한데 보여주는 예시입니다. ⁸

(참고로, 포렌식에서 “서로 다른 접근이 어디서 보완적인지”를 측정하고 결합을 시도한 연구로는 “Harmonizing Image Forgery Detection & Localization”이 실무적 연결점이 큼니다. ¹⁴)

실용적인 구현 방법

보조 모델(corrector) 설계에서 핵심은 “언제, 무엇을, 얼마나” 보정할지의 정의입니다. 현재 실패 유형이 “(manipulated→authentic), (OOD ai_generated→authentic)”로 명확하므로, corrector는 다음과 같이 설계하는 편이 현실적입니다.

1) 학습 데이터 구성: ‘공통 실패 버킷’의 명시화

- 검증(또는 운영 로그)에서 두 base 모델의 예측을 기록하고, 특히 두 모델이 모두 **authentic**로 낸 샘플 중 실제 라벨이 **manipulated/ai_generated**인 집합을 분리합니다(하드 양성).
- 별도로 “한 모델만 실패”한 샘플도 버킷화하면, (a) **공통 실패 교정**과 (b) **상호 교정(서로의 블라인드 스팟)**을 각각 노리는 2단계 설계도 가능해집니다. 이런 오류 집합 기반 분석은 disagreement/double-fault 등 다양성 지표를 직접 활용하는 접근과 연결됩니다. ¹

2) 입력 신호 설계: ‘feature는 유사’해도 ‘정보는 추가’될 수 있게

현재 두 모델이 CKA 상 유사하다는 전제에서는, corrector가 단순히 “기존 임베딩을 또 쓰는” 방식이면 이득이 제한될 수 있습니다. 실무적으로는 아래 중 최소 하나를 추가하는 것이 안전합니다.

- **(A) 두 모델의 로짓/확률 + 중간 feature를 함께 사용**: corrector 입력에 [p1(3-class), p2(3-class), margin, entropy, temperature-scaled logits] 같은 **예측 분포 특징**을 넣으면, 동일 feature 공간이라도 “결정 경계 근처/불확실/불일치” 신호가 살아납니다. “틀릴 때 불확실성을 키우는” 학습(EUAT 류)은 이런 게이팅 신호를 강화하는 방향과 맞물립니다. ⁷
- **(B) 저비용 포렌식 전처리(Residual) 기반 추가 채널**: SRM/고역통과/FFT/DCT residual 같은 저수준 단서를 소형 CNN/Conv1×1로 요약해서 corrector에 제공합니다(다음 섹션의 subtle manipulation 파트와 직결). ¹⁵

3) 학습 방식: 하드 버킷을 ‘가중’하거나 ‘샘플링’으로 강하게 보기

- easiest는 **Focal Loss**나 class-balanced/focal 변형으로 하드 양상에 집중시키는 것입니다. ¹²
- 더 직접적인 방식은 OHEM처럼 배치 내 손실 상위 샘플을 중심으로 업데이트하는 것입니다. ¹¹

- “공통 실패만”을 노린다면, 전체 데이터에서 하드 버킷을 과샘플링하고 나머지는 소량 섞는 **mixture sampling**이 운영 친화적입니다(성능 지표를 “false negative 최소화”로 잡는다면 더욱). 6

4) 추론 설계: ‘선별적 호출(selective invocation)’로 비용을 제어

corrector는 항상 돌릴 필요가 없습니다.

- base 모델 둘 다 **authentic**이고, (a) confidence가 높거나/낮거나, (b) 둘이 **강하게 동의**하거나/미세하게 동의하는 경우 등 조건을 정해, “**놓치면 큰 손해인 구간**”에만 호출합니다.

- 이런 선별 호출은 “틀릴 때 불확실성을 높이도록” 학습된 uncertainty 지표와 특히 궁합이 좋습니다. 7

이미지 위변조 탐지에의 적용 가능성 평가

- **(1) manipulated→authentic 교정**: corrector가 residual/경계 기반 단서를 추가로 사용한다면 효과 가능성이 큼니다. 최근 포렌식 탐지·지역화 연구는 RGB만으로는 희미한 조작 흔적이 사라지는 상황에서 noise/frequency view를 결합하는 방향으로 움직였고, 이는 “진짜처럼 보이는 조작” 실패를 겨냥한 설계와 맞습니다. 16
- **(2) OOD ai_generated→authentic 교정**: corrector가 “신규 생성기 흔적”을 잡으려면, (a) CLIP 계열의 일반화(또는 학습 없이 kNN) 신호, (b) 재구성 기반(diffusion inversion/reconstruction error) 신호, (c) 편향 제거 데이터셋 학습 중 하나가 필요합니다. 그렇지 않으면 단순 재학습은 신규 생성기에서 다시 무너질 확률이 큼니다. 17

Subtle manipulation detection 최신 접근

“미세 조작(subtle manipulation)”은 고전적 copy-move/splicing뿐 아니라, 최신 inpainting·diffusion 기반 편집으로 인해 **RGB에서 육안으로 거의 티가 나지 않는** 상황을 포함합니다. 최근 주요 흐름은 (i) **고역/노이즈/압축/주파수 영역 단서**, (ii) **경계(Edge) 일관성**, (iii) **객체·장면 일관성(semantic-agnostic inconsistency)**를 함께 쓰는 쪽으로 수렴하고 있습니다. 16

핵심 논문 3~5편

- **ObjectFormer (CVPR 2022)**: RGB만으로 사라진 조작 흔적을 잡기 위해 **고주파 특징을 추출해 RGB와 결합**하는 멀티모달 패치 임베딩을 쓰고, **learnable object prototypes**로 객체 수준 일관성을 모델링합니다. “미세 조작 흔적이 RGB에서 안 보일 수 있다”는 문제의식을 정면으로 다룹니다. 18
- **TruFor (CVPR 2023)**: RGB + “학습된 noise-sensitive fingerprint(Noiseprint++ 계열)”를 transformer로 융합해 다양한 조작 유형에 대응하고, **reliability map(오류 가능 영역)**까지 출력하는 “trustworthy” 프레임워크를 제안합니다. 19
- **AdaIFL (ECCV 2024)**: forged region의 “경계만 과도하게 보거나, 반대로 경계를 놓치는” 문제를 지적하며, **dynamic/importance-aware transformer**로 단서 가중을 조절하는 설계를 제안합니다. 20
- **DiffForensics (CVPR 2024)**: diffusion prior를 활용한 2-stage self-supervised 학습으로 “mesoscopic properties(거시·미시 중간)”에 집중하는 전략을 제안하고, **Edge Cue Enhancement Module(ECEM)**로 조작 경계 단서를 단계적으로 강화합니다. 21
- **UnionFormer (CVPR 2024)**: RGB view + noise view + object consistency view의 **3-view 단서 통합**을 unified learning으로 수행하며, 경계 민감 특징 상호작용(BSFI-Net)과 객체 일관성 모델링을 결합합니다. 22

실용적인 구현 방법

현재 시스템이 “3-class 분류”이므로, 최신 문헌(대부분 detection + localization)을 그대로 옮기기보다는, “**분류 파이프라인에 주입 가능한 저비용 포렌식 단서**”부터 단계적으로 추가하는 편이 안전합니다.

1) Residual/Noise/Frequency 입력 채널 추가(가장 실무적)

- **SRM(Spatial Rich Model)** 기반 **residual**: SRM은 본래 steganalysis에서 발전했지만, 조작 탐지에서 “콘텐츠를

억제하고 잔여(residual) 통계와 국소 상관”을 보는 데 강력합니다. SRM 원전(리치 모델)과, SRM 필터를 딥 모델의 입력으로 쓰는 포렌식 네트워크(CVPR 2018) 흐름이 연결됩니다. ²³

- **PRNU/카메라 지문 계열**: PRNU는 센서 고유 노이즈 기반의 대표적 카메라 지문이며, 조작으로 인해 지역적으로 불일치가 생길 수 있습니다(다만 단일 이미지에서 안정적으로 쓰기 어렵거나, 강한 후처리/재압축에 약할 수 있음). ²⁴

- **Noiseprint 계열(카메라 모델 지문)**: scene content를 억제하고 카메라 모델 관련 흔적을 강화하는 CNN 기반 fingerprint(Noiseprint)는 “자연 이미지의 규칙적 패턴에서 벗어난 영역을 anomaly로 본다”는 현대 포렌식 프레임과 맞물립니다. ²⁵

- **DCT/FFT 기반 특징**: JPEG/DCT residual과 FFT amplitude/phase는 조작·재샘플링·생성 흔적을 포착할 수 있어, 경량 보조 분기(예: 1~3 conv + pooling)로 요약해 메인 분류기에 주입할 수 있습니다. ²⁶

2) ‘조작은 국소적’이라는 가정에 맞춘 Patch/MIL 보강

미세 조작이 매우 국소적이면, 전역 3-class 분류기는 “조작 흔적이 프레임 내 작은 영역에만 존재”할 때 평균화되어 놓칠 수 있습니다. 실무적으로는

- 이미지를 여러 패치로 나눠 patch-level 점수를 만들고, **top-k pooling / attention pooling**으로 이미지 레벨 점수를 내는 MIL 스타일 집계기 false negative를 줄이는 데 유리합니다(특히 manipulated→authentic 혼동 대응). 이 계열은 “region/patch 단서로 조작을 잡는다”는 탐지·지역화 문헌의 핵심과 맞닿습니다. ¹⁶

3) 경계 단서(Edge) 강화 모듈은 ‘교묘한 inpainting/splicing’에 직접적

DiffForensics의 ECEM처럼 “경계 단서를 스케일별로 점진 강화”하는 모듈은, 고현실감 inpainting에서 특히 유용합니다. 경량 구현은 (a) Sobel/LoG 기반 edge map을 추가 채널로 넣거나, (b) high-pass branch를 두고 cross-attention/concat으로 결합하는 형태가 가능합니다. ²⁷

이미지 위변조 탐지에의 적용 가능성 평가

- **강점(당장 도움 되는 지점)**: 질문에서 가장 큰 공통 실패인 “조작인데 authentic로 놓치는 케이스”는, 문헌상 반복적으로 “RGB에서 보이지 않는 저수준 단서(노이즈/주파수/압축/경계)”를 결합할 때 개선되는 경향이 보고됩니다. ObjectFormer/TruFor/UnionFormer는 모두 이 방향(멀티뷰·멀티모달 단서 통합)을 강하게 지지합니다. ¹⁶
- **한계(주의할 점)**: PRNU/Noiseprint 계열은 강한 리사이즈·재압축·SNS 재인코딩에서 약화될 수 있고, 도메인 편향(포맷/해상도) 자체를 학습해버리면 오히려 “진짜 사진이 JPEG인 경우” 같은 상황에서 오탐이 늘 수 있습니다. 최근 연구는 이런 편향을 반복 경고합니다. ²⁸
- **현 시스템(분류만 수행) 관점**: 지역화 모듈을 그대로 도입하기 어렵다면, (a) patch/MIL, (b) residual branch, (c) corrector(선별 호출) 조합이 비용 대비 효과가 가장 큼니다. ²⁹

OOD 일반화 기반 AI 생성 이미지 탐지

OOD 생성기 탐지는 2023~2025에 매우 빠르게 전개된 분야이며, 큰 줄기는 대략 세 갈래입니다.

- (i) **Foundation model(특히 CLIP) 특징 공간 기반의 보편 탐지(universal detector)**
 - (ii) **재구성/역과정(reconstruction / inversion) 기반 “생성 이미지가 더 잘 ‘복원되는’ 성질” 활용**
 - (iii) **생성기 구조에서 유도되는 일반적 저수준 흔적(upsampling, frequency, gradients 등) 일반화**
- 그리고 이 모든 흐름을 가로지르는 공통 이슈가 데이터셋 편향(“Fake vs JPEG” 문제)과 “현실적 평가 프로토콜”입니다. ³⁰

핵심 논문 3~5편

- **UniFD / UniversalFakeDetect (CVPR 2023)**: CLIP 특징 공간에서 **nearest neighbor / linear probing** 같은 “학습을 최소화한” 방식이 오히려 보편 일반화에 유리할 수 있음을 분석하고, 기존 패러다임(특정 생성기 학습)이 unseen family로 일반화되지 않는 문제를 짚습니다. ³¹

- **DIRE (ICCV 2023)**: “Diffusion Reconstruction Error”라는 표현을 제안하며, **생성 이미지는 사전학습 diffusion 모델로 더 잘 재구성될 수 있다**는 관찰을 탐지 신호로 사용합니다(특히 unseen diffusion 모델에 대한 일반화와 다양한 perturbation에 대한 강건성을 강조). ³²
- **AEROBLADE (CVPR 2024)**: latent diffusion의 구성 요소인 **autoencoder(AE) 재구성 오차**를 이용한 training-free 탐지 방법으로, 별도 분류기 학습 없이도 강한 성능과 구현 용이성을 제시합니다. ³³
- **FakeInversion (CVPR 2024)**: 오픈소스 diffusion(Stable Diffusion)의 inversion에서 얻는 특징으로 detector를 학습해, **unseen 고품질 생성기(예: DALL·E 3)**로 일반화함을 보이며, 스타일/주제 편향을 줄이기 위해 **reverse image search 기반 평가 프로토콜(SynRIS)**을 제안합니다. ³⁴
- **OpenSDI (CVPR 2025)**: open-world diffusion 조작(전역 생성 + 국소 편집) 상황을 위한 **벤치마크 (OpenSDID)**를 제시하고, 여러 사전학습 foundation model을 “synergizing”하는 방식과 **MaskCLIP**을 제안합니다. 데이터셋에는 SD3, Flux.1 등 신형 계열이 포함됩니다. ³⁵

(추가로 “데이터 편향 제거”를 정면으로 다룬 **B-Free (CVPR 2025)**는 OOD 실패를 줄이는 “학습 데이터 설계” 관점에 서 특히 중요합니다. ³⁶)

실용적인 구현 방법

현재 시스템에 바로 엮기 쉬운 것부터, 비용은 크지만 OOD에 강한 것까지 “계층형”으로 정리합니다.

1) 가장 경량·현실적: CLIP(또는 MobileCLIP) 특징 + kNN/linear probe + 캘리브레이션

- UniFD의 관점은 “특징 공간이 이미 강력하면, 과도한 end-to-end 학습이 오히려 생성기 특이 편향을 학습할 수 있다”는 쪽입니다. 지금 이미 MobileCLIP을 fine-tune 중이므로, OOD를 노릴 때는 (a) 완전 fine-tune보다 (b) **frozen backbone + linear probe**, (c) 또는 **kNN**을 병행해 “학습 편향을 줄이는 경로”를 마련하는 게 실무적으로 유리합니다. ³⁷

- 운영 팁: “authentic로 판단된 샘플”에 대해서만 kNN 거리 기반 OOD 점수를 계산해, ‘**authentic but far-from-real-manifold**’를 후단으로 올리는 구조가 비용 대비 효과가 혼합니다. ³⁸

2) 중간 비용·강한 일반화: 재구성/역과정 기반 탐지(DIRE/AEROBLADE/FakeInversion)

- DIRE/AEROBLADE는 “재구성 오차”가 핵심이며, 모형 학습 없이도 동작하거나(특히 AEROBLADE) 비교적 적은 학습으로도 효과를 냅니다. ³⁹

- FakeInversion은 inversion 기반 특징으로 unseen 고품질 생성기까지 일반화를 보고하는데, 이는 “이미지-공간 detector가 신형 생성기에 빨리 낡는다”는 문제의 직접 해법 중 하나입니다. ³⁴

- 실무 제약: 이 계열은 보통 GPU 시간이 크므로, (a) **샘플링 기반(저해상도/부분 패치)**, (b) 특정 조건에서만 호출(의심 케이스), (c) 서버/배치 분석 전용 전략이 필요합니다. ⁴⁰

3) 저수준 흔적의 “발견”을 통한 일반화: gradients / upsampling / frequency space

- **LGrad (CVPR 2023)**는 “이미지를 gradients로 변환”해 생성 흔적의 일반 표현을 만들고 cross-model/cross-data 일반화를 강조합니다. ⁴¹

- **NPR / up-sampling 재고찰 (CVPR 2024)**은 생성기 업샘플링에서 유도되는 구조적 흔적을 “이웃 픽셀 관계”로 모델링해 open-world 데이터에서 일반화 성능을 보고합니다. ⁴²

- **FreqNet (AAAI 2024)**은 주파수 공간 학습을 통해 source-agnostic feature를 노립니다. ⁴³

4) 가장 중요한 실무 포인트: 데이터 편향 제거와 ‘현실적 평가’

- “Fake or JPEG?”는 많은 AIGI 탐지 데이터셋이 JPEG/해상도 편향을 포함해 탐지기가 그 편향을 학습할 수 있음을 보여주고, 편향을 제거하면 cross-generator 성능과 JPEG 강건성이 크게 바뀔 수 있음을 보고합니다. ⁴⁴

- B-Free는 “real을 기반으로 self-conditioned generation + content augmentation”으로 **semantic alignment**를 강제해 편향을 줄이고, 다수 생성기(FLUX, SD3.5 포함)에서 일반화와 캘리브레이션을 개선했다고 보고합니다. ⁴⁵

- 평가 측면에서는 AIGIBench(NeurlPS 2025)처럼 “멀티 소스 일반화, 열화 강건성, 전처리 민감도”를 체계화한 벤치마크가 등장했고, ICCV 2025 RRDataset도 “현실 시나리오(전송/재디지타이즈 등)”를 강조합니다. ⁴⁶

이미지 위변조 탐지에의 적용 가능성 평가

- **(OOD ai_generated→authentic 문제에 직접적):** UniFD(kNN/linear probe), DIRE/AEROBLADE/FakeInversion(Open-world 탐지), OpenSDI(Open-world 조작 벤치/모델) 계열은 모두 “학습에 없는 생성기에서 real로 빨려 들어가는 문제”를 정면으로 다룹니다. 질문의 OOD 실패 모드에 가장 직접적인 문헌 축입니다. 47
- **(운영 현실성):** on-device/저비용을 유지해야 한다면, 당장 실현 가능한 최우선 조합은 “MobileCLIP 특징 + (frozen) linear probe + kNN OOD 점수 + 편향 통제된 하드셋 재학습”입니다. 역과정 기반(DIRE/FakeInversion)은 “의심 샘플에만 호출”하는 2단계 운영으로 실용성이 올라갑니다. 48

의도적으로 설계된 specialists와 disagreement 기반 합의

질문에서 요구한 “disagreement-based consensus + intentionally designed specialists”는 최근(특히 2024~2025) 포렌식에서 빠르게 현실화된 흐름입니다. 핵심은 두 가지입니다.

1) ‘다양성’은 우연히 생기게 두지 말고, 목표 실패 모드에 맞게 설계

고전적으로 앙상블 다양성은 disagreement / double-fault 같은 지표로 정량화됩니다. 특히 “둘 다 틀리는 케이스(double-fault)”가 낮을수록 앙상블 이득이 커질 가능성이 높다는 관찰이 있고, 다양한 지표가 제안돼 왔습니다. 1

2) ‘전문가(specialist)’는 (a) 서로 다른 단서(주파수/노이즈/의미/재구성)를 보거나, (b) 서로 다른 서브태스크(진짜 vs 조작, 진짜 vs AI 등)를 맡는 방식으로 만들 수 있음

최근 ICCV 2025의 Forensic-MoE는 다양한 synthetic technique에서 “단일 관점”이 한계를 가지므로, 여러 포렌식 전문가(adapters)를 한 backbone에 통합해 상호작용과 trace 통합을 유도하는 구조를 제안합니다. 49

핵심 논문 3~5편

- **Ensemble diversity 측정(기초):** Kuncheva & Whitaker(2003)는 Q-statistic, correlation, disagreement, double-fault 등 다양한 diversity 통계를 정리했습니다. 50
- **DREP (Diversity Regularized Ensemble Pruning):** diversity를 명시적으로 정규화해 작은 서브앙상블을 선택하는 pruning 방법론으로, “효율 제약이 있는 앙상블 운영”과 연결됩니다. 51
- **Deep ensemble에 대한 diversity regularization:** deep ensemble에 다양성 정규화를 넣는 접근(예: calibration 개선 목적)까지 포함해 “딥 앙상블에서의 다양성 설계”를 다룹니다. 52
- **Agree to Disagree (ICLR 2023):** disagreement를 학습 목표로 삼아 transferability를 높이려는 연구로, “특정 분포에 과적합된 일치성(consensus)” 대신 “의도된 불일치”가 일반화에 도움이 될 수 있음을 보여줍니다. 53
- **Forensic-MoE (ICCV 2025):** 여러 전문가(adapter)를 활용해 “다양한 synthetic trace를 다관점으로 포착”하고 상호 정렬/상호작용으로 통합하는 구조를 제안합니다. 54

(“포렌식 방법들 간 상호 보완성 측정과 결합”을 다룬 연구로 Harmonizing...도 직접적으로 참고 가치가 큼. 14)

binary specialists 조합이 3-class generalist보다 앙상블에 유리할 수 있는 근거

질문 맥락(3-class: authentic / manipulated / ai_generated)에서 “binary specialist 조합”이 유리한 이유는 크게 세 층위로 정리할 수 있습니다.

- **오류 구조를 쪼개기:** 지금 관측된 핵심 실패는 사실상 두 개의 이진 경계에서 발생합니다.
 - manipulated vs authentic 경계에서 “조작을 진짜로 놓침”
 - ai_generated vs authentic 경계에서 “신규 생성기를 진짜로 놓침”
- 따라서 3-class 하나로 모든 경계를 동시에 잘 맞추기보다, 각 경계에 특화된 binary specialist를 만들고 후단에서 결합하면 “실제 버킷을 직접 겨냥”하기 쉽습니다. 이는 앙상블 다양성 측정·설계 관점과 맞물립니다. 1

- **단서의 종류가 다르다(조작 vs 생성):** Subtle manipulation은 noise/frequency/edge 단서가 강한 반면, AI기는 생성기 구조 흔적(upsampling/frequency/gradients) 또는 foundation model 특징·재구성 특성이 핵심이 되는 경우가 많습니다. UnionFormer/TruFor/ObjectFormer(조작)과 UniFD/DIRE/FakeInversion(AIGI)은 “잘 먹히는 단서”가 다름을 보여주는 대표 축입니다. 55
- **다중 이진 분해(ECOC/에러 정정 관점)의 정당화:** multi-class를 여러 binary로 분해해 “에러 정정”을 얻는 ECOC 계열은 오래된 개념이지만, 최근에는 binary 분기 간 다양성을 최대화하는 설계를 통해 robustness를 강화하려는 딥 학습 연구도 있습니다. 이 관점은 “binary specialist들의 조합이 단일 3-class보다 더 fault-tolerant할 수 있다”는 구조적 근거로 쓸 수 있습니다. 56

실용적인 구현 방법

1) 특화 binary heads를 명시적으로 설계

- Specialist-M: `manipulated vs authentic` (high recall 목표), 입력에 SRM/edge/Noiseprint 등 “조작 단서”를 강하게 포함. 57
- Specialist-G: `ai_generated vs authentic` (open-world generalization 목표), MobileCLIP frozen+linear probe + kNN/거리 점수 병행. 37
- (선택) Specialist-A: `authentic vs not-authentic` 를 매우 보수적으로(누락 최소) 학습해 “진짜로 보일 때 한 번 더 걸러주는 안전망”으로 사용. 이는 운영상 false negative 감축에 직접적입니다. 58

2) 결합 규칙: disagreement를 ‘트리거’로 쓰고, 확률은 ‘캘리브레이션 후’ 합치기

- 두 base + specialists의 출력은 데이터 편향에 민감할 수 있으므로, B-Free/“Fake or JPEG?”류에서 지적하는 편향을 줄인 검증셋으로 temperature scaling/Platt scaling을 권장합니다. 2
- 결합은 (a) 규칙 기반(예: Specialist-A가 fake면 항상 fake), (b) stacking meta-learner(로짓/특징 입력) 둘 다 가능하며, Harmonizing...처럼 “상호 보완성”을 먼저 계측하고 결합을 설계하는 접근이 실무적입니다. 59

3) 전문가 수/구성은 “DREP식 pruning”으로 경량화

- 많은 전문가를 만들기보다, 검증셋에서 double-fault(공동 실패)가 낮은 조합을 남기는 pruning은 비용 제약(모바일/엣지)에서 특히 유리합니다. 60

이미지 위변조 탐지에의 적용 가능성 평가

- **특히 유리한 조건:** 지금처럼 (i) 에러 패턴이 부분 독립이고, (ii) 실패 모드가 “특정 혼동 방향(authentic sink)”으로 뚜렷하며, (iii) 비용 제약이 있어 “필요할 때만 추가 연산”이 가능한 경우, “의도적 specialist + disagreement 트리거”는 비용 대비 효과가 큰 편입니다. 61
- **실패 가능 지점:** specialist가 결국 같은 편향(포맷/해상도/JPEG)이나 같은 표현(유사한 CKA 특성)만 재학습하면, 다양성이 실종되어 이득이 작아질 수 있습니다. 최근 연구가 데이터 편향을 반복 경고하는 이유가 여기에 있습니다. 62

통합 적용 로드맵과 평가

아래는 “두 경량 3-class(현행) + 오류 기반 specialists/corrector”를 **최소 리스크로 단계 도입**하는 로드맵입니다(각 단계는 독립적으로도 의미가 있도록 설계).

시스템 설계 제안

단계적 캐스케이드(권장)

- 1) **Stage 0 (현재 유지):** 두 3-class 모델을 그대로 실행해 기본 분류를 얻습니다.
- 2) **Stage 1 (저비용 안전망):** base 출력이 authentic(특히 둘 다 authentic)인 경우에만,
 - (a) `authentic vs not` 보수적 Specialist-A(또는 corrector)를 호출하거나,
 - (b) MobileCLIP 기반 kNN 거리 점수(“real manifold로부터의 이탈”)를 계산합니다(UniFD 스타일). 63

3) **Stage 2 (고비용 OOD 강화, 선택적)**: Stage 1에서 “의심”으로 올라온 케이스만,
- DIRE/AEROBLADE/FakeInversion류 재구성/역과정 기반 점수를 추가 계산합니다(서버/배치 가능). 64

이 설계는 “false negative 최소화”에 직결되는 반면, 오탐(cost of false positive)을 통제하려면 캘리브레이션과 평가 프로토콜이 중요합니다. 65

학습 데이터/프로토콜 권장

- **하드셋 구성 원칙**: 공통 실패(둘 다 authentic로 놓친 케이스)를 모으되, “Fake or JPEG?”가 지적하듯 JPEG/해상도/포맷 편향이 섞이면 모델이 엉뚱한 단서를 학습할 수 있으므로, 가능한 한 **real과 fake의 포맷·해상도·후처리 분포를 맞추는 통제**가 필요합니다. 28
- **OOD 확장 방식**: B-Free처럼 semantic alignment를 강제하거나, FakeInversion처럼 reverse image search로 real 분포에 맞춘 매칭 평가를 하는 등 “콘텐츠 편향 최소화”가 OOD 일반화에 유리합니다. 66
- **평가 벤치마크 관점**:
 - AIGIBench는 multi-source generalization과 degradation/전처리 민감도까지 체계화합니다. 67
 - ICCV 2025 RRDataset는 인터넷 전송/재디지타이즈 같은 현실 변형을 포함해 “in-the-wild 성능”을 더 직접 겨냥합니다. 68
 - OpenSDI는 open-world diffusion 조작(전역/국소)을 포함해 “실제 편집 위협”과 가까운 평가축을 제공합니다. 69

기대 효과와 리스크 관리

- **기대 효과(가장 가능성이 높은 개선)**:
 - subtle manipulation(조작) 농침 감소: noise/frequency/edge 단서 보강 + patch/MIL + corrector 조합이 문헌 흐름과 가장 잘 맞습니다. 70
 - OOD AIGI 농침 감소: CLIP 특징 기반 universal 신호(UniFD), 재구성 기반(DIRE/AEROBLADE/FakeInversion), 편향 제거 데이터(B-Free) 중 최소 1개 축을 도입하면 개선 가능성이 큼. 71
- **리스크(실제 배포에서 자주 터지는 지점)**:
 - 데이터 편향을 “가짜 단서”로 학습 → 배포 시 오탐/미탐 급증. 28
 - 전문가를 늘렸지만 error correlation이 높아 다양성 실종 → 계산만 늘고 이득 미미. 이를 방지하려면 double-fault/불일치 지표 기반으로 전문가를 고르고(DREP식 pruning), disagreement 트리거를 명시적으로 설계하는 것이 중요합니다. 72

이상의 문헌과 설계안을 종합하면, 질문의 상황(두 모델의 공통 실패가 “미세 조작”과 “신규 생성기 OOD”에 집중됨)은 “에러 기반 보조모델 + 의도적 전문가 설계”가 가장 이득을 내기 쉬운 전형적인 조건에 가깝습니다. 다만 2024~2025 연구가 반복적으로 보여주듯, 성능을 좌우하는 병목은 알고리즘만이 아니라 **편향 없는 하드셋 구성과 현실적 평가**이므로, 구현 시에는 “하드 예제 추가”보다 “하드 예제의 편향 제거”를 동일한 수준의 핵심 과제로 두는 것이 안전합니다. 73

1 3 50 58 61 72 <https://link.springer.com/article/10.1023/A%3A1022859003006>

<https://link.springer.com/article/10.1023/A%3A1022859003006>

2 36 45 65 66 73 https://openaccess.thecvf.com/content/CVPR2025/papers/Guillaro_A_Bias-Free_Training_Paradigm_for_More_General_AI-generated_Image_Detection_CVPR_2025_paper.pdf

https://openaccess.thecvf.com/content/CVPR2025/papers/Guillaro_A_Bias-Free_Training_Paradigm_for_More_General_AI-generated_Image_Detection_CVPR_2025_paper.pdf

4 https://www.face-rec.org/algorithms/Boosting-Ensemble/decision-theoretic_generalization.pdf

https://www.face-rec.org/algorithms/Boosting-Ensemble/decision-theoretic_generalization.pdf

- 5 10 14 59 <https://www.mdpi.com/2313-433X/10/1/4>
<https://www.mdpi.com/2313-433X/10/1/4>
- 6 11 29 https://openaccess.thecvf.com/content_cvpr_2016/papers/Shrivastava_Training_Region-Based_Object_CVPR_2016_paper.pdf
https://openaccess.thecvf.com/content_cvpr_2016/papers/Shrivastava_Training_Region-Based_Object_CVPR_2016_paper.pdf
- 7 13 **Error-Driven Uncertainty Aware Training**
https://arxiv.org/html/2405.01205v2?utm_source=chatgpt.com
- 8 <https://arxiv.org/html/2508.09475v1>
<https://arxiv.org/html/2508.09475v1>
- 9 17 30 31 37 38 47 48 63 71 https://openaccess.thecvf.com/content/CVPR2023/papers/Ojha_Towards_Universal_Fake_Image_Detectors_That_Generalize_Across_Generative_Models_CVPR_2023_paper.pdf
https://openaccess.thecvf.com/content/CVPR2023/papers/Ojha_Towards_Universal_Fake_Image_Detectors_That_Generalize_Across_Generative_Models_CVPR_2023_paper.pdf
- 12 https://openaccess.thecvf.com/content_ICCV_2017/papers/Lin_Focal_Loss_for_ICCV_2017_paper.pdf
https://openaccess.thecvf.com/content_ICCV_2017/papers/Lin_Focal_Loss_for_ICCV_2017_paper.pdf
- 15 23 <https://dde.binghamton.edu/kodovsky/pdf/TIFS2012-SRM.pdf>
<https://dde.binghamton.edu/kodovsky/pdf/TIFS2012-SRM.pdf>
- 16 18 70 https://openaccess.thecvf.com/content/CVPR2022/papers/Wang_ObjectFormer_for_Image_Manipulation_Detection_and_Localization_CVPR_2022_paper.pdf
https://openaccess.thecvf.com/content/CVPR2022/papers/Wang_ObjectFormer_for_Image_Manipulation_Detection_and_Localization_CVPR_2022_paper.pdf
- 19 https://openaccess.thecvf.com/content/CVPR2023/papers/Guillaro_TruFor_Leveraging_All-Round_Clues_for_Trustworthy_Image_Forgery_Detection_and_CVPR_2023_paper.pdf
https://openaccess.thecvf.com/content/CVPR2023/papers/Guillaro_TruFor_Leveraging_All-Round_Clues_for_Trustworthy_Image_Forgery_Detection_and_CVPR_2023_paper.pdf
- 20 https://www.ecva.net/papers/eccv_2024/papers_ECCV/papers/06023.pdf
https://www.ecva.net/papers/eccv_2024/papers_ECCV/papers/06023.pdf
- 21 27 **DiffForensics: Leveraging Diffusion Prior to Image Forgery Detection and Localization**
https://openaccess.thecvf.com/content/CVPR2024/papers/Yu_DiffForensics_Leveraging_Diffusion_Prior_to_Image_Forgery_Detection_and_Localization_CVPR_2024_paper.pdf
- 22 55 **UnionFormer: Unified-Learning Transformer with Multi-View Representation for Image Manipulation Detection and Localization**
https://openaccess.thecvf.com/content/CVPR2024/papers/Li_UnionFormer_Unified-Learning_Transformer_with_Multi-View_Representation_for_Image_Manipulation_Detection_CVPR_2024_paper.pdf
- 24 https://ws2.binghamton.edu/fridrich/Research/full_paper_02.pdf
https://ws2.binghamton.edu/fridrich/Research/full_paper_02.pdf
- 25 <https://github.com/grip-unina/noiseprint>
<https://github.com/grip-unina/noiseprint>
- 26 <https://dl.acm.org/doi/full/10.1145/3633203>
<https://dl.acm.org/doi/full/10.1145/3633203>
- 28 44 62 <https://arxiv.org/abs/2403.17608>
<https://arxiv.org/abs/2403.17608>

32 39 64 DIRE for Diffusion-Generated Image Detection

https://openaccess.thecvf.com/content/ICCV2023/papers/Wang_DIRE_for_Diffusion-Generated_Image_Detection_ICCV_2023_paper.pdf?utm_source=chatgpt.com

33 40 https://openaccess.thecvf.com/content/CVPR2024/papers/Ricker_AEROBLADE_Training-Free_Detection_of_Latent_Diffusion_Images_Using_Autoencoder_Reconstruction_CVPR_2024_paper.pdf

https://openaccess.thecvf.com/content/CVPR2024/papers/Ricker_AEROBLADE_Training-Free_Detection_of_Latent_Diffusion_Images_Using_Autoencoder_Reconstruction_CVPR_2024_paper.pdf

34 https://openaccess.thecvf.com/content/CVPR2024/papers/Cazenavette_FakeInversion_Learning_to_Detect_Images_from_Unseen_Text-to-Image_Models_by_CVPR_2024_paper.pdf

[https://openaccess.thecvf.com/content/CVPR2024/papers/](https://openaccess.thecvf.com/content/CVPR2024/papers/Cazenavette_FakeInversion_Learning_to_Detect_Images_from_Unseen_Text-to-Image_Models_by_CVPR_2024_paper.pdf)

[Cazenavette_FakeInversion_Learning_to_Detect_Images_from_Unseen_Text-to-Image_Models_by_CVPR_2024_paper.pdf](https://openaccess.thecvf.com/content/CVPR2024/papers/Cazenavette_FakeInversion_Learning_to_Detect_Images_from_Unseen_Text-to-Image_Models_by_CVPR_2024_paper.pdf)

35 69 https://openaccess.thecvf.com/content/CVPR2025/papers/Wang_OpenSDI_Spotting_Diffusion-Generated_Images_in_the_Open_World_CVPR_2025_paper.pdf

https://openaccess.thecvf.com/content/CVPR2025/papers/Wang_OpenSDI_Spotting_Diffusion-Generated_Images_in_the_Open_World_CVPR_2025_paper.pdf

41 https://openaccess.thecvf.com/content/CVPR2023/papers/Tan_Learning_on_Gradients_Generalized_Artifacts_Representation_for_GAN-Generated_Images_Detection_CVPR_2023_paper.pdf

[https://openaccess.thecvf.com/content/CVPR2023/papers/](https://openaccess.thecvf.com/content/CVPR2023/papers/Tan_Learning_on_Gradients_Generalized_Artifacts_Representation_for_GAN-Generated_Images_Detection_CVPR_2023_paper.pdf)

[Tan_Learning_on_Gradients_Generalized_Artifacts_Representation_for_GAN-Generated_Images_Detection_CVPR_2023_paper.pdf](https://openaccess.thecvf.com/content/CVPR2023/papers/Tan_Learning_on_Gradients_Generalized_Artifacts_Representation_for_GAN-Generated_Images_Detection_CVPR_2023_paper.pdf)

42 https://openaccess.thecvf.com/content/CVPR2024/papers/Tan_Rethinking_the_Up-Sampling_Operations_in_CNN-based_Generative_Network_for_Generalizable_CVPR_2024_paper.pdf

https://openaccess.thecvf.com/content/CVPR2024/papers/Tan_Rethinking_the_Up-Sampling_Operations_in_CNN-based_Generative_Network_for_Generalizable_CVPR_2024_paper.pdf

43 <https://ojs.aaai.org/index.php/AAAI/article/view/28310/28609>

<https://ojs.aaai.org/index.php/AAAI/article/view/28310/28609>

46 67 <https://arxiv.org/abs/2505.12335>

<https://arxiv.org/abs/2505.12335>

49 54 https://openaccess.thecvf.com/content/ICCV2025/html/Fang_Forensic-MoE_Exploring_Comprehensive_Synthetic_Image_Detection_Traces_with_Mixture_of_ICCV_2025_paper.html

[https://openaccess.thecvf.com/content/ICCV2025/html/Fang_Forensic-](https://openaccess.thecvf.com/content/ICCV2025/html/Fang_Forensic-MoE_Exploring_Comprehensive_Synthetic_Image_Detection_Traces_with_Mixture_of_ICCV_2025_paper.html)

[MoE_Exploring_Comprehensive_Synthetic_Image_Detection_Traces_with_Mixture_of_ICCV_2025_paper.html](https://openaccess.thecvf.com/content/ICCV2025/html/Fang_Forensic-MoE_Exploring_Comprehensive_Synthetic_Image_Detection_Traces_with_Mixture_of_ICCV_2025_paper.html)

51 60 <https://people.cs.bris.ac.uk/~flach/ECMLPKDD2012papers/1125539.pdf>

<https://people.cs.bris.ac.uk/~flach/ECMLPKDD2012papers/1125539.pdf>

52 <https://openreview.net/pdf?id=Hy1QdPyvz>

<https://openreview.net/pdf?id=Hy1QdPyvz>

53 <https://openreview.net/pdf?id=K7CbYQbyYhY>

<https://openreview.net/pdf?id=K7CbYQbyYhY>

56 <https://arxiv.org/abs/1912.00181>

<https://arxiv.org/abs/1912.00181>

⁵⁷ [https://openaccess.thecvf.com/content_cvpr_2018/papers/](https://openaccess.thecvf.com/content_cvpr_2018/papers/Zhou_Learning_Rich_Features_CVPR_2018_paper.pdf)

[Zhou_Learning_Rich_Features_CVPR_2018_paper.pdf](https://openaccess.thecvf.com/content_cvpr_2018/papers/Zhou_Learning_Rich_Features_CVPR_2018_paper.pdf)

https://openaccess.thecvf.com/content_cvpr_2018/papers/Zhou_Learning_Rich_Features_CVPR_2018_paper.pdf

⁶⁸ [https://openaccess.thecvf.com/content/ICCV2025/papers/](https://openaccess.thecvf.com/content/ICCV2025/papers/Li_Bridging_the_Gap_Between_Ideal_and_Real-world_Evaluation_Benchmarking_AI-Generated_ICCV_2025_paper.pdf)

[Li_Bridging_the_Gap_Between_Ideal_and_Real-world_Evaluation_Benchmarking_AI-Generated_ICCV_2025_paper.pdf](https://openaccess.thecvf.com/content/ICCV2025/papers/Li_Bridging_the_Gap_Between_Ideal_and_Real-world_Evaluation_Benchmarking_AI-Generated_ICCV_2025_paper.pdf)

https://openaccess.thecvf.com/content/ICCV2025/papers/Li_Bridging_the_Gap_Between_Ideal_and_Real-world_Evaluation_Benchmarking_AI-Generated_ICCV_2025_paper.pdf