

이미지 위변조 탐지 시스템 고도화를 위한 **CKA** 기반 표현 비유사성 정규화 및 앙상블 다양성 학습 방법론 연구

서론 및 연구의 목적

현대의 이미지 위변조 탐지(Image Forensics) 시스템은 점차 고도화되는 생성형 인공지능(Generative AI) 및 정교한 딥페이크(Deepfake), 악의적인 이미지 편집 기술에 대응하기 위해 다각적인 특징 추출 및 분석 능력을 강력하게 요구받고 있다. 단일 신경망 모델 구조로는 이미지의 전역적 의미(Semantic) 정보와 국소적 미세 노이즈(Micro-artifacts) 정보를 동시에 학습하고 추론하는 데 근본적인 한계가 존재한다. 이를 극복하기 위해 본 연구는 서로 다른 목적과 구조를 지닌 두 개의 경량 모델을 앙상블(Ensemble)로 결합하는 하이브리드 아키텍처 설계 방법론의 타당성과 구체적인 최적화 방안을 심층적으로 다룬다.

분석의 대상이 되는 제안 아키텍처는 다음과 같은 두 가지 핵심 컴포넌트로 구성된다. 첫째, Model A(MobileNetV2 기반)는 RGB 이미지 데이터에 기반하여 원본(Authentic), 조작(Manipulated), AI 생성(AI-generated) 이미지를 분류하는 3-class 범용 분류기(Generalist) 역할을 수행한다. 둘째, Model B는 조작 탐지에 특화된 전문가 모델(Binary Specialist)로서 원본과 조작 이미지 구분에만 집중한다. 이 앙상블 시스템이 성공하기 위한 필수 요건은 두 모델 간의 '표현 다양성(Representation Diversity)' 및 '상호보완성(Complementarity)'을 수학적으로 확보하는 것이다. 단순히 두 모델을 독립적으로 학습시키는 것을 넘어, Model B를 학습할 때 Model A의 표현(Representation)과 통계적으로 다르게 학습되도록 강제하는 손실 함수 설계가 제안되었다.

제안하는 목적함수는 클래스 불균형을 해소하기 위한 Focal Loss와 CKA(Centered Kernel Alignment) 기반의 정규화 항으로 구성된다. 수식으로는

$L = L_{focal}(logits, labels) - \lambda \cdot CKA(f_B, f_A)$ 로 표현되며, 여기서 f_A 는 사전 학습이 완료되어 가중치가 고정(Frozen)된 Model A의 특징 맵(Feature map) 또는

임베딩(Embedding)이고, f_B 는 역전파를 통해 갱신 중인 Model B의 특징이다. λ 는 다양성을 강제하는 페널티의 강도를 조절하는 하이퍼파라미터이다. 이 수학적 구조는 Model B가 정답을 도출하는 방향으로 최적화됨과 동시에, Model A와는 최대한 직교하거나 겹치지 않는 새로운 특징 공간(Feature Space)을 탐색하도록 강제한다. 본 보고서는 이러한 CKA 기반 손실 함수 통합의 수학적 정당성, 앙상블 다양성 강제 방법론의 역사와 한계, 이미지 포렌식에 특화된 다중 모달리티(Multi-stream) 고려사항, 그리고 실용적 구현을 위한 최적화 전략을 종합적으로 분석한다.

CKA 및 HSIC를 학습 목적함수로 활용한 수학적 분석 및

선행연구

신경망의 은닉층(Hidden layer)에서 추출된 표현(Representation) 간의 유사도를 측정하는 것은 모델의 동작 방식을 이해하는 핵심 도구로 자리 잡아 왔다. 초기에는 정형적 상관 분석(Canonical Correlation Analysis, CCA)이 주로 사용되었으나, 이는 가역적 선형 변환에 불변하다는 특성 때문에 데이터 포인트 수보다 차원이 큰 현대 신경망의 고차원 표현을 비교하는 데 한계를 보였다.¹ 이러한 한계를 극복하기 위해 등장한 것이 CKA(Centered Kernel Alignment)이며, 이는 통계적 독립성을 측정하는 HSIC(Hilbert-Schmidt Independence Criterion)를 기반으로 하여 등방성 스케일링(Isotropic scaling)과 직교 변환(Orthogonal transformation)에 불변하는 특성을 갖춘 강력한 유사도 지표로 널리 채택되었다.¹

HSIC Bottleneck 및 목적함수로서의 활용

최근 연구 동향은 CKA와 HSIC를 단순한 분석 도구를 넘어, 신경망의 가중치를 업데이트하기 위한 최적화 목적함수(Objective Function)에 직접 통합하는 방향으로 진화하고 있다. 가장 대표적이고 선구적인 선행 연구는 Ma et al. (2020)이 제안한 HSIC Bottleneck 방법론이다.³ 이 연구는 기존 딥러닝의 표준인 교차 엔트로피(Cross-Entropy)와 오차 역전파(Backpropagation) 메커니즘을 대체하기 위해 정보 병목(Information Bottleneck, IB) 이론을 차용했다. 정보 병목 이론은 입력 데이터 X 와 은닉층의 표현 Z 사이의 상호정보량(Mutual Information) $I(X; Z)$ 를 최소화하여 불필요한 정보를 압축하고, 은닉층 표현 Z 와 정답 레이블 Y 사이의 상호정보량 $I(Z; Y)$ 를 최대화하여 예측에 필수적인 정보만을 남기는 것을 목표로 한다.⁶ Fano의 부등식(Fano's inequality)에 따르면, 분류 오류 확률은 조건부 엔트로피 $H(Y|X)$ 에 의존하므로 이러한 정보 병목 구조는 수학적으로 강력한 분류 성능을 보장한다.³

Ma et al. (2020)은 고비용의 상호정보량 계산을 피하기 위해 이를 HSIC로 대체하여 다음과 같은 층별(Layer-wise) 목적함수를 구성하였다. $\min (HSIC(X, Z_l) - \beta \cdot HSIC(Y, Z_l))$.⁴ 이 방식은 기울기 소실(Vanishing gradient) 및 폭발(Exploding gradient) 문제를 근본적으로 완화하며, 망의 깊이에 상관없이 스킵 커넥션(Skip connection)조차 필요 없는 안정적인 훈련을 가능하게 함을 입증했다.³ 또한 이 방법은 층 간의 순차적인 역전파에 의존하지 않아 병렬 연산 및 생물학적 타당성(Biological plausibility) 측면에서도 높은 평가를 받았다.⁷ 이는 HSIC 및 CKA가 신경망의 훈련 과정에서 손실 함수로서 직접적으로 피드백을 제공할 수 있는 강력하고 안정적인 통계량임을 증명하는 핵심 사례이다.

이후 베이지안 딥러닝(Bayesian Deep Learning) 및 지식 증류(Knowledge Distillation) 분야에서도 CKA를 손실 함수로 도입하는 사례가 등장했다. 예를 들어, 교사 모델과 학생 모델 간의 유사도를 극대화하기 위해 CKA 기반의 표현 증류(Representation Distillation) 손실 함수를 제안한 연구는 CKA가 기존의 유클리디안 거리 기반 손실보다 신경망의 기하학적 특성을 훨씬 잘 정렬함을 확인했다.¹⁰ 반면, 앙상블 다양성을 확보하기 위해 초구면 에너지(Hyperspherical Energy) 개념을 도입하여 CKA 값을 정칙화 항으로 사용해 모델 간의 거리를 극대화(즉, CKA 최소화)하는 접근법도 연구되었다.¹¹ 이는 제안된 아키텍처가 Model A와 Model B의 CKA를

최소화하려는 시도와 정확히 일치하는 선행 사례이다.

미니배치 단위 CKA 추정기의 편향(Bias) 문제와 비편향 추정기(Unbiased Estimator)

CKA를 학습 손실 함수로 편입할 때 직면하는 가장 큰 기술적 난관은 역전파를 위한 미니배치(Mini-batch) 단위의 연속적 계산에서 발생하는 통계적 오차이다. 수학적으로 HSIC 및

CKA는 전체 데이터 분포에 대한 전역적 통계량이다. 이를 최적화 과정에서 크기가 m 인 미니배치 샘플로 근사(Estimation)할 때, 단순한 경험적 추정(Empirical estimation)은 심각한 상향 편향(Upward bias)과 높은 분산(Variance) 문제를 야기한다.¹³

표준적인 편향 CKA 연산은 두 특징 행렬 $X, Y \in \mathbb{R}^{m \times d}$ 에 대해 Gram 행렬 $K = XX^T$ 및 $L = YY^T$ 를 구성하고, 중앙화 행렬(Centering Matrix)

$H = I_m - \frac{1}{m}11^T$ 를 적용하여 중앙화된 유사도 행렬의 궤적(Trace)을 기반으로 내적을 구한다.³ 그러나 이 경험적 수식은 Gram 행렬의 대각 성분(Diagonal elements), 즉 동일한 샘플

자기 자신과의 유사도를 포함하여 연산하기 때문에, 미니배치 크기 m 이 작을수록 자기 자신에 대한 과도한 확신이 추정치 전체를 지배하게 되어 실제 모집단의 CKA 값보다 통계량을 과대적합하게 부풀린다.¹³

이 문제를 해결하고 학습을 안정화하기 위해서는 Song et al. (2012) 및 Nguyen et al. (2021) 등의 연구에서 제안되고 증명된 비편향 HSIC 추정기(Unbiased HSIC Estimator)를 반드시 도입해야 한다.¹⁴ 비편향 추정기는 Gram 행렬 연산에서 대각 성분의 영향을 수학적으로 소거하여 미니배치 크기에 독립적인 일관된 추정을 가능하게 한다. 수식은 다음과 같이 고차원 행렬 연산으로 보정된다.

$$HSIC_1(K, L) = \frac{1}{n(n-3)} \left(tr(\tilde{K}\tilde{L}) + \frac{1}{(n-1)(n-2)} (1^T \tilde{K} 1)(1^T \tilde{L} 1) - \frac{2}{n-2} 1^T \tilde{K} \tilde{L} 1 \right).$$

여기서 $\tilde{K}$ 와 $\tilde{L}$ 은 기존 Gram 행렬에서 대각 성분만을 0으로 설정한 행렬이다.¹⁴ 이 비편향 CKA(Unbiased CKA)를 신경망의 손실 함수로 사용할 경우, 훈련 과정에서의 기울기(Gradient) 변동성이 현저히 감소하고, 미니배치 크기가 비교적 작은 상황에서도 안정적인 표현 공간 탐색과 파라미터 최적화가 보장된다.¹⁵ 이는 본 제안 아키텍처의 성공적인 구현을 위한 핵심 수학적 전제 조건이다.

앙상블 다양성을 직접 학습하는 방법론의 진화와 정확도-다양성 딜레마

다수의 신경망 모델을 결합할 때, 각 모델이 서로 다른 오차 분포를 가질 경우 앙상블의 전체 예측 성능이 획기적으로 향상된다는 점은 기계 학습의 오랜 정설이다. 이러한 다양성(Diversity)을 모델이 자발적으로 학습하도록 목적함수 수준에서 강제하는 시도는 오랜 시간 동안 진화해 왔으며, 본 연구에서 제안하는 CKA 정규화 접근법 역시 이러한 역사적 흐름의

최전선에 위치한다.

Negative Correlation Learning (NCL) 및 오차 분해 이론

Liu와 Yao (1999)에 의해 체계화된 NCL(Negative Correlation Learning)은 앙상블 내 개별 네트워크의 예측 오차 간 상관관계를 직접적인 패널티로 부과하는 전통적이고 강력한 이론적 프레임워크이다.¹⁶ 기계학습의 근본적인 편향-분산 분해(Bias-Variance Decomposition) 이론을 앙상블 시나리오로 확장한 편향-분산-공분산 분해(Bias-Variance-Covariance Decomposition) 정리에 따르면, 앙상블 시스템의 총 평균 제곱 오차(MSE)는 개별 모델들의 편향, 개별 모델들의 분산, 그리고 모델 예측 간의 상호 공분산(Covariance)의 합으로 정확히 분해된다.¹⁷

앙상블의 전체 오차를 최소화하기 위한 가장 효과적인 방법은 이 공분산 항을 음수(Negative Correlation)로 유도하는 것이다. 즉, 한 모델이 특정 샘플에서 과대적합이나 구조적 한계로 인해 양의 방향으로 오류를 범할 때, 다른 모델은 음의 방향으로 오류를 범하게 함으로써 앙상블 평균을 취할 때 오류가 서로 상쇄되도록 만드는 원리이다.¹⁶ NCL은 전체 손실 함수에 각 모델의 출력과 앙상블 평균 출력 간의 차이를 패널티 항으로 추가하여 이를 강제한다. 제안하는

$\lambda \cdot CKA(f_B, f_A)$ 방식은 이러한 NCL의 철학을 단순한 최종 예측값(Logits) 수준이 아니라, 신경망의 심층 표현(Feature/Representation) 행렬 분포라는 고차원 공간으로 끌어올린 현대적이고 기하학적인 확장으로 해석할 수 있다.

DeCov를 통한 특징 공분산 최소화와 표현 직교성 강제

네트워크 내부의 특징 공간에서 중복을 제거하기 위해 고안된 방법론 중 가장 돋보이는 것은 Cogswell et al. (2015)이 제안한 DeCov(Decorrelating Representations)이다.²⁰ 이 연구는 모델이 훈련 데이터에 과대적합(Overfitting)되는 주요 원인을 은닉층 내 활성화(Activation)들이 서로 불필요하게 높은 상관관계를 가지며 동일한 특징을 중복 학습하는 동조화(Co-adaptation) 현상으로 지목했다. 이를 방지하기 위해 DeCov는 특정 은닉층 내 미니배치 활성화들의

교차-공분산(Cross-Covariance) 행렬 C 를 계산하고, 이 행렬의 비대각(Off-diagonal) 성분들의 프로베니우스 노름(Frobenius Norm)을 최소화하도록 손실 함수에 직접적인 제약을 더한다.²⁰ 수식은 $\$L_{\text{DeCov}} = \frac{1}{2} (\|C\|_F^2 - \|\text{diag}(C)\|_2^2)\$$ 로 전개되며, 이는 신경망이 특징 공간의 직교성(Orthogonality)을 높이도록 유도하여 과대적합을 억제하고 데이터의 다양한 측면을 비상관화된(Decorrelated) 형태로 학습하게 만든다.²¹

유사하게, DivE-KD나 Feature Orthogonality Constraint 기법들은 여러 학생 모델 또는 앙상블 멤버들이 서로 교차하지 않는 직교화된 특징 공간을 구성하도록 유도하여 앙상블의 포괄성을 극대화한다.²³ 하지만 DeCov와 같은 단일 모델 내에서의 비상관화 기법은, 서로 다른 구조와 목적을 가진 두 이기종 모델(Model A와 B) 간의 '상대적' 비유사성을 제어하기에는 수학적 한계가 존재한다. 따라서 서로 차원이 다른 계층 간에도 스케일 불변성을 유지하며 유사도를 측정할 수 있는 CKA 기반 접근이 다중 모델 앙상블에는 훨씬 적합한 대안이 된다.

Anti-Distillation과 예측 불일치 극대화

최근 자연어 처리 및 구조적 예측(Structured Prediction) 분야에서 앙상블의 예측 다양성을

확보하기 위해 주목받은 개념이 Anti-Distillation이다.²⁵ Shamir와 Coviello (2020) 등에 의해 제안된 이 접근법은 전통적인 지식 증류(Knowledge Distillation)의 철학을 정반대로 뒤집은 것이다.²⁶ 지식 증류가 교사 모델의 연성 레이블(Soft labels)을 학생 모델이 모방하도록 클백-라이블러 발산(KL Divergence)을 최소화하는 반면, Anti-Distillation은 앙상블 컴포넌트들의 출력이나 임베딩이 서로 이격되도록 상관관계를 낮추는 페널티(Decorrelation loss)를 부여하여 예측의 다양성을 극대화한다.²⁶ 이를 통해 미니배치 내의 샘플들에 대해 모델들이 인위적으로 다른 가설 공간(Hypothesis space)을 탐색하도록 유도하며, 최종 앙상블 예측의 안정성과 재현성(Reproducibility), 그리고 적대적 공격(Adversarial attack)에 대한 방어력을 비약적으로 향상시킨다.²⁷ 제안 방법인 CKA 최소화는 이러한 Anti-Distillation 철학을 로짓(Logit) 단위가 아닌 중간층 표현 벡터 단위에서 수학적으로 훨씬 더 안정적인 행렬 내적 형태로 구현한 전략이다.

Accuracy-Diversity Trade-off와 적응형 완화 기법

이러한 다양성 강제 방법론들이 현업에 적용될 때 부딪히는 가장 큰 한계는 이른바 '정확도-다양성 트레이드오프(Accuracy-Diversity Trade-off)' 문제이다.²⁹ 앙상블 예측 오차를

줄이기 위해 다양성 정규화 강도(예: λ 값)를 너무 높게 설정하면, 개별 모델(여기서는 Model B)은 단순히 다양성 지표를 충족시키기 위해, 정답을 판별하는 데 매우 핵심적이고 유용한 특징마저 Model A가 사용한다는 이유만으로 회피하게 된다. 결과적으로 개별 모델들의 자체적인 탐지 성능(Accuracy)이 심각하게 훼손되며, 오히려 앙상블 전체의 성능 저하를 초래하는 붕괴 현상이 발생한다.³⁰

이러한 모순을 해결하기 위해 최근의 Diversity-Promoting Regularization 방법론들은 고정된 상수를 사용하는 대신 정교한 적응형(Adaptive) 스케줄링이나 자가 오류 조정(Self-Error Adjustment, SEA) 프레임워크를 도입한다.³² SEA 프레임워크는 앙상블 오류를 개별 학습자의 자기 오류와 학습자 간의 상호작용(다양성)이라는 두 가지 뚜렷한 구성 요소로 분해하고, 개별 모델의 손실을 훼손하지 않는 경계선 내에서만 상호작용 항을 동적으로 조정한다.³² 실용적인 훈련 단계에서는, 학습 초기에는 다양성 페널티를 주지 않고 각 모델이 개별적인 분류 성능을

달성하도록 유도한 후(Curriculum learning), 수렴의 후반부에 들어서 적응형으로 λ 를 증가시켜 결정 경계를 세밀하게 비틀어주는 방식이 강력히 권장된다.³³

이미지 포렌식에 특화된 다중 스트림과 전문가 모델 이론

딥러닝 기반 이미지 포렌식(Image Forensics)은 객체를 인식하고 분류하는 전통적인 컴퓨터 비전 작업과 본질적으로 다른 통찰을 요구한다. 이미지에 '무엇'이 찍혔는지(Content/Semantics)를 파악하는 것을 넘어, 그 이미지가 '어떻게' 생성되거나 조작되었는지에 대한 미시적이고 물리적인 인과 관계, 즉 미세 아티팩트(Micro-artifacts, 센서 노이즈, 양자화 오류, 압축 흔적 등)에 집중해야 하기 때문이다.³⁴

Multi-stream 앙상블 및 Handcrafted Feature와의 상호보완성

수많은 선행 포렌식 연구들은 RGB 스트림 하나만으로는 생성형 AI가 남긴 미세한 흔적이나

경계선 블러링(Blurring)을 동반한 정교한 스플라이싱(Splicing) 조작을 포착하기 어렵다는 사실을 증명해왔다.³⁶ 이에 따라 시각적 특징과 통계적 노이즈 특징을 동시에 분석하는 다중 스트림(Multi-stream) 접근법이 업계의 표준으로 자리 잡았다. 주요하게 활용되는 두 가지 추가 모달리티는 다음과 같다.

1. **SRM (Steganalysis Rich Model)** 필터: 이미지의 픽셀 값에 고주파 통과 필터(High-pass filter)들을 적용하여 시각적인 내용(Semantics) 정보는 억제하고, 국소적인 노이즈 패턴과 조작 과정에서 발생한 잔차(Residual)의 불일치성만을 두드러지게 남긴다.³⁶
2. **DCT (Discrete Cosine Transform)** 스트림: 주파수 도메인으로의 변환을 통해 JPEG 압축 단계에서 필연적으로 발생하는 이산화 잔차, 이중 압축(Double JPEG) 아티팩트, 그리고 특정 압축 라이브러리가 남기는 고유한 크로마 링클(Chroma wrinkle)이나 양자화 지문 등을 효과적으로 포착한다.³⁹

RGB 특징공간을 기반으로 심층 신경망이 스스로 학습한 특징(Learned feature)과 SRM/DCT를 거친 전문가 설계 특징(Handcrafted feature) 간의 상호보완성(Complementarity)을 정량화한 연구들에 따르면, 이 두 정보 공간은 완전히 다른 저차원 매니폴드(Subspace)를 차지하고 있다.³⁶ 즉, 결합 시 모델 간의 정보 겹침이 적어 시너지가 극대화된다.

본 제안에서 Model B를 이진 스페셜리스트(Binary Specialist)로 구성할 때, 만약 입력으로 RGB뿐만 아니라 SRM 필터링 결과나 주파수 도메인 잔차를 함께 병합하여 넣어준 상태에서 CKA 페널티를 부과한다면, Model B는 Model A가 이미 탐색한 의미론적 RGB 필터 경로를 무시하고 온전히 고주파 아티팩트와 노이즈 불일치 특성에 집중하도록 수학적으로 강제된다. 이는 설계자가 의도한 "A가 보지 못하는 맹점을 보는 모델"을 구현하는 가장 이상적인 방법론적 연결이다.

Binary Specialist 설계와 Meyen et al. (2021)의 이론적 함의

조작 탐지는 조작 기법(Copy-move, Splicing, Deepfake Inpainting 등)마다 남기는 흔적과 노이즈 패턴이 판이하게 다르기 때문에 단일 네트워크가 모든 조작을 파악하기는 어렵다. 이러한 관점에서 Meyen et al. (2021)의 연구는 왜 제너럴리스트보다 스페셜리스트 앙상블이 포렌식에서 유리한지에 대한 매우 중요한 신호 탐지 이론(Signal Detection Theory, SDT)적 근거를 제공한다.⁴²

Meyen 등은 다수의 이진 분류기(Binary classifier)들의 조합을 분석하며, 범용적 데이터에 훈련된 제너럴리스트(Generalist) 모델들보다 국소적이고 편향되지 않은(Uncorrelated) 정보에 집중하는 전문가(Specialist) 모델들의 앙상블이 그룹 의사결정의 정확도에서 이론적으로 훨씬 높은 상한선(Upper bound)을 갖는다는 것을 증명했다.⁴² 해당 이론에 따르면, Model A가 전체적인 이미지의 맥락과 AI 생성 여부를 포괄적으로 판별하는 제너럴리스트 역할을 수행하고, Model B가 픽셀 간 노이즈 조작 탐지라는 국소적 이진 분류(Authentic vs Manipulated)에만 역량을 집중하는 스페셜리스트로 작동할 때, Model B의 정보 내용(Mutual Information)이 Model A와 중복되지 않을수록(즉, 상관관계가 0에 가깝고 CKA가 낮을수록) 앙상블의 결합 정확도는 정보이론적으로 볼록(Convex)하게 상승한다.⁴³ 더 나아가 각 분류기의 예측 신뢰도(Confidence) 가중치를 기반으로 집계할 때, 서로 완벽히 다른 근거에 기반한 높은 신뢰도의 결정들이 모여 오탐(False Positive)을 억제하고 견고한 예측을 도출할 수 있다.⁴² 이는

사용자가 **Model B**의 설계에 있어 **Model A**와의 표현 유사도 제어를 목적함수에 추가하려는 시도가 단순한 휴리스틱이 아니라 신호 탐지 및 정보이론적으로 완벽하게 타당한 전략임을 시사한다.

대안적 앙상블 다양성 확보 방법론과의 장단점 비교 분석

다양성 확보를 위해 "**CKA 기반 정규화**" 외에도 여러 대안적 방법론을 손실 함수 및 훈련 전략으로 도입할 수 있다. 다음은 제안 방법과 주요 대안들을 이론적 근거, 구현의 복잡성, 그리고 포렌식 도메인 적용성을 기준으로 철저하게 비교한 결과이다.

방법론	핵심 원리 및 (a) 이론적 근거	(b) 구현 복잡도	(c) 포렌식 적용 가능성	장단점 및 특성 요약
1. CKA 정규화 (제안 방법)	(a) 표현 수준의 공분산 제어: 통계적 독립성을 측정하는 HSIC의 스케일 불변 변형을 통해 심층 신경망 다차원 공간의 완벽한 비상관화를 유도함. ¹³	높음. 대규모 행렬 내적 연산 및 미니배치 분산을 제어하기 위한 비편향(Unbiased) 추정기 구현 코드가 필수적임.	매우 높음. 의미 정보와 아티팩트 정보를 층(Layer) 수준에서 분리하여, 포렌식 특화된 "완전히 새로운 단서" 발굴을 강제함.	장점: 심층 특징 맵 단위의 완벽한 비상관화로 가장 구조적인 차이를 유도함. 단점: 과도 적용 시 표현 붕괴(Representation Collapse) 위험 존재. ⁴⁶
2. Gradient Diversity	(a) 기울기 방향의 다양성: 오차 역전파 시 앙상블 모델들 간 Gradient 벡터의 코사인 유사도를 패널티화하여 매개변수 갱신 궤적을 분산시킴. ²⁸	중간. 다중 모델의 그래디언트를 동시에 메모리에 올리고 병렬 역전파를 계산해야 하므로 메모리 부담이 있음.	보통. 최적화 경로의 분산일 뿐, 모델들이 결과적으로 추출해내는 특징(Feature)의 본질적 차이를 강제하긴 다소 어려움.	장점: 학습 불안정성이 낮고 Accuracy 침해가 적어 안전한 수렴 보장. 단점: 근본적으로 다른 아티팩트 종류를 강제 탐색하게 하는 효과는 미미함.

3. Error-guided Sampling	(a) 부스팅(Boosting) 철학: Model A가 잘못 예측하거나 높은 엔트로피를 보인 샘플에 높은 가중치를 부여하여 Model B가 이를 집중 학습하게 유도함. ¹⁸	낮음. 복잡한 행렬 연산 없이 데이터 로더 및 크로스 엔트로피 가중치 동적 조정만으로 단순 구현 가능.	높음. Model A가 놓치는 희귀 포렌식 샘플(Hard example)이나 미세 조작 영역을 공략하는 데 매우 직접적임.	장점: 학습 프레임워크 수정이 거의 불필요하며 직관적인 성과 향상. 단점: Model B가 라벨 노이즈나 지나친 이상치(Outlier)에만 과적합될 위험이 큼.
4. Feature Orthogonality	(a) 벡터 직교성 강제: 두 모델 가중치 행렬 간의 내적($\ W_A^T W_B\ $)이나 활성화 기반 Gram 행렬 자체의 프로베니우스 노름을 제어하여 직교성을 유도함. ²⁰	낮음. 행렬 간 내적만 수행하므로 CKA 추정기보다 수식이 훨씬 단순하고 연산 속도가 빠름.	낮음~보통. CKA가 가지는 등방성 스케일(Isotropic scaling) 불변성이 없어 차원이 다른 층간 비교에 부적합함.	장점: 연산 부하가 적어 실시간 모니터링 및 페널티 부여가 용이함. 단점: 회전이나 스케일 차이를 유의미하게 구별하지 못해 실제적 다양성 확보에 비효율적일 수 있음.
5. Prediction Disagreement	(a) 로짓 분산 극대화: Model A와 Model B의 출력 로짓(Logits)이나 Softmax 확률 분포 간의 KL 발산을 최대화하는 Anti-distillation	낮음. 특징 추출층 연산 없이 최종 Loss 계층에서 확률 거리 통계량만 추가하면 되므로 가벼움.	보통. 특징 공간 분리가 이루어졌는지 보장할 수 없고 단순히 모델의 예측값 분포만 달라질 가능성이 높음.	장점: 중간층을 건드리지 않아 CKA에서 발생하는 표현 붕괴(Collapse) 위험이 없음. 단점: A(3분류)와 B(이진분류) 간

	접근. ²⁷			출력 차원 불일치로 수식 정의가 복잡해짐.
6. Adversarial Complementarity	(a) 적대적 학습 보완: 한 모델이 취약한 적대적 예제(Adversarial Example)에 대해 다른 모델이 견고하도록 정규화하여 가설 공간의 공집합을 줄임. ⁶	매우 높음. 매이터레이션마다 적대적 예제를 생성하는 추가적인 순방향/역방향 패스가 필요하여 훈련 시간 급증.	매우 높음. 안티포렌식(Anti-forensics) 공격이나 워터마크 세탁 공격 등에 대한 앙상블 시스템의 전반적 생존성을 극대화.	장점: 고의적인 조작 공격 환경에서 가장 안전한 앙상블 보장. 단점: 연산 비용이 기하급수적으로 증가하며 하이퍼파라미터 튜닝이 매우 까다로움.

분석 결과의 종합: 제안된 **CKA** 정규화 방법론은 비편향 추정기 적용이라는 구현상의 난이도를 동반하지만, "Model A가 보지 못하는 깊은 수준의 특징(Feature) 자체를 보게 만든다"는 사용자의 본래 목적에 가장 부합하는 수학적 완결성을 지니고 있다. 반면 **Prediction Disagreement** 방식은 결과만 다르게 낼 뿐 어떤 필터를 형성할지는 통제 불능이며, **Error-guided** 방식은 하드 샘플에 편향된 취약한 모델을 만들 수 있다. 따라서 **CKA** 정규화를 메인 엔진으로 채택하되, 구현 시 기술적인 보완 장치를 겹겹이 설계하는 것이 최적의 아키텍처 전략이다.

실용적 구현을 위한 가이드라인 및 표현 붕괴 방지 전략

실제 PyTorch나 TensorFlow 등의 딥러닝 프레임워크를 활용하여 본 앙상블 아키텍처를 프로덕션 레벨로 구현할 때, 이론적 우수성이 모델 붕괴(Collapse)나 학습 마비로 이어지지 않게 하기 위한 고도의 엔지니어링 가이드라인을 제시한다.

1. CKA 측정 계층 (Layer Selection)의 지정 전략

CKA 페널티를 Model B의 어느 심도(Depth) 계층에 적용할 것인가는 앙상블 성능을 좌우하는 가장 치명적인 결정이다. 최종 분류를 담당하는 분류기(Classifier) 직전의 임베딩(Embedding) 벡터 공간에서 CKA를 최소화하는 것은 피해야 한다.

- **권장안:** 전체 네트워크 깊이를 기준으로 중반부에서 후반부에 이르는 중간 계층(**Middle-to-Deep Intermediate layers**), 즉 Global Average Pooling을 통과하기 전의 마지막 1~2개의 합성곱 피쳐 맵(Convolutional Feature Map) 블록에 대해 CKA를 측정하고 최소화해야 한다.
- **이론적 근거:** 최종 임베딩 층은 태스크 종속적(Task-specific)인 클래스 분리성(Class separability)을 담당한다.⁴⁸ Model A와 해당 계층의 표현을 극단적으로 다르게 만들도록

강제하면, Model B는 'Authentic'과 'Manipulated'라는 본연의 분리성 자체를 파괴하며 예측률이 50% 언저리로 떨어지는 치명적 손상을 입는다.⁴⁸ 따라서 Model A의 주요 의미적 특징이 잡히는 중간 블록과 Model B의 대응 블록 간 CKA를 최소화하여 추출하는 기반 필터(Base filters)의 성격을 고주파나 노이즈 중심으로 다르게 유도하고, 추출이 끝난 최종 임베딩은 온전히 크로스 엔트로피(L_{focal})에만 종속되어 자율적으로 클래스를 분류하도록 두는 것이 정확도-다양성 트레이드오프를 가장 우아하게 우회하는 비결이다.

2. 미니배치 크기 설정과 추정 안정성 확보

앞서 논의한 미니배치 단위 CKA 계산 시의 분산 문제를 극복하기 위한 환경 설정이다.

- **권장안: 비편향 CKA 추정기(Unbiased CKA estimator)** 함수를 사용자 정의로 완벽하게 구현하여 Loss 계산 그래프에 편입해야 하며, 미니배치 크기(Batch Size)는 최소 128에서 256 이상을 유지할 것을 강력히 권고한다.¹⁴
- **구현 시 주의점: PyTorch 구현 시 Gram 행렬에서 대각 성분 연산이 스칼라의 지수적 폭발을 일으키지 않도록** 마스킹(X.fill_diagonal_(0))과 텐서 노름 스케일링을 정교하게 처리해야 한다.¹⁴ 배치 사이즈가 64 미만일 경우 한 배치 내에 이미지 클래스가 고르게 분포하지 못해 Gram 행렬의 유사도 분포가 심하게 요동치며, 배치마다 CKA 기울기 갱신 방향이 역전되어 학습이 발산할 위험이 극도로 높아진다.

3. λ 하이퍼파라미터의 동적 스케줄링(Scheduling) 전략

λ 값에 대한 고정 상수 부여는 학습의 재앙적 실패를 부른다. 초기 에포크에서 랜덤 초기화된 Model B에게 CKA를 낮추라는 페널티를 주면 의미 없는 노이즈 매니폴드로 갇히게 된다.

- **권장안: 학습 초기에는 CKA를 끄고, 점진적으로 개입시키는 코사인 어닐링(Cosine Annealing) 기반의 웜업 커리큘럼(Warm-up Curriculum) 스케줄링을 도입한다.**³³
- **적용 방법:** 전체 학습 주기의 처음 10~20% 에포크에서는 $\lambda = 0$ 으로 설정하여 Model B가 $\mathcal{L}_{\{focal\}}$ 만으로 이미지의 기초적 포렌식 특징과 분류 능력을 획득하도록 한다. 이후 모델이 기본적 판별력(예: AUC 0.7 수준)을 갖춘 시점부터 λ 를 0.01에서 시작하여 최대 $\lambda_{max} \approx 0.05 \sim 0.1$ 범위 내로 코사인 곡선을 따라 천천히 상승시킨다.³³ 더불어 CKA 기반 손실 항에서 발생하는 기울기(Gradient)의 노름(Norm)이 $\mathcal{L}_{\{focal\}}$ 의 기울기 노름 대비 10~20% 비율을 초과하지 않도록 그래디언트 클리핑(Gradient Clipping)을 동적으로 적용하는 안전장치가 필수적이다.

4. 표현 붕괴(Representation Collapse) 방지와 상호정보량 제약

Model B가 Model A의 표현 공간과 멀어지기 위한 가장 '쉬운' 방법은 입력 이미지의 어떠한 구조적 특징도 반영하지 않는 백색 잡음(White noise)을 텐서로 출력하는 것이다. 이를 표현 붕괴라 한다.¹¹

- 해결책: Model B의 활성화 출력 f_B 와 입력 이미지 X , 그리고 정답 레이블 Y 간의 상호정보량(Mutual Information) 하한 제약(Lower Bound Constraint)을 은연중에 보장해야 한다.³ 기본적으로 $\mathcal{L}_{\text{focal}}$ 이 정답 Y 와의 MI를 높이는 역할을 수행하나, 붕괴를 적극 방지하기 위해 f_B 특징 행렬의 스펙트럼 노름(Spectral Norm)이 특정 임계값 이하로 떨어지지 않도록 특잇값(Singular value) 소실 방지 페널티를 손실 함수에 가버운 가중치로 곱들이는 것이 좋다.⁵² 또한 미니배치 내 임베딩 벡터들이 공간 내에 지나치게 군집화되지 않도록 초구면 에너지(Hyperspherical Energy) 분산 제약을 걸어주면 표현 붕괴를 극복할 수 있다.¹¹

결론 및 기대 산출물 요약

1. 관련 선행연구 핵심 요약

본 분석에서 도출된 CKA/HSIC, 앙상블 다양성, 포렌식 스페셜리스트와 관련된 주요 선행연구는 아래 표와 같이 요약된다.

대표 저자 및 연도	방법론 / 논문 핵심 주제	주요 발견 및 메커니즘	본 제안 아키텍처(포렌식) 적용 시사점
Ma et al. (2020) ³	HSIC Bottleneck	역전파 체인 룰 없이 총별로 HSIC(통계적 독립성) 기반 목적함수만으로 딥러닝 훈련에 성공함을 입증.	CKA/HSIC 통계량이 역전파 과정에서 안정적이고 강력한 방향성을 제공하는 정식 손실 함수로 작동함을 수학적으로 보증함.
Nguyen et al. (2021) ¹⁴	Unbiased Minibatch CKA	미니배치 샘플링 시 대각 성분으로 인한 편향을 제거하여 배치 크기에 독립적인 비편향 유사도 추정 수식 제안.	CKA 손실을 사용할 때 반드시 탑재해야 할 연산 모듈. 이것이 없을 경우 분산 폭발로 Model B의 학습이 붕괴됨.
Cogswell et al. (2015) ²⁰	DeCov Loss	은닉층 활성화 분포의 교차 공분산 비대각 성분을	포렌식 아티팩트와 같이 숨겨진 미세 특징을 단일 모델이

		최소화하여 특징의 직교성과 다양성을 극대화.	다양하게 포착하려면 직교화 정규화가 필수적임을 제시함.
Shamir & Coviello (2020) ²⁶	Anti-Distillation	모델 앙상블의 예측 벡터 상관관계를 낮춤(의도적 이격) 가설 공간 탐색 범위를 넓히고 견고성을 확보.	Model A(Teacher)를 의도적으로 회피하여 새로운 관점을 습득하는 Model B(Student)의 훈련 패러다임에 직접적 영감을 제공함.
Meyen et al. (2021) ⁴²	Binary Specialist Theory	범용 분류기 조합보다, 서로 다른 정보원에 특화되고 무관한(Uncorrelated) 이진 전문가 집단이 신호탐지이론상 더 나음을 증명.	Model A(3-class RGB 제너럴)와 Model B(Binary 스페셜리스트) 간 CKA 제어 앙상블이 최고의 포렌식 조합이라는 이론적 근거.

2. 포렌식 도메인 시나리오 분석: 본 접근법의 유효성과 한계

매우 유효한 시나리오 (Highly Effective Scenarios):

본 제안 방법은 생성형 AI 이미지(GAN, 확산 모델 등)와 고전적 수작업 조작(Splicing, Copy-move)이 혼재된 환경에서 압도적인 파괴력을 지닌다. Model A가 모바일넷(MobileNetV2)의 특성상 이미지 내 사물의 왜곡, 인체 관절의 기형적 형태 등 전역적인 '의미론적 이상(Semantic anomaly)'을 기준으로 AI 생성 여부와 조작을 식별하는 데 최적화된다면, CKA 페널티에 묶인 Model B는 이를 철저히 외면하게 된다. 결국 Model B는 크로스 엔트로피의 압박 속에서 살아남기 위해 인간의 눈에는 보이지 않으나 데이터 통계상 명백히 존재하는 주파수 대역의 절단, 크로마 서브샘플링(Chroma subsampling)의 불일치, 노이즈 패턴의 지역적 경계선 등 픽셀 레벨의 포렌식 아티팩트를 자발적으로 발굴하는 현미경 메커니즘을 획득하게 될 것이다. 이는 현존하는 그 어떤 포렌식 단일 모델보다 상호 보완성이 뛰어난 방패가 된다.

부적합하거나 위험한 시나리오 (Unsuitable Scenarios):

그러나 조작 이미지가 소셜 미디어를 거치며 극도로 강한 JPEG 재압축(Re-compression), 해상도 다운샘플링, 가우시안 블러링 등 전역적 파괴(Global degradation) 필터를 강하게 거친 경우에는 이 접근이 부적합할 수 있다. 이러한 환경에서는 미세한 픽셀 레벨의 아티팩트가 모두

소실되므로, Model B가 찾아내야 할 고주파 대역의 정보 자체가 증발한다. 이 상황에서 CKA 페널티가 강제되면 Model B는 존재하지도 않는 특징을 찾으려 해마다 표현 붕괴에 빠지고, 오탐(False Positive)을 양산하는 결과로 이어질 수 있다. 따라서 실무 배포 시에는 입력 데이터의 해상도나 품질 점수를 사전 평가하여, 극저품질 이미지에 대해서는 Model B의 신뢰도 가중치를 동적으로 하락시키는 적응형 라우팅(Adaptive routing) 기법의 도입이 수반되어야 할 것이다.

결론적으로, CKA를 손실 함수로 편입하여 이기종 스펙트리스트를 강제 분리하는 본 앙상블 아키텍처 설계는 다중 모달리티 이미지 포렌식 분야의 차세대 방법론으로서 이론적, 수학적으로 완벽한 설득력을 지닌다. 비편향 추정기 구현과 정교한 하이퍼파라미터 커리큘럼 스케줄링이라는 허들만 성공적으로 엔지니어링한다면, 가장 견고하고 포괄적인 위변조 탐지 생태계를 구축할 수 있을 것이다.

참고 자료

1. Similarity of Neural Network Representations Revisited - Department of Computer Science, University of Toronto, 3월 21, 2026에 액세스, <https://www.cs.utoronto.ca/~hinton/absps/similarity.pdf>
2. Similarity of Neural Network Representations Revisited - Proceedings of Machine Learning Research, 3월 21, 2026에 액세스, <http://proceedings.mlr.press/v97/kornblith19a/kornblith19a.pdf>
3. The HSIC Bottleneck: Deep Learning without Back-Propagation, 3월 21, 2026에 액세스, <https://ojs.aaai.org/index.php/AAAI/article/view/5950/5806>
4. The HSIC Bottleneck: Deep Learning without Back-Propagation, 3월 21, 2026에 액세스, <https://arxiv.org/abs/1908.01580>
5. Towards Continual Learning Desiderata via HSIC-Bottleneck Orthogonalization and Equiangular Embedding - arXiv, 3월 21, 2026에 액세스, <https://arxiv.org/html/2401.09067v1>
6. Revisiting Hilbert-Schmidt Information Bottleneck for Adversarial Robustness - NeurIPS, 3월 21, 2026에 액세스, https://papers.neurips.cc/paper_files/paper/2021/file/055e31fa43e652cb4ab6c0ee845c8d36-Paper.pdf
7. Information bottleneck-based Hebbian learning rule naturally ties working memory and synaptic updates - Frontiers, 3월 21, 2026에 액세스, <https://www.frontiersin.org/journals/computational-neuroscience/articles/10.3389/fncom.2024.1240348/full>
8. Laor Initialization: A New Weight Initialization Method for the Backpropagation of Deep Learning - MDPI, 3월 21, 2026에 액세스, <https://www.mdpi.com/2504-2289/9/7/181>
9. Information bottleneck-based Hebbian learning rule naturally ties working memory and synaptic updates - PMC, 3월 21, 2026에 액세스, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11137249/>
10. Distilling Representational Similarity using Centered Kernel Alignment (CKA) - UQ eSpace - The University of Queensland, 3월 21, 2026에 액세스, https://espace.library.uq.edu.au/view/UQ:575f049/UQ575f049_OA.pdf
11. Enhancing Diversity in Bayesian Deep Learning via Hyperspherical Energy

- Minimization of CKA - NIPS, 3월 21, 2026에 액세스,
https://proceedings.neurips.cc/paper_files/paper/2024/file/f9e72ee379bb781f3005775c870a3871-Paper-Conference.pdf
12. Enhancing Diversity in Bayesian Deep Learning via Hyperspherical Energy Minimization of CKA - arXiv, 3월 21, 2026에 액세스,
<https://arxiv.org/html/2411.00259v1>
 13. Centered Kernel Alignment (CKA) Overview - Emergent Mind, 3월 21, 2026에 액세스, <https://www.emergentmind.com/topics/centered-kernel-alignment-cka>
 14. DO WIDE AND DEEP NETWORKS LEARN THE SAME THINGS? UNCOVERING HOW NEURAL NETWORK REPRESENTATIONS VARY WITH WIDTH AND DEPTH - OpenReview, 3월 21, 2026에 액세스, <https://openreview.net/pdf?id=KJNcAkY8tY4>
 15. Source-Free Model Transferability Assessment for Smart Surveillance via Randomly Initialized Networks - MDPI, 3월 21, 2026에 액세스,
<https://www.mdpi.com/1424-8220/25/13/3856>
 16. Implementing Negative Correlation Learning in Evolutionary, 3월 21, 2026에 액세스, <https://www.irma-international.org/viewtitle/28038/?isxn=9781599048079>
 17. Diversity and Generalization in Neural Network Ensembles - Proceedings of Machine Learning Research, 3월 21, 2026에 액세스,
<https://proceedings.mlr.press/v151/ortega22a/ortega22a.pdf>
 18. [2011.02952] Generalized Negative Correlation Learning for Deep Ensembling - arXiv, 3월 21, 2026에 액세스, <https://arxiv.org/abs/2011.02952>
 19. Ensemble Learning through Diversity Management: Theory, Algorithms, and Applications, 3월 21, 2026에 액세스,
<http://staff.ustc.edu.cn/~hchen/tutorial/IJCNN2011.pdf>
 20. [1511.06068] Reducing Overfitting in Deep Networks by Decorrelating Representations, 3월 21, 2026에 액세스, <https://arxiv.org/abs/1511.06068>
 21. Reducing Overfitting in Deep Networks by Decorrelating Representations., 3월 21, 2026에 액세스,
https://mlp.cc.gatech.edu/papers/2016/cagzb_iclr16/cagzb_iclr16.pdf
 22. A Deep Neural Network Regularization Measure: The Class-Based Decorrelation Method, 3월 21, 2026에 액세스,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC11154264/>
 23. Nonesuch Records (@nonesuch.com) - Bluesky, 3월 21, 2026에 액세스,
<https://bsky.app/profile/nonesuch.com>
 24. On Bilevel Optimization without Full Unrolls: Methods and, 3월 21, 2026에 액세스,
https://utoronto.scholaris.ca/bitstream/1807/126835/3/Vicol_Paul_Adrian_202303_PhD_thesis.pdf
 25. Reducing Model Churn: Stable Re-training of Conversational Agents - ACL Anthology, 3월 21, 2026에 액세스, <https://aclanthology.org/2022.sigdial-1.2.pdf>
 26. Anti-Distillation: Improving reproducibility of deep networks - ResearchGate, 3월 21, 2026에 액세스,
https://www.researchgate.net/publication/344779903_Anti-Distillation_Improving_reproducibility_of_deep_networks
 27. anti-distillation: improving reproducibility - arXiv, 3월 21, 2026에 액세스,
<https://arxiv.org/pdf/2010.09923>

28. Negative correlation learning for classification ensembles | Request PDF - ResearchGate, 3월 21, 2026에 액세스,
https://www.researchgate.net/publication/221534090_Negative_correlation_learning_for_classification_ensembles
29. Diversity Balancing for Two-Stage Collaborative Filtering in Recommender Systems - MDPI, 3월 21, 2026에 액세스,
<https://www.mdpi.com/2076-3417/10/4/1257>
30. Diversity-Aware Algorithms - Emergent Mind, 3월 21, 2026에 액세스,
<https://www.emergentmind.com/topics/diversity-aware-algorithms>
31. Novel Ensemble Diversification Methods for Open-Set Scenarios, 3월 21, 2026에 액세스,
https://openaccess.thecvf.com/content/WACV2022/papers/Farber_Novel_Ensemble_Diversification_Methods_for_Open-Set_Scenarios_WACV_2022_paper.pdf
32. Self-Error Adjustment: Theory and Practice of Balancing Individual Performance and Diversity in Ensemble Learning - arXiv, 3월 21, 2026에 액세스,
<https://arxiv.org/html/2508.04948v1>
33. TRepliNa: Layer-wise CKA+REPINA Alignment Improves Low-Resource Machine Translation in Aya-23 8B - ACL Anthology, 3월 21, 2026에 액세스,
<https://aclanthology.org/2025.mmls-1.3.pdf>
34. Image Forensics - Hany Farid - University of California, Berkeley, 3월 21, 2026에 액세스, <https://farid.berkeley.edu/downloads/publications/CVReference20.pdf>
35. Forensic Self-Descriptions Are All You Need for Zero-Shot Detection, Open-Set Source Attribution, and Clustering of AI-generated Images - arXiv, 3월 21, 2026에 액세스, <https://arxiv.org/html/2503.21003v1>
36. Learning Rich Features for Image Manipulation Detection - CVF Open Access, 3월 21, 2026에 액세스,
https://openaccess.thecvf.com/content_cvpr_2018/CameraReady/2813.pdf
37. arXiv:1805.04953v1 [cs.CV] 13 May 2018, 3월 21, 2026에 액세스,
<https://arxiv.org/pdf/1805.04953>
38. Learning Rich Features for Image Manipulation Detection - CVF Open Access, 3월 21, 2026에 액세스,
https://openaccess.thecvf.com/content_cvpr_2018/papers/Zhou_Learning_Rich_Features_CVPR_2018_paper.pdf
39. Multi-branch network for double JPEG detection and localization - PMC, 3월 21, 2026에 액세스, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12134093/>
40. Photo Forensics from JPEG Dimples - Hany Farid, 3월 21, 2026에 액세스,
<https://farid.berkeley.edu/downloads/publications/wifs17.pdf>
41. Image Forensics from Chroma Subsampling of High-Quality JPEG Images - ResearchGate, 3월 21, 2026에 액세스,
https://www.researchgate.net/publication/334331302_Image_Forensics_from_Chroma_Subsampling_of_High-Quality_JPEG_Images
42. Information-Theoretic Measures of Metacognition: Bounds and Relation to Group Performance - PMC, 3월 21, 2026에 액세스,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12618015/>
43. Human Cognitive Simulation Framework - Emergent Mind, 3월 21, 2026에 액세스,

- <https://www.emergentmind.com/topics/human-cognitive-simulation-framework>
44. Weighing Votes in Human–Machine Collaboration for Hazard Recognition: Inferring a Hazard-Based Perceptual Threshold and Decision Confidence from Electroencephalogram Wavelets | Journal of Construction Engineering and Management | Vol 149, No 9 - ASCE Library, 3월 21, 2026에 액세스, <https://ascelibrary.org/doi/10.1061/JCEMD4.COENG-13351>
 45. Centered Kernel Alignment Loss - Emergent Mind, 3월 21, 2026에 액세스, <https://www.emergentmind.com/topics/centered-kernel-alignment-cka-loss>
 46. Track: Poster Session 1 East - NeurIPS, 3월 21, 2026에 액세스, <https://neurips.cc/virtual/2024/session/108362>
 47. CVPR Poster On the Effectiveness of Partial Variance Reduction in Federated Learning With Heterogeneous Data - The Computer Vision Foundation, 3월 21, 2026에 액세스, <https://cvpr.thecvf.com/virtual/2023/poster/21139>
 48. RegMean++: Enhancing Effectiveness and Generalization of Regression Mean for Model Merging - OpenReview, 3월 21, 2026에 액세스, <https://openreview.net/pdf?id=H5IDsSCS9i>
 49. Why Do Better Loss Functions Lead to Less Transferable Features? - OpenReview, 3월 21, 2026에 액세스, <https://openreview.net/pdf?id=8twKpG5s8Qh>
 50. TRepLiNa: Layer-wise CKA+REPINA Alignment Improves Low-Resource Machine Translation in Aya-23 8B - arXiv, 3월 21, 2026에 액세스, <https://arxiv.org/html/2510.06249v1>
 51. NeurIPS 2025 Posters, 3월 21, 2026에 액세스, <https://neurips.cc/virtual/2025/loc/san-diego/events/poster>
 52. Spectral Geometry for Deep Learning: Compression and Hallucination Detection via Random Matrix Theory - arXiv, 3월 21, 2026에 액세스, <https://arxiv.org/html/2601.17357v1>