

이미지 위변조 탐지를 위한 DAAC(Disagreement-Aware Adaptive Consensus) 합의 기법에 관한 연구

정준¹, 문수혁¹

¹ 동서울대학교 컴퓨터소프트웨어학과 학부생

jj81271000@gmail.com, m51187251@gmail.com

DAAC(Disagreement-Aware Adaptive Consensus) for Image Forgery Detection

Jun-Jeong¹, Moon-Su Hyeok¹


¹ Dept. of Computer Software, Dong-Seoul University

요 약

생성형 인공지능의 발전으로 이미지 위변조는 편집조작부터 확산(Diffusion) 및 GAN(Generative Adversarial Networks)기술을 이용하여 합성까지 다양해지고 있다. 이에 따라 단일 탐지원리에 의존하는 방법은 도메인 편향을 피하기 어렵다. 이 문제를 해결하기 위해 다중 전문 에이전트를 결합한 접근이 필요하다. 본 연구에서는 다중 전문 에이전트 간 구조적 불일치를 활용하는 새로운 합의 기법인 DAAC(Disagreement-Aware Adaptive Consensus)을 제안하여 이미지의 위변조 탐지 성능을 개선하였다. Frequency, Noise, FatFormer, Spatial의 전문 에이전트 각각은 특정 클래스에서 구조적 한계를 보인다. Frequency, Noise, Spatial은 AI생성(ai_generated) 클래스에서 F1 값이 0.000을 기록하였으며, FatFormer 에이전트는 위변조(manipulated) 클래스에 대한 판정에서 F1값이 0.000의 성능을 보였다. 본 연구에서 제안한 DAAC방식은 에이전트 간 판정 불일치를 학습 신호로 활용함으로써 모든 클래스에서 균형 잡힌 위변조 탐지 성능을 달성하였다. F1 측정치가 0.861을 기록하여, 기존의 합의 기법인 COBRA(CoMBined Regression Strategy)의 0.266 대비 +0.595의 우수한 성능을 얻었다.

1. 서론

이미지 위변조 탐지는 조작 탐지와 생성형 이미지 기반 탐지를 동시에 만족해야 한다. 실제 운영에서는 JPEG 압축 흔적, 센서 노이즈 불일치, 공간적 조작 흔적, 생성 모델 아티팩트가 혼재하므로, 단일 모델의 편향은 오탐/미탐(False positive/Falsse negative)으로 직결된다. 이에 이질적 탐지 원리를 가진 다수의 전문 에이전트를 조합하는 다중 에이전트 접근이 해법으로 주목받고 있다[1]. 그러나 다중 에이전트 간의 합의(consensus) 단계에서 병목현상이 문제로 부상하고 있다. 기존 합의 기법인 COBRA는 에이전트별 신뢰도(trust)점수 기반 합의를 제공하며 RoT/DRWA/AVGA 세 가지 합의 알고리즘을 자동 선택하여 적용하는 방법을 제안한다[2]. 그러나 이러한 방식은 모두 사전 정의된 신뢰도 점수에 의존한다. 이미지 포렌식 분야에서는 FatFormer, TruFor등이 제안되었으나, 다중 에이전트 합의 단계에서 불일치 패턴을 학습 신호로 활용한 연구는 드물다[3][4]. 본 연구는 이러한 문제를 해결하기 위해 불일치 인지형 적응합의(Disagreement-Aware Adaptive Consensus)방



식을 제안하였다.

(그림1) COBRA 프레임워크의 개요

2. DAAC(Disagreement-Aware Adaptive Consensus)

DAAC방식의 기본원리는 멀티 에이전트 간의 “누가 맞았는가”가 아닌 “어떻게 서로 다르게 틀린가”를 학습 신호로 활용하는 것이다. 에이전트 간의 판정 충돌로 구성된 43차원 메타 특징을 활용해서 LR(Logistic Regression), GBM(Gredient Boosting Machine), MLP(Multi-Layer Perceptron) 세 분류기를 학습하여 개별 에이전트들의 맹점이 오히려 이미지 위변조 탐지에 중요한 근거가 됨을 정량적으로 확인하였다. 본 연구에서는 다음과 같은 3가지 내용을 수행하였다.


① 이미지 위변조 탐지에서 에이전트 간 판정 불

일치를 명시적 학습 신호로 활용하는 합의 프레임워크 DAAC를 제안함

② 에이전트별 특정 클래스에 대한 구조적 한계점을 DAAC로 극복할 수 있음을 실험을 통해 증명함

③ 고정 샘플셋 10개시드 실험과 6개 데이터 조합 총 60회 일반화 실험에서 DAAC가 COBRA 대비 일관된 성능 우위를 보임을 증명함

n 개의 에이전트가 이미지 x 에 대해 판정 $v_i \in V$ 와 confidence $c_i \in [0,1]$ 을 독립 산출한다. 여기서 $V = \{\text{authentic, manipulated, ai_generated, uncertain}\}$ 은 에이전트 수준의 판정 집합이다. Uncertain은 validation set에서 F1을 최대화하도록 보정된 임계 값에 의해 결정된다. DAAC의 학습 목표는 최종 클래스 $C = \{\text{authentic, manipulated, ai_generated}\}$ 에 대한 합의 함수 $f: \{(v_i, c_i)\}_{i=1}^n \rightarrow C$ 를 데이터로부터 학습하는 것이다. COBRA는 f 를 handcrafted 수식으로 정의하지만, DAAC는 불일치 구조를 포함한 43차원 메타 특징 위에서 f 를 학습한다. 그림 2는 DAAC에 사용하는 4개의 에이전트와 43개의 메타 특징이 만들어지는 과정에 관한 것이다.



(그림2) DAAC 에이전트 및 43차원 메타 특징 구성

집단특징(Aggregate feature)은 전체 합의 수준을 요약하는 아래의 5가지의 벡터로 표현된다.

$$\sigma_c^2 = \frac{1}{n} \sum_{i=1}^n (c_i - \bar{c})^2, \quad \bar{c} = \frac{1}{n} \sum_{i=1}^n c_i \quad (1)$$

confidence variance(σ_c^2)는 확신도 분산을 나타낸다.

$$H = - \sum_{k \in V} p_k \log p_k, \quad p_k = \frac{N_k}{n} \quad (2)$$

verdict entropy(H)는 판정 불확실성을 나타낸다.

$$\Delta c = \max c_i - \min c_i \quad (3)$$

max-min confidence gap(Δc)은 극단적 confidence 차이를 나타낸다.

$$U = |\{v_1, \dots, v_n\}| \quad (4)$$

unique verdict count(U)는 판정 다양성을 나타낸다.

$$r = \frac{\max_k |i : v_i = k|}{n} \quad (5)$$

majority ratio(r)는 다수결 집중도를 나타낸다. 본 연구의 다중 에이전트 시스템을 구성하는 4개의 전문 에이전트의 영역과 각 에이전트의 사용모델명은 표 1과 같다[5][6].

<표 1> 4개 전문 에이전트 구성

에이전트영역	Frequency	Noise	FatFormer	Spatial
사용모델명	CAT-Net	MVSS-Net	CLIP ViT-L/14+DWT	Mesorch

각 에이전트는 이미지 포렌식의 주요 분석 대상인 주파수, 노이즈, 공간적 특징 및 시각적 문맥 정보를 독립적으로 분석하도록 설계되었다. 각 도메인에 최적화된 최신 모델을 배치함으로써, 단일 모델이 가질 수 있는 탐지 맹점을 상호 보완하고 다양한 위변조 유형에 대해 높은 강건성을 확보하였다.

3. 성능비교 실험 및 결과

본 연구에서 수행한 실험은 크게 주요 성능 비교를 위한 실험과 일반화 능력 검증을 위한 실험으로 구분된다. 표 2는 각 실험에 사용된 데이터셋에 관한 것이다.

<표 2> 실험 환경 설정 비교

항목	주요 성능 비교 실험	일반화 검증 실험
목적	방법 간 성능 비교	데이터셋 이동에 대한 일반화 검증
데이터셋	CASIA2 (Au 500 + Tp 500) + GenImage BigGAN (500)	DS-A~D (출처-유형 교차 4종) + OpenSDI + AI-GenBench proxy
총 샘플	1,500장	조합별 500장
Split	train/val/test = 0.6/0.2/0.2	train/val/test = 0.6/0.2/0.2
반복 횟수	seeds 300~309 (10회)	6개 조합 × 10개 시드 = 총 60회 실험
통계 검정	paired Wilcoxon vs COBRA	sign test + Wilcoxon

데이터 분할(Split)은 이미지 단위 무작위 분할을 적용하였다. CASIA2의 경우 동일 원본에서 파생된 변형 이미지가 존재하지 않으며, GenImage의 BigGAN 데이터는 학습용과 평가용이 같은 생성 프롬프트를 공유하지 않도록 구성되어 있어서, 학습 데이터의 출처 정보가 평가 데이터로 새어 들어가는 문제가 없다. 일반화 검증 실험의 경우 조합별로 동일한 분할 비율을 적용하되, 데이터셋 간 이미지 중복은 없도록 하였다. 실험은 합의 기반 baseline으로 다수결, 가중 다수결, 그리고 COBRA를 사용하였다. DAAC는 43차원 메타 특징을 입력으로 LR, GBM, MLP 세 분류기를 각각 학습하여 비교한다. 각 에이전트의 판정 임계값은 validation set에서 F1을 최대화하도록 보정하였다.

4. 실험결과 분석

4.1 클래스별 F1 성능비교 및 분석

본 섹션에서는 각 전문 에이전트가 특정 도메인에서 보이는 한계를 분석하였다. DAAC는 43차원 메타 특징을 학습한 DAAC-LR, DAAC-GBM 두 분류기를 각각 비교하였다. 표 3은 단일 에이전트들의 클래스별 10개 시드 평균기반으로 F1 성능비교 한 결과이다.


<표 3> 클래스별 F1 성능비교

분석 모델	원본	위변조	AI 생성
Frequency(Standalone)	0.804	0.481	0.000
Noise(Standalone)	0.558	0.476	0.000
FatFormer(Standalone)	0.542	0.000	0.473
Spatial(Standalone)	0.570	0.355	0.000
COBRA	0.573	0.199	0.027
DAAC-LR	0.809	0.787	0.954
DAAC-GBM	0.821	0.800	0.963

Frequency/Noise/Spatial 에이전트는 AI 생성 클래스에 대한 판정에서 F1=0.000, FatFormer는 위변조 클래스에 대한 판정에서 F1=0.000의 구조적 맹점을 가진다. COBRA는 이 맹점을 가중 합산으로 전파하는 방법으로 낮은 성능을 기록한 반면, DAAC는 에이전트 간 판정 충돌 패턴을 학습함으로써, 입력 이미지에 대해 원본, 위변조, AI 생성의 최종 클래스를 보다 균형 있게 산출한다. 또한, DAAC는 높은 일치도를 보였다.

4.2 합의 기법 성능비교 실험 및 분석

그림 3은 규칙기반 합의 기법인 다수결, 가중 다수결, 그리고 COBRA와 DAAC 기반 LR, GBM, MLP 세 분류기를 각각 비교한 것이다.



(그림 3) 방법 간 Macro-F1 비교

본 연구에서 제안한 DAAC는 규칙기반 합의 기법보다 평균 +0.595 우수했다.

4.3 일반화 검증 성능비교 실험 및 분석

학습에 사용되지 않은 데이터셋 6개 조합을 이용한 실험에서 DAAC가 COBRA보다 우수하였다. 평균 차이는 +0.493 이고 단 한 번도 성능이 역전되지 않아 특정 데이터 조합에 의한 우연 효과가 아님을 확인하였다. 표 4는 다양한 데이터셋 소스 및 생성 모델의 변화(Domain shift)에 따른 제안 모델의 일반화 성능을 기존 COBRA 방법론과 비교한 것이다. 실험 결과치는 10개 시드 평균값이다.

<표 4> 일반화 검증 성능 비교결과

조합	Validation Aspect	COBRA F1	DAAC F1	Delta
DS-A (CASIA+BigGAN)	Baseline combination	0.277	0.835	+0.558
DS-B (ImageNet+CASIA+BigGAN)	Authentic source shift	0.274	0.867	+0.593
DS-C (CASIA+IMD2020+BigGAN)	manipulation type shift	0.303	0.898	+0.595
DS-D (ImageNet+IMD2020+BigGAN)	Both sources unseen	0.300	0.863	+0.564
OpenSDI	Real-world distribution	0.177	0.409	+0.232
AI-GenBench proxy	Non-BigGAN generators	0.333	0.750	+0.417

5. 결론

본 논문은 이미지 위변조 탐지에서 단일 인공지능 모델의 한계점을 극복하고 다중 에이전트를 효율적으로 운영하기 위해, 에이전트 간 불일치 패턴을 명시적으로 학습하는 합의 기법 DAAC를 제안하였다. 주요 성능 비교 실험에서 제안한 DAAC-GBM은 macro-F1 분류값이 0.861을 기록하여 COBRA의 0.266 대비 0.595 높은 성능을 보였으며, 훈련에 사용되지 않은 6개 데이터셋 조합에 대한 일반화 검증 반복 실험에서도 DAAC는 평균 macro-F1 값이 0.772를 기록하여 COBRA의 0.279 대비 0.493 높은 성능을 나타냈다. 또한 에이전트 자체의 성능 개선 없이 합의 계층만 개선하더라도 +0.43 ~ +0.60 수준의 F1 값의 향상이 가능함을 실험을 통해 확인하였다. 본 연구를 통해 다중 에이전트 시스템에서 합의 기법의 설계가 개별 에이전트 성능보다 더 중요함을 입증하였다. 향후에는 DAAC의 최적 에이전트 조합과 추론시간, 모델 크기를 함께 분석해 온디바이스 상용화 가능성을 연구할 것이다.

참고문헌

- [1] Ojha, U., et al., Towards Universal Fake Image Detectors that Generalize Across Generative Models, CVPR, 2023, 24480-24489.
- [2] Haider, Z., et al., A framework for mitigating malicious RLHF feedback in LLM training using consensus based reward, Scientific Reports, 15, 9177, 2025.
- [3] Liu, H., et al., Forgery-aware Adaptive Transformer for Generalizable Synthetic Image Detection, CVPR, 2024, 10770-10780.
- [4] Guillaro, F., et al., TruFor: Leveraging All-Round Clues for Trustworthy Image Forgery Detection and Localization, CVPR, 2023, 20606-20615.
- [5] Kwon, M.-J., et al., CAT-Net: Compression Artifact Tracing Network for Detection and Localization of Image Splicing, WACV, 2021, 375-384.
- [6] Chen, X., et al., Image Manipulation Detection by Multi-View Multi-Scale Supervision, ICCV, 2021, 14185-14193.