

판정 결합 및 수정을 이용한 경량 이미지 위변조 탐지에 관한 연구

정준¹, 이용수¹, 문수혁¹

¹ 동서울대학교 컴퓨터소프트웨어학과 학부생

jj81271000@gmail.com, dydtn61498@naver.com, m51187251@gmail.com

Lightweight Image Forgery Detection with Prediction Aggregation and Revision

Jun-Jeong¹, Lee-yong su, Moon-Su Hyeok¹

¹ Dept. of Computer Software, Dong-Seoul University

요 약

딥페이크 악용과 생성형 AI 기반 사기가 확산되면서 이미지 위조 탐지는 현장 기기에서 즉시 동작해야 하는 문제가 되었다. 선행 연구 DAAC는 모델 불일치 패턴을 활용해 좋은 성능을 냈으나 엣지 기기에서 직접 실행하기 어렵다. 본 연구는 경량 기본 분류기와 보조 모델 두 개만으로 이 아이디어를 이어받되, 두 모델을 적극 결합할 때 발생하는 역교정 문제를 직접 다룬다. 기본 분류기 오분류의 74.3%가 고확신 오류여서 단순 임계값 방식으로는 접근이 어렵기 때문이다. 이를 위해 본 논문은 PAR(Prediction Aggregation and Revision)을 제안한다. PAR은 1단계에서 역신뢰도 가중 융합으로 판정 변경 후보를 생성하고, 2단계에서 XGBoost(Extreme Gradient Boost) 기반 비대칭 위험 평가로 해로운 변경만 선택적으로 되돌린다. 실험 결과 역교정 55% 억제와 평균 F1 0.9652를 달성하였으며, Raspberry Pi 5에서 CPU 215ms, USB Edge TPU 75ms, PCIe HAT 54ms의 종단간 추론시간을 확인하였다.

1. 서론

생성형 AI의 발전으로 딥페이크 악용, 이미지 기반 사기, 전쟁 상황의 정보 교란 피해가 증가함에 따라, 이미지 위변조 탐지는 서버 사후 분석을 넘어 현장 단말에서 즉시 동작해야 하는 문제로 바뀌고 있다. 선행 연구인 DAAC[1]은 여러 모델의 불일치 패턴을 활용해 좋은 성능을 보였으나 Raspberry Pi 5 같은 엣지 기기에서 직접 실행하기 어렵다. 본 연구는 그 핵심 아이디어를 두 개의 경량 모델로 재구성하여 엣지 환경에서 실용적으로 사용하는 것을 목표로 한다.

그러나 두 모델을 적극적으로 결합하면 예상치 못한 문제가 나타난다. 분석 결과 기본 분류기의 오분류 중 74.3%가 신뢰도 0.6을 넘는 고확신 오류로, 저신뢰 샘플에만 개입하는 임계값 방식으로는 대부분의 오류에 접근조차 할 수 없다. 반면 보조 모델을 항상 결합하면 기본 분류기의 판정을 바꾸는 교정 건수가 늘어나는 동시에, 기본 분류기가 원래 맞았던 샘플을 틀리게 바꾸는 역교정도 함께 증가한다.

이 역교정 문제를 해결하기 위해 본 논문은 PAR

을 제안한다. PAR은 1단계에서 역신뢰도 가중 융합으로 판정 변경 후보를 만들고, 2단계에서 판정이 실제로 바뀐 경우에만 XGBoost 기반 위험 평가를 수행하여 해로운 변경만 선택적으로 되돌린다.

2. 관련연구

2.1 DAAC

DAAC는 각 모델의 점수보다도 불일치 정보가 더 좋은 단서가 될 수 있음을 보여준다. 본 연구에서는 모델 사이에서 발생하는 정보를 활용한다는 아이디어를 Edge Device 환경에서 적용한다.

2.2 Focal Loss

Focal Loss는 쉬운 샘플이 학습을 지배하지 않도록 어려운 샘플의 손실 기여를 상대적으로 키우는 방식을 제안하였다[2]. 본 연구에서는 기본 분류기의 정답 확률을 이용하여 기본 분류기가 약한 샘플에 더 큰 가중치를 부여하는 방식으로 보조 모델을 학습한다.

2.3 MobileNet V2

MobileNet V2는 모바일 환경에서 정확도와 연산량의 균형을 제공하는 대표적인 경량 백본이다[3]. 본 논문에서 MobileNet V2를 기본 분류기와 보조 모델의 백본으로 선택하였다.

3. 문제 분석

기본 분류기인 MNV2(MobileNet v2) 오분류는 낮은 신뢰도 영역에만 모여 있지 않다. 오분류의 74.3%가 신뢰도 0.6을 넘으므로, 저신뢰 샘플에서만 보조 모델을 호출하는 방식은 전체 오분류의 25.7%에만 개입할 수 있다. 보조 모델을 항상 결합하면 더 많은 오류를 교정할 수 있지만, 동시에 기본 분류기가 원래 맞았던 샘플의 판정을 1단계 결과에서 잘못 바꾸어 오답으로 만드는 역교정이 발생한다. 따라서 본 연구의 핵심은 더 많은 변경을 만드는 것이 아니라, 해로운 변경만 선택적으로 되돌리는 것이다.

4. PAR

4.1 전체 구조

PAR은 2단계로 구성되어 있다. 1단계는 기본 분류기의 출력 $\{P_{base}(auth), P_{base}(manip), P_{base}(aigen)\}$ 과 보조 모델의 출력 $\{P_{aux}(auth), P_{aux}(manip)\}$ 을 합쳐 기본 분류기의 판정 변경 후보를 만들고, 2단계는 기본 분류기의 판정 변경 후보를 선택적으로 거부한다. 그림1은 PAR의 전체 아키텍처를 보여준다.




그림1에서 보듯이 입력 이미지는 기본 분류기와 보조 모델에 동시에 전달된다. 두 모델의 출력은 1단계에 사용된다. 1단계의 결과가 기본 분류기의 판정을 바꾸려는 경우에만 2단계가 동작하여 기본 분류기의 판정으로 되돌릴지 아니면 바꿀지를 결정한다.

4.2 보조 모델 학습

보조 모델은 MobileNet V2를 백본으로 하는 이진 분류기이며, 기본 분류기의 약점을 보이는 샘플 중심으로 학습된다.

식(1)은 보조 모델의 손실함수이다.

$$L = -\frac{1}{N} \sum_i w(x_i) \sum_{c \in Y_{aux}} \mathbf{1}[y_i = c] \log P_{aux}(c|x_i) \quad (1)$$

식(2)는 각 샘플의 가중치 정의이다.

$$w(x_i) = (1 - P_{base}(y_i|x_i))^\gamma \quad (2)$$

여기서 보조 모델의 클래스 집합은 원본과 편집 조작 두 범주로만 이루어지며, 이는 문제 구조에 근거한 설계다. 3.문제인식에서 보듯 기본 분류기의 오분류 중 78.3%가 원본-편집 조작 분류에 집중되고, AI 생성 클래스는 기본 분류기가 이미 높은 신뢰도로 처리하므로, 보조 모델이 AI 생성 출력까지 학습하면 표현 용량이 분산되고 1단계 결합 시 불필요한 간섭으로 역교정이 추가 발생할 수 있다. $P_{aux}(c|x_i)$ 는 보조 모델이 클래스 c 에 부여한 확률, $P_{base}(y|x_i)$ 는 기본 분류기가 정답 클래스에 부여한 확률로, 기본 분류기가 흔들리는 샘플일수록 더 큰 가중치를 받는다.

본 논문의 주 실험에서는 $\gamma = 1$ 을 사용하였다.

4.3 1단계 역신뢰도 가중 융합

1단계에서는 기본 분류기와 보조 모델의 출력을 단순 평균하지 않는다. 대신 각각의 모델의 확신도를 통해 가중치를 정한다. 이를 통해 확신이 큰 모델의 영향력은 줄이고 덜 확신하는 모델의 영향력을 높인다. 이 조절의 강도는 α 로 조절한다.

식(3)은 두 모델의 각각의 가중치이다.

$$w_{base} = \frac{1}{\max(P_{base})^\alpha}, w_{aux} = \frac{1}{\max(P_{aux})^\alpha} \quad (3)$$

식(4)는 가중치를 반영한 최종 점수이다.

$$score(c) = w_{base}P_{base}(c) + w_{aux}P_{aux}(c) \quad (4)$$

4.4 2단계 선택적 판정 되돌림

2단계는 기본 분류기의 예측값과 1단계의 결과가 다를 때만 동작한다. 해당 단계를 통해 PAR은 1단계를 통한 변경을 유지할지, 아니면 기본 분류기의 판정으로 되돌릴지 결정한다. 본 연구에서 2단계는 XGBoost로 구현하였다. 입력 특징은 아래의 표(1)와 같다.

<표 1> 2단계 입력 특징 정의

기호	정의
$P_X(c)$	$X \in \{base, aux, stage1\}$
m_X	$P_X(manip) - P_X(auth), X \in \{base, aux, stage1\}$
$conf_X$	$\max_c P_X(c), X \in \{base, aux, stage1\}$
$d_{A,B}$	$\mathbf{1}[y_A \neq y_B], (A, B) \in \{(base, aux), (base, stage1)\}$
t	(y_{base}, y_{stage1}) 원-핫 인코딩(9차원)
m_{aigen}	$P_{base}(aigen) - \max(P_{base}(auth), P_{base}(manip))$

5. 실험 결과

표 1은 본 연구에 쓰인 실험 데이터셋 구성이다.

<표 2> 실험 데이터셋 구성

데이터셋	샘플 수
base(CASIA2+BigGAN)	1500(1000+500)
dsC	900
OpenSDI	900
aigenproxy	900
합계	4200

5.1 기본 분류기 대비 PAR 전체 알고리즘

다음 표 1은 본 연구에서 제안하는 PAR 전체 알고리즘과 기본 분류기 단독 모델 간의 주요 성능 지표를 비교한 결과이다.

<표 3> 기본 분류기 단독과 PAR 전체 알고리즘 성능 비교


방법	교정=역교정+순이득	평균 F1	$\Delta F1$	교정률
기본 분류기	—	0.9581	—	—
PAR	52=18+34	0.9652	+0.71	0.6538

표 1에서 보듯이 PAR 알고리즘은 4200장의 데이터셋에서 총 52건의 교정과 18건의 역교정을 기록하며 기본 분류기의 오답을 교정하는 비율인 교정률 0.6538과 총 순이득 34건을 달성했다. 메인 평균 F1 점수는 0.9652로 기본 분류기 대비 0.71%p 상승되었다. 이러

한 성능 개선은 교정과 역교정을 더한 70건의 사례를 대상으로 이항 검정(Binomial Test)을 실시한 결과에서 교정 성공 사례가 역교정 사례에 비해 통계적으로 유의함을 나타낸다.

5.2 데이터셋별 결과

앞선 주요 성능 비교에 이어, 제안하는 PAR 알고리즘이 개별 데이터셋에서 어떠한 세부적인 교정 양상을 보이는지 분석하였다. 그림 2는 각 데이터셋에 대한 1단계 및 2단계(PAR)의 역교정 건수 변화와 기본 분류기 대비 F1 점수이다.



(그림 2) 데이터셋별 기본 분류기와 PAR 비교


그림 2에 나타난 바와 같이, 2단계 모듈은 대부분의 데이터셋에서 1단계의 역교정을 유의미하게 감소시켰다. 특히 모든 데이터셋에서 기준 분류기 대비 향상된 F1 점수를 기록하며 성능 개선 효과를 입증했다. 하지만, eigenproxy 데이터셋은 알고리즘의 한계를 명확히 보여준다. 해당 데이터셋에서 PAR은 역교정을 100.0%(2건 → 0건) 차단해 기본 분류기 대비 최종 F1 점수는 상승시켰으나, 1단계의 유익한 교정(12건)마저 일부 되돌려 순이익이 5로 축소되었다. 이는 해로운 변경을 완벽히 차단하는 과정에서 발생하는 유효 교정의 손실을 보여주며, 향후 알고리즘 최적화 시 개선해야 할 주요 과제이다.

5.3 PAR 중단간 추론시간 측정 실험

본 실험에서는 총 50장의 입력 이미지로 2단계가 활성화된 PAR 중단간 추론시간을 측정하였다.

표 2는 각 backend별 PAR의 평균 중단간 추론시간이다.

<그림 3> 단계별 추론 시간



각각의 backend 모두에서 총 추론시간의 93~95%가 1단계에서 발생하며, 2단계 추론은 전체의 5~7%에 불과하다. 이는 2단계 설계가 비용대비 성능이 우수

함을 나타낸다. 전체 지연 시간 기준으로 PCIe 연결 HAT은 54.961 ms를 기록했다. 이는 초당 약 18프레임 처리 속도에 해당하며, 엣지 환경에서의 실시간 이미지 위변조 탐지뿐만 아니라 영상 위변조 탐지에도 적용 가능성을 보여준다.

5.4 기본 분류기 확장

PAR이 특정 기본 분류기에 종속되는 구조인지 확인하기 위해, MobileCLIP 기반 기본 분류기를 사용해 평가를 진행하였다.

해당 실험에 대해서는 난수 초기값을 바꾸어 10회 반복 실험을 수행하였다.

<표 4> 10회 반복 실험 평균 결과

기본 분류기	기본분류기 단독	PAR	평균 역교정	역교정 감소율
MobileNetV2	0.9581	0.9644	20.2	49.5% (40.0건 → 20.2건)
MobileCLIP	0.9455	0.9498	10.0	76.6% (43.0건 → 10.0건)

표 3의 핵심은 역교정 감소율이다. 1단계 결합은 기본 분류기의 판정을 바꾸면서 불가피하게 역교정을 발생시키는데, PAR의 2단계가 이중 상당수를 선택적으로 되돌린다. MobileNetV2에서는 1단계에서 생긴 역교정의 49.5%를, MobileCLIP 미세조정에서 76.7%를 억제하였으며, 이 경향은 10회 반복 실험 전체에서 일관되게 재현되었다. 동시에 F1도 두 설정 모두 기본 분류기에서 단독 보다 높게 유지가 되는데 이는 PAR이 역교정을 줄이는 과정에서 유익한 교정까지 함께 제거하지 않음을 나타낸다.

6. 결론

본 논문은 두 경량 모델의 적극적 결합이 불가피하게 만드는 역교정 문제를 정면으로 다루는 PAR을 제안하였다. PAR의 1단계는 역실패도 가중 융합으로 판정 변경 후보를 만들고, 2단계는 해로운 변경만 선택적으로 되돌린다. 실험 결과 PAR은 1단계 역교정의 55.0%를 억제하면서 평균 F1 0.9652를 달성하였고, 기본 분류기를 MobileCLIP으로 교체한 반복 실험에서도 역교정 감소(76.7%)와 F1 향상이 일관되게 재현되었다. Raspberry Pi 5에서 2단계가 활성화된 경우의 중단간 추론시간은 PCIe HAT 기준 54.961 ms로, 2단계가 전체 지연의 10% 미만을 차지하였다. 다만 일부 데이터셋에서 2단계가 유익한 교정까지 함께 되돌리는 과보수 경향이 남아 있으므로, 향후에는 억제와 보존 사이의 균형을 더 정교하게 조절할 필요가 있다.

참고문헌

- [1] Jeong, J., et al., A Study on DAAC (Disagreement-Aware Adaptive Consensus) for Image Forgery Detection, ASK 2026, 2026.
- [2] Lin, T.-Y., et al., Focal Loss for Dense Object Detection, ICCV, 2017, 2980-2988.
- [3] Sandler, M., et al., MobileNetV2: Inverted Residuals and Linear Bottlenecks, CVPR, 2018, 4510-4520.